

Batch processing vs Stream processing

Le **traitement par lots (batch processing)** et le **traitement par flux (stream processing)** sont deux approches fondamentales du big data, différant principalement par le moment où les données sont traitées et la latence des résultats.

Traitement par Lots (Batch Processing)

Le traitement par lots consiste à collecter de grands volumes de données sur une période donnée (par exemple, une journée ou une semaine), à les stocker, puis à les traiter en une seule fois, lors d'une exécution planifiée.

- **Caractéristiques :**
 - **Latence élevée :** Les résultats ne sont pas immédiats ; ils sont disponibles après la fin du traitement du lot.
 - **Volume de données :** Idéal pour des volumes massifs de données historiques.
 - **Complexité :** Généralement moins complexe à mettre en œuvre que le traitement par flux.
 - **Efficacité :** Optimisé pour le débit (throughput) et l'efficacité des ressources lors de tâches intensives.
- **Exemples d'utilisation :**
 - **Rapports financiers mensuels ou hebdomadaires :** Génération de bilans de ventes consolidés à la fin d'une période donnée.
 - **Calcul de la paie (payroll) :** Traitement des salaires de tous les employés en une seule opération planifiée.
 - **Entraînement de modèles de *machine learning* :** Utilisation de vastes ensembles de données historiques pour former des algorithmes.
 - **Sauvegardes et archivage de données :** Copie et déplacement de grands volumes de données à des intervalles réguliers.

Traitement par Flux (Stream Processing)

Le traitement par flux (ou *streaming*) traite les données de manière continue, au fur et à mesure qu'elles sont générées ou reçues, sans attendre qu'un lot s'accumule.

- **Caractéristiques :**
 - **Faible latence :** Fournit des informations et permet des actions en temps quasi réel (secondes, voire millisecondes).
 - **Données continues et illimitées :** Gère un flux constant et non borné de données (unbounded data streams).
 - **Complexité :** Plus complexe à concevoir et à gérer, notamment pour assurer la cohérence des données et la tolérance aux pannes.

- **Actionnabilité immédiate** : Permet une réponse instantanée aux événements.
- **Exemples d'utilisation** :
 - **Détection de fraude bancaire** : Analyse en temps réel des transactions par carte de crédit pour identifier immédiatement les activités suspectes.
 - **Analyse du trafic web en direct** : Suivi instantané des utilisateurs actifs, des pages vues, etc., pour les plateformes de commerce électronique ou les médias sociaux.
 - **Systèmes IoT (Internet des Objets)** : Traitement continu des données provenant de capteurs (gestion du trafic urbain, surveillance de la santé) pour des alertes instantanées.
 - **Systèmes de trading algorithmique** : Réaction instantanée aux fluctuations du marché boursier.

Résumé des différences

Caractéristique	Traitement par Lots (Batch)	Traitement par Flux (Stream)
Approche	Traite de grands ensembles de données accumulées.	Traite les données individuellement ou par micro-lots continuellement.
Latence	Élevée (minutes, heures).	Faible (secondes, millisecondes).
Moment du traitement	Planifié, à intervalles réguliers.	Continu, en temps réel.
Cas d'utilisation	Rapports, analyse historique, ETL vers data warehouse.	Détection de fraude, monitoring en temps réel, IoT.

Dans la pratique, de nombreuses architectures modernes combinent les deux approches (architectures hybrides comme Lambda ou Kappa) pour bénéficier à la fois d'une analyse complète et précise des données historiques et d'une réactivité en temps réel. Des outils populaires incluent Apache Spark pour les deux paradigmes (bien que souvent associé au batch) et [Apache Kafka](#) ou Apache Flink pour le streaming.

Hadoop est un framework conçu spécifiquement pour le batch processing distribué de très grands ensembles de données

La latence fait référence au délai qui se produit entre le moment où un utilisateur effectue une action sur un réseau ou une application Web et le moment où il reçoit une réponse. Une autre définition de la latence est le temps total ou « aller-retour » nécessaire pour qu'un paquet de données se déplace.