
DATA MINING – Séance 1

Enseignant : ER-RAHMOUNY Hamza

1 Définition des termes

DATA (Données)

- Représentation symbolique d'un fait, d'un événement ou d'un objet.
- Sous une forme **utilisable par un ordinateur**.

MINING (Exploitation/Extraction)

- Chercher et extraire quelque chose de précieux enfoui dans la masse.

2 Pourquoi le nom "Data Mining" ?

- La **donnée** est déjà là, comme **la roche** (matière brute).
- L'**information précieuse** est cachée dans ces données, comme **l'or dans la roche**.
- Le rôle du **Data Mining** : **extraire, révéler et valoriser** cette information.

Analogie :

Métaphore	Informatique
Roche / sable / pierre	Données brutes
Or caché	Information précieuse
Mining	Data Mining (extraction de la valeur)

3 Pourquoi un Data Engineer doit-il connaître le Data Mining ?

- Le **Data Engineering** permet de collecter, nettoyer et organiser les données.
 - Mais **sans Data Mining**, l'information précieuse reste cachée.
 - **Exemple** : Après le Data Engineering, on a beaucoup de sable et de pierre, mais l'or n'apparaît que grâce au Data Mining.
-

4 Conclusion

- Le **Data Mining** est essentiel pour transformer des **données brutes** en **information utile**.
 - Un **Data Engineer** doit comprendre le Data Mining pour **extraire de la valeur** des données qu'il gère.
-

- **QSM – Data Mining (QCM)**
 - Pourquoi dit-on que le **Data Mining** est comme l'extraction de l'or dans la roche ?
 - a) Parce que le Data Mining transforme les données brutes en informations précieuses.
 - b) Parce que le Data Mining crée de nouvelles données à partir de rien.
 - c) Parce que le Data Mining supprime toutes les données inutiles.
 - d) Parce que le Data Mining ne concerne que le stockage des données.
 - ✓ Réponse correcte : a)
-

Résumé clair – Définition du Data Mining

1 Définition du Data Mining – Points essentiels

◆ Définitions sélectionnées

- **Fayyad et al. :**
Le Data Mining est un **processus non trivial** permettant d'identifier dans les données des **motifs valides, nouveaux, utiles et compréhensibles**.
 - **Hand :**
Analyse de **données secondaires**, c'est-à-dire des données déjà collectées pour un autre but.
 - **Siebes :**
Induction automatique de **modèles et motifs compréhensibles** à partir de bases de données.
 - **Leamer (1978) :**
Processus guidé par les données pour **sélectionner un modèle statistique**.
-

2 Le Data Mining en tant que discipline

- Sous-discipline de l'**informatique**.
- Développe et analyse des **algorithmes**.
- Permet l'extraction efficace de **modèles et motifs**.

- Conçu pour des bases de données **grandes, variées** et parfois **complexes**.
-

3 ☐ Modèle vs Motif (Pattern)

☐ Modèle (Global)

- S'applique à **toutes les données**.
- Exemples :
 - Une **équation de régression** qui prédit le prix d'une maison en fonction de la surface et de l'emplacement.
 - Un arbre de décision qui classe tous les clients.

☐ Motif (Pattern, Local)

- S'applique à **une partie** des données seulement.
 - Exemples :
 - Règle d'association :
 “80 % des clients qui achètent du café achètent aussi du sucre.”
 - Un segment particulier découvert dans un clustering.
-

4 ☐ Objectifs du Data Mining

- Transformer des **grandes bases** en informations **utiles** et **compréhensibles**.
 - Découvrir des **connaissances nouvelles**.
 - Prédire : comportements, ventes, risques, fraudes...
 - Décrire : segmentation, regroupement des populations.
 - Aider à la **prise de décision stratégique** et **opérationnelle**.
-

5 ☐ AED (Analyse exploratoire) vs Data Mining

AED (Exploratoire)	Data Mining
Résumer, visualiser	Découvrir automatiquement
Formuler des hypothèses	Induire/tester des modèles
Statistiques descriptives	Algorithmes ML, réseaux neuronaux, clustering...
Histogrammes, scatterplots	Arbres, régression, K-Means...

6 Origines du Data Mining

- **Statistiques** → modèles, corrélations, prédiction.
- **Bases de données** → stockage massif, SQL, performance.
- **Intelligence Artificielle / Machine Learning** → algorithmes apprenants.

☞ Leur fusion = **naissance du Data Mining**.

7 Histoire du Data Mining (KDD → Big Data)

- **Années 1980** : KDD (Knowledge Discovery in Databases).
 - **Années 1990** : le terme *Data Mining* apparaît, premières conférences KDD (1995).
 - **Années 2000** : algorithmes supervisés et non supervisés.
 - **Années 2010–2020** : Big Data + ML automatisé.
 - **Aujourd’hui** : partie centrale de la Data Science et de l’IA.
-

✓ QCM – Questions de Synthèse

QCM 1 — Définition

Le Data Mining consiste principalement à :

- a) Stocker les données efficacement
- b) Trouver des motifs valides, nouveaux et utiles dans les données
- c) Modifier les données à leur source
- d) Supprimer les données non pertinentes

✓ ☐ Réponse : b

QCM 2 — Modèle vs Motif

Quel exemple correspond à un **motif (pattern)** ?

- a) Une équation qui prédit le prix d’une maison
- b) Une règle disant “80 % des clients café achètent du sucre”
- c) Une droite de régression générale
- d) Un modèle complet de prédiction

✓ ☐ Réponse : b

QCM 3 — Objectif du Data Mining

Lequel n'est PAS un objectif du Data Mining ?

- a) Découvrir des connaissances cachées
- b) Segmenter les populations
- c) Visualiser les données uniquement
- d) Prédire des comportements

✓ ☐ Réponse : c

QCM 4 — AED vs Data Mining

L'AED sert principalement à :

- a) Appliquer automatiquement des modèles
- b) Résumer et visualiser les données
- c) Prédire les comportements
- d) Découvrir des règles générales automatiquement

✓ ☐ Réponse : b

QCM 5 — Origines du Data Mining

Le Data Mining est né de la fusion entre :

- a) Réseaux, cybersécurité et IoT
- b) Bases de données, statistiques et IA
- c) HTML, PHP et SQL
- d) Analyse financière et comptabilité

✓ ☐ Réponse : b

Data Mining (Suite Séance 1)

1 Domaines d'application du Data Mining

◆ Domaines généraux

- **Marketing & e-commerce** : segmentation clients, recommandations (Amazon, Netflix).
- **Finance & Assurance** : détection de fraude, scoring de crédit.
- **Santé & Bio-informatique** : aide au diagnostic, analyse génomique.

- **Web & Réseaux sociaux** : détection de communautés, analyse de sentiments.

◆ Domaines au Maroc

- **E-commerce** : Jumia Maroc, Hmizate, Glovo (recommandations, segmentation).
- **Finance & Banques** : Attijariwafa Bank, Bank Al-Maghrib (fraude, scoring).
- **Santé** : Groupe Akdital (prévision, diagnostic assisté).
- **Transport & Smart City** : laboratoires de recherche (analyse trafic, données urbaines).

2 Processus KDD (Knowledge Discovery in Databases)

☞ C'est le **processus global** de découverte de connaissances.

Étapes :

1. **Sélection**
Choisir les données pertinentes pour l'objectif.
2. **Prétraitement**
Nettoyage, gestion des valeurs manquantes, outliers.
3. **Transformation**
Normalisation, réduction de dimension, encodage.
4. **Data Mining**
Application des algorithmes : classification, clustering, association...
5. **Interprétation & Évaluation**
Comprendre les résultats et appuyer la décision business.

3 Méthodologie CRISP-DM (1996)

☞ Standard industriel du Data Mining (toujours utilisé aujourd'hui).

Étapes :

1. **Business Understanding**
Comprendre le problème métier.
2. **Data Understanding**
Explorer, visualiser, décrire les données.

3. **Data Preparation**
Nettoyer et préparer le dataset final.
 4. **Modeling**
Choisir et entraîner les algorithmes.
 5. **Evaluation**
Valider que le modèle répond au besoin métier.
 6. **Deployment**
Mise en production, utilisation réelle.
-

4 Outils et Environnements Logiciels

◆ Python (le plus utilisé en entreprise)

- **pandas** → préparation, nettoyage.
- **scikit-learn** → classification, clustering, régression.
- **matplotlib** / **seaborn** → visualisation.

Avantages : open source, puissant, facile, énorme communauté.

◆ Logiciels spécialisés

- **Weka** → simple, utilisé à l'université.
- **Orange** → workflows visuels (drag & drop).
- **RapidMiner** → outil professionnel (version gratuite limitée).

◆ Datasets publics

- **Iris** → classification.
 - **Titanic** → survie.
 - **Adult** → prédiction revenu.
 - **MNIST** → chiffres manuscrits.
 - **Sources :** UCI Repository, Kaggle, Open Data Maroc.
-

QCM – Questions de Synthèse (QSM)

QCM 1 — Domaines d'application

Le Data Mining est utilisé dans :

- a) La segmentation des clients
- b) La détection de fraude
- c) L'analyse génomique
- d) Toutes les réponses

✓ ☐ Réponse : d

QCM 2 — Processus KDD

Quelle étape appartient au processus KDD ?

- a) Création d'un site web
- b) Prétraitement des données
- c) Installation d'un serveur
- d) Compilation de code

✓ ☐ Réponse : b

QCM 3 — CRISP-DM

La dernière étape de la méthodologie CRISP-DM est :

- a) Business Understanding
- b) Data Preparation
- c) Deployment
- d) Modeling

✓ ☐ Réponse : c

QCM 4 — Outils Python

Quel outil Python est utilisé pour les algorithmes de Data Mining ?

- a) pandas
- b) matplotlib
- c) scikit-learn
- d) seaborn

✓ ☐ Réponse : c

QCM 5 — Logiciels spécialisés

Quel outil permet de créer des **workflows visuels** (drag & drop) ?

a) Weka

b) Orange

c) VS Code

d) Excel

✓ ☐ Réponse : b

Chapitre 2

PROCESSUS KDD + PRÉTRAITEMENT

🔗 Résumé clair et complet (style cours)

☐ 1. Processus KDD (Knowledge Discovery in Databases)

Le KDD est le **processus complet** pour transformer les données brutes → en **connaissances utiles**.

✦ Étapes du KDD :

1. Sélection

- Choisir les données pertinentes pour l'objectif.
- Réduire le volume, améliorer la qualité.

2. Prétraitement

- Nettoyage : valeurs manquantes, doublons, erreurs.
- Détection des outliers.
- Harmonisation.

3. Transformation

- Normalisation, codage, réduction de dimension.

4. Data Mining

- Appliquer les algorithmes (classification, clustering, règles...).

5. Interprétation / Évaluation

- Analyser les résultats.
- Prendre une décision.

2. Sélection des Données

Objectif :

Prendre **uniquement les données utiles** → pour obtenir de bons résultats.

🔍 Pourquoi sélectionner ?

- Réduire le volume.
- Améliorer la qualité.
- Respecter l'objectif du projet.
- Réduire le temps de calcul.
- Faciliter l'interprétation.

🔧 Comment sélectionner ?

- **Manuellement** : expertise humaine.
- **Automatiquement** : corrélation, Random Forest feature importance.
- **Hybride** : mélange des deux.

🔧 ☐ Outils utilisés :

- Requêtes : **SQL, Pandas**
- Cleaning : **Excel, OpenRefine**
- Feature selection : **Weka, Orange, Scikit-Learn**

✦ Sélectionner = poser la bonne question avant d'avoir la bonne réponse.

☐ 3. Prétraitement des Données

🎯 **Objectif :**

Rendre les données **fiables, cohérentes, exploitables**.

⚠ ☐ À savoir :

- Le prétraitement prend **≈ 70% du temps** d'un projet.
- *Garbage in* → *Garbage out* : mauvaise donnée = mauvais modèle.

☐ Pourquoi nettoyer ?

- Corriger erreurs / doublons.
- Gérer valeurs manquantes.
- Identifier valeurs aberrantes.
- Harmoniser formats (dates, unités...).
- Préparer pour transformation / Data Mining.

□ 3.1. Gestion des valeurs manquantes

Méthode	Principe	Quand l'utiliser
Suppression	Supprimer lignes/colonnes	Moins de 5% manquants
Imputation simple	Moyenne, médiane, mode	Variables continues/catégorielles
Imputation avancée	Régression, kNN	Données corrélées
Catégorie "manquant"	Ajouter un label spécial	Données qualitatives

□ 3.2. Détection des Outliers (valeurs aberrantes)

🔢 Méthodes statistiques :

- **Z-score** (>3 ou <-3)
- **IQR** ($Q1 - 1.5 \times IQR \rightarrow Q3 + 1.5 \times IQR$)

👁 Méthodes visuelles :

- Boxplot
- Scatterplot

□ Méthodes algorithmiques :

- Isolation Forest
- DBSCAN

✂ □ Traitement :

- Corriger
- Supprimer
- Garder (si observation réelle)

□ 3.3. Autres tâches du Prétraitement

- Normaliser les unités (€, \$, Dh → même unité)
 - Formater les dates
 - Harmoniser types et noms des colonnes
 - Supprimer doublons
 - Fusionner différentes sources (intégration)
-

✓ QCM (QSM) – Data Mining : Séances 2 & 3

QCM 1

Le KDD signifie :

- A. Knowledge Discovery in Databases
- B. Knowledge Data Detection
- C. Known Data Discovery
- D. Knowledge Driven Development

☞ **Bonne réponse : A**

QCM 2

Étape qui consiste à nettoyer et harmoniser les données :

- A. Sélection
- B. Prétraitement
- C. Transformation
- D. Data Mining

☞ **Bonne réponse : B**

QCM 3

"Garbage in → Garbage out" signifie :

- A. Le modèle est toujours précis
- B. Mauvaise donnée = mauvaise analyse
- C. On doit supprimer toutes les données
- D. Le Data Mining n'est pas important

☞ **Bonne réponse : B**

QCM 4

Méthode recommandée si $<5\%$ de valeurs manquantes :

- A. Imputation avancée
- B. Ajout d'une catégorie
- C. Suppression
- D. Clustering

☞ **Bonne réponse : C**

QCM 5

Les outliers peuvent être détectés par :

- A. Boxplot
- B. Z-score
- C. IQR
- D. Toutes les réponses

☞ **Bonne réponse : D**

QCM 6

Le Feature Selection peut être fait avec :

- A. Excel
- B. Random Forest
- C. Word
- D. PowerPoint

☞ **Bonne réponse : B**

QCM 7

Étape où l'on applique les algorithmes (classification, clustering) :

- A. Sélection

- B. Transformation
- C. Data Mining
- D. Interprétation

☞ **Bonne réponse : C**

QCM 8

Le prétraitement représente environ :

- A. 10% du temps
- B. 30%
- C. 70%
- D. 90%

☞ **Bonne réponse : C**

QCM 9

L'objectif de la sélection :

- A. Choisir toutes les données
- B. Choisir données pertinentes
- C. Augmenter la taille des données
- D. Supprimer toutes les valeurs manquantes

☞ **Bonne réponse : B**

QCM 10

Une méthode d'imputation avancée :

- A. Moyenne
- B. Régression
- C. Suppression
- D. Mode

☞ **Bonne réponse : B**

HNA **WALID**, voici **LE RÉSUMÉ LE PLUS CLAIR**, maħydit **WALOO**, derth **cours propre, organisé, logique**, b style simple w professionnel.

- QCM complet f-lâkhir.
-

TRANSFORMATION + DATA MINING

Résumé clair et organisé (STYLE COURS)**

1. Introduction : Pourquoi transformer les données ?

Après nettoyage, il faut **préparer mathématiquement** les données pour qu'elles soient compatibles avec les modèles.

🎯 Objectif :

- Avoir des données **numériques, cohérentes, sur la même échelle.**
 - Améliorer la performance des algorithmes.
 - Réduire la complexité et la redondance.
-

☐ 2. Étape du KDD utilisée ici : Transformation

🔄 Rappel du KDD :

1. Sélection
 2. Prétraitement
 3. **Transformation**
 4. Data Mining
 5. Interprétation
-

☐ 3. Transformation : Définition

La transformation consiste à :

- ✓ Mettre toutes les variables sur des **échelles comparables**.
- ✓ Réduire complexité et redondance.
- ✓ Encoder les données non numériques.
- ✓ Réduire la dimension.

Pourquoi ?

- Pour éviter que certaines variables dominent le modèle.
- Pour rendre les données exploitables par les algorithmes (ML/statistiques).

✦ Exemple :

- Revenu : $0 \rightarrow 1\,000\,000$ DH
 - Âge : $18 \rightarrow 60$
 - La distance Euclidienne serait dominée par *Revenu* → Mauvais modèle.
-

□ 4. Normalisation

Mettre les données sur une **même échelle**, souvent $[0,1]$.

✦ Méthodes de Normalisation :

1. Min-Max Scaling (la plus utilisée)

$$\left[\begin{array}{l} x' = \frac{x - \min(x)}{\max(x) - \min(x)} \end{array} \right]$$

- ✓ Donne valeurs entre 0 et 1
 - ✓ Pour données continues, **sans outliers**
-

2. Mean Normalization

$$\left[\begin{array}{l} x' = \frac{x - \text{moyenne}(x)}{\max(x) - \min(x)} \end{array} \right]$$

- ✓ Centrée sur 0
 - ✓ Pas adaptée aux outliers
-

3. Robust Scaling

$$x' = \frac{x - \text{médiane}(x)}{\text{IQR}}$$

✓ Très bon pour les données avec **outliers**

4. Unit Length / Normalisation par norme

$$x' = \frac{x}{|x|}$$

✓ Pour textes (vectorisation)

✓ Utilisée pour similarité cosinus

□ 5. Standardisation (Z-Score)

Recentrer les variables autour de zéro et leur donner la même échelle.

✦ Méthodes :

1. Standardisation classique (Z-Score)

$$z = \frac{x - \mu}{\sigma}$$

✓ Quand les données ont des unités différentes

✓ Utilisée dans la majorité des modèles ML

2. Robust Standardization

$$z = \frac{x - \text{médiane}}{\text{IQR}}$$

✓ Quand les données contiennent des **valeurs extrêmes**

3. Scaling by Range

$$z = \frac{x - \min(x)}{\max(x) - \min(x)}$$

- ✓ Simple
 - ✓ Pas de centrage réel
-

□ 6. Encodage des variables catégorielles

Transformer les données qualitatives en numériques.

✦ Méthodes :

1. Label Encoding

- Homme → 0
 - Femme → 1
 - ✓ Simple
 - ✗ Attention : crée un ordre artificiel
-

2. One-Hot Encoding

Ville → Marrakech / Casablanca / Rabat

- ✓ Crée 1 colonne par catégorie
 - ✓ Le plus utilisé en ML
-

3. Ordinal Encoding

Faible → 1

Moyen → 2

Élevé → 3

- ✓ Quand il existe un ordre (low, medium, high)
-

□ 7. Réduction de dimension

Réduire le nombre de variables tout en gardant la majorité de l'information.

✦ Techniques principales :

- **PCA (ACP)** → Analyse en Composantes Principales
- **Sélection de variables** (Feature Selection)

✦ Avantages :

- Moins de bruit
 - Calcul plus rapide
 - Meilleures performances
-

□ 8. Data Mining : Définition

Une fois les données prêtes → on applique les algorithmes.

📊 **Data Mining** = **extraire de la connaissance cachée** dans les données.

On cherche :

- ✓ tendances
 - ✓ relations
 - ✓ prédictions
 - ✓ regroupements
-

□ 9. Grandes techniques du Data Mining

Technique	Description	Objectif
Classification	Assigner une classe	Ex : spam / non spam
Association	Découvrir relations	Ex : Si A → B (panier d'achat)
Estimation	Prédire une valeur numérique	Ex : prix maison
Segmentation	Regrouper données en clusters	Ex : K-means
Prévision	Prédire valeurs futures	Ex : séries temporelles
Résumé	Décrire/synthétiser	Statistiques, visualisation

□ 10. Approches du Data Mining

✓ Approche statistique

- Moyenne, variance, corrélation
- Résumé, description

✓ Approche Machine Learning

- Classification
 - Régression
 - Clustering
 - Association
 - Analyse factorielle
-

QCM (QSM) – PARTIE TRANSFORMATION

Q1. La transformation consiste à :

- A. Nettoyer les données
- B. Mettre les données sur la même échelle
- C. Visualiser les résultats
- D. Faire la sélection

→ Réponse : B

Q2. La normalisation Min-Max donne des valeurs entre :

- A. $(-\infty, +\infty)$
- B. $[-1,1]$
- C. $[0,1]$
- D. $[0,100]$

→ Réponse : C

Q3. Quelle méthode est la meilleure en présence d'outliers ?

- A. Min-Max
- B. Robust Scaling
- C. One-Hot Encoding
- D. Scaling by Range

→ Réponse : B

Q4. Le One-Hot Encoding est utilisé pour :

- A. Ordre
- B. Variables numériques
- C. Variables catégorielles sans ordre
- D. Moyenne des données

→ Réponse : C

Q5. La standardisation Z-Score centre les données autour de :

- A. 1
- B. 100
- C. 0
- D. 10

→ Réponse : C

Q6. Le PCA sert à :

- A. Nettoyer
- B. Réduire la dimension
- C. Encoder
- D. Prédire

→ Réponse : B

Q7. Dans le Data Mining, la classification sert à :

- A. Prédire une valeur numérique
- B. Regrouper
- C. Attribuer une catégorie
- D. Décrire la population

→ Réponse : C

Q8. "Si A alors B" est une règle de :

- A. Classification
- B. Association
- C. Segmentation
- D. Régression

→ Réponse : B

Q9. K-Means appartient à :

- A. Classification
- B. Clustering
- C. Régression
- D. Association

→ Réponse : B

Q10. Le Data Mining appartient à quelle étape du KDD ?

- A. Sélection
- B. Prétraitement
- C. Transformation
- D. Analyse et extraction

→ Réponse : D

Deux grandes approches du Data Mining

1 Approche statistique

- **Objectif** : Décrire, comprendre et résumer les relations entre les données.
- **Outils et mesures** :
 - Moyenne
 - Variance
 - Écart-type
 - Corrélation
- **But** : Analyser les données pour obtenir une compréhension globale, détecter des tendances et résumer les informations.

2 Approche par Machine Learning

- **Objectif** : Prédire, classer ou regrouper des observations.
 - **Techniques principales** :
 - **Classification** : attribuer des observations à des catégories.
 - **Prédiction (régression)** : estimer des valeurs continues (ex : régression linéaire).
 - **Clustering (ex : K-Means)** : regrouper des données similaires.
 - **Association (ex : Apriori)** : identifier des règles fréquentes dans les données.
 - **Analyse factorielle (ex : ACP, CAH)** : réduction de dimensions et regroupement des variables.
-

Statistiques et mesures associées

Définition

La statistique est la science qui permet de collecter, organiser, analyser et interpréter des données pour répondre à une question de recherche.

Processus classique

1. Identifier une question ou un problème.
2. Collecter des données.
3. Analyser les données.
4. Tirer une conclusion.

Organisation des données

- Les données sont souvent stockées sous forme de **matrice** :
 - **Lignes** : individus / observations / cas
 - **Colonnes** : variables / caractéristiques mesurées

Exemple de matrice :

Stu	Gender	intro_extra
1234	male	extravert
1235	female	extravert
1236	female	introvert
...	...	...

Types de variables

Type	Sous-type	Exemple
Numériques	Continues	âge, taille
Numériques	Discrètes	nombre d'enfants
Catégorielles	Nominales	sport préféré, sexe
Catégorielles	Ordinales	satisfaction, note scolaire

Mesures de tendance centrale

- **Moyenne ($\bar{x}$)** : somme des valeurs divisée par le nombre d'observations.
 - Sensible aux valeurs extrêmes (outliers).
 - Non adaptée pour les données asymétriques ou catégorielles.

[
 $\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}$
]

- **Médiane** : valeur qui sépare les données en deux parties égales (50% en dessous et 50% au-dessus).
 - Pertinente pour obtenir un point central représentatif, surtout avec données asymétriques.

[
 \text{Si } n \text{ impair : Médiane = valeur du milieu}
 \text{Si } n \text{ pair : Médiane = moyenne des deux valeurs centrales}
]

QCM – Data Mining & Statistiques

Q1 : Quelles sont les deux grandes approches du Data Mining ?

- A) Statistique et Machine Learning ✓
- B) Analyse factorielle et Clustering
- C) Régression et Classification
- D) Moyenne et Médiane

Réponse : A

Explication : L'approche statistique décrit et résume, le ML prédit, classe ou regroupe.

Q2 : Quelle mesure statistique est sensible aux valeurs extrêmes ?

- A) Médiane
- B) Moyenne ✓
- C) Écart-type
- D) Corrélacion

Réponse : B

Explication : La moyenne est affectée par les outliers, la médiane non.

Q3 : Quelle technique est utilisée pour regrouper des observations similaires ?

- A) Régression linéaire
- B) Classification
- C) Clustering (K-Means) ✓
- D) Corrélacion

Réponse : C

Explication : Le clustering regroupe des données selon leur similarité.

Q4 : Quelle variable est nominale ?

- A) Note d'un examen
- B) Sport préféré ✓
- C) Âge
- D) Taille

Réponse : B

Explication : Nominal = catégorie sans ordre ; sport préféré est un exemple typique.

Q5 : Quelle mesure sépare les données en deux parties égales ?

- A) Moyenne
- B) Variance
- C) Médiane ✓
- D) Écart-type

Réponse : C

Explication : La médiane divise le jeu de données en 50% inférieur et supérieur.

Q6 : Quelle formule correspond à la moyenne d'un jeu de données ?

- A) $(x_1 + x_2 + \dots + x_n) \div n$ ✓
- B) Racine de la variance
- C) $(x_{\text{max}} - x_{\text{min}}) \div 2$
- D) $n \div \sum x_i$

Réponse : A

Q7 : La corrélation mesure :

- A) Le regroupement de données
- B) La force et la direction d'une relation linéaire ✓
- C) La variance des données
- D) La médiane

Réponse : B

Q8 : Quelles sont les étapes classiques d'une analyse statistique ?

- A) Analyser, collecter, tirer conclusion, identifier problème
- B) Identifier problème, collecter données, analyser, tirer conclusion ✓
- C) Collecter données, calculer corrélation, faire régression
- D) Moyenne, médiane, écart-type

Réponse : B

Q9 : La régression linéaire est utilisée pour :

- A) Regrouper des données
- B) Prévoir une variable continue ✓
- C) Classer des catégories
- D) Mesurer la corrélation

Réponse : B

Q10 : La variance mesure :

- A) La tendance centrale
- B) La dispersion des données autour de la moyenne ✓
- C) La relation entre deux variables
- D) La médiane

Réponse : B

Ok Walid 🤖, ghadi ndir **résumé clair, structuré et professionnel** de toute cette partie avec **QCM à la fin** pour réviser facilement. On va faire ça **progressif, concis, mais complet**, étape par étape.

Résumé Data Mining & Statistiques – Partie Médiane, Dispersion, Corrélation et Régression

1 Médiane et asymétrie

- **Médiane** : valeur qui sépare les données en deux parties égales (50% en dessous, 50% au-dessus).
 - **Impair** : Médiane = valeur centrale.
 - **Pair** : Médiane = moyenne des deux valeurs centrales.
- **Importance** : représentative d'un point central, surtout pour données asymétriques.
- **Asymétrie des distributions** :
 - **Symétrique** : Médiane $\approx$ Moyenne
 - **Positive (à droite)** : Moyenne $>$ Médiane

- **Négative (à gauche) :** Moyenne < Médiane
-

2 Mesures de dispersion

2.1 Variance

- Mesure la dispersion autour de la moyenne :
[
$$\text{Var}(X) = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

]
- Plus $\text{Var}(X)$ est grande $\rightarrow$ données dispersées.
- Sensible aux valeurs extrêmes (outliers).
- Unité : au carré (peu intuitive).

2.2 Écart-type

- Racine carrée de la variance :
[
$$\sigma = \sqrt{\text{Var}(X)}$$

]
- Même interprétation que la variance, mais plus intuitive (mêmes unités que les données).

2.3 Quartiles et IQR

- **Q1** : 25% des données en dessous
- **Q2** : Médiane
- **Q3** : 75% des données en dessous
- **IQR** : Écart interquartile = $Q3 - Q1$
 - Robuste aux valeurs extrêmes.
 - Détecte les outliers :
[
$$x < Q1 - 1.5 \times \text{IQR} \quad \text{ou} \quad x > Q3 + 1.5 \times \text{IQR}$$

]

2.4 Boxplot

- Boîte = $Q1$ à $Q3$
 - Ligne centrale = Médiane ($Q2$)
 - Moustaches = bornes normales ($1.5 \times \text{IQR}$)
 - Points isolés = outliers
-

3 ☐ Covariance et Corrélation

3.1 Covariance

- Mesure si deux variables varient ensemble :
 - Positive → augmentent ensemble
 - Négative → l'une augmente quand l'autre diminue
- Dépend de l'échelle des données :
[
$$\text{Cov}(X,Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n-1}$$

]

3.2 Corrélation de Pearson

- Version normalisée de la covariance :
[
$$r_{X,Y} = \frac{\text{Cov}(X,Y)}{\sigma_X \sigma_Y}$$

]
 - Interprétation :
 - $r \approx +1$ → forte corrélation positive
 - $r \approx -1$ → forte corrélation négative
 - $r \approx 0$ → pas de relation linéaire
 - Permet comparaison indépendamment des unités
 - **Heatmap** : visualisation simple des corrélations
-

4 ☐ Régression linéaire simple

- **Objectif** : modéliser la relation entre deux variables et prédire Y à partir de X
[
$$\hat{Y} = aX + b$$

]
 - a = pente (variation de Y quand X augmente de 1)
 - b = intercept (valeur de Y quand X=0)
 - **Erreur quadratique (résidus)** :
[
$$e_i = Y_i - \hat{Y}_i \quad ; \quad \text{SCE} = \sum (Y_i - \hat{Y}_i)^2$$

]
 - La droite optimale minimise la somme des carrés des résidus
-

5 ☐ Plan complet de la partie

1. Types de variables : Numériques (continues/discrètes), Catégorielles (nominales/ordinales)
 2. Mesures de tendance centrale : Moyenne, Médiane
 3. Mesures de dispersion : Variance, Écart-type, Quartiles, IQR, Boxplot
 4. Association vs indépendance
 5. Covariance & Corrélation
 6. Régression linéaire simple
 7. Distances & Similarités (non détaillées ici mais importantes pour clustering et ML)
-

QCM – Révision rapide

Q1 : La médiane sépare les données en combien de parties ?

- A) 3
 - B) 2 ✓
 - C) 4
 - D) 10
-

Q2 : Quelle mesure est robuste aux outliers ?

- A) Moyenne
 - B) Variance
 - C) Médiane & IQR ✓
 - D) Écart-type
-

Q3 : La variance est :

- A) Racine carrée de l'écart-type
 - B) La dispersion autour de la moyenne ✓
 - C) La corrélation
 - D) Le même que IQR
-

Q4 : Covariance positive signifie :

- A) X et Y varient dans le même sens ✓
- B) X et Y varient dans des sens opposés

- C) X et Y sont indépendants
 - D) X ou Y est constant
-

Q5 : Corrélation $r \approx -1$ indique :

- A) Pas de relation
 - B) Forte corrélation négative ✓
 - C) Forte corrélation positive
 - D) Corrélation faible
-

Q6 : Dans un boxplot, la ligne centrale représente :

- A) Q1
 - B) Q3
 - C) Médiane (Q2) ✓
 - D) Moyenne
-

Q7 : Régression linéaire simple permet de :

- A) Regrouper des données
 - B) Prévoir Y à partir de X ✓
 - C) Calculer l'IQR
 - D) Mesurer l'asymétrie
-

Q8 : L'écart-type est :

- A) La racine carrée de la variance ✓
 - B) Le même que la variance
 - C) La médiane
 - D) Le $Q3 - Q1$
-

Ok Walid 🤖, ghadi ndir **résumé clair et complet** de cette partie sur les **Distances et Similarités**, avec **plan, définitions, formules, exemples** et **QCM** à la fin pour réviser efficacement.

Distances et Similarités

1 Introduction

- Après avoir étudié les **mesures statistiques** (tendance centrale, dispersion, corrélation), en Data Mining il est essentiel de **comparer les individus** ou **mesurer la ressemblance entre objets**.
 - Ces mesures servent pour le **clustering, recommandations et classification**.
-

2 Distances et Similarités

2.1 Distance Euclidienne

- **Définition** : distance géométrique directe entre deux points dans l'espace.
 - **Formule** :
[
$$d(x,y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

]
 - **Utilisation** : données numériques continues (âge, taille, revenu...).
 - **Exemple** : distance “à vol d’oiseau” entre deux villes selon leurs coordonnées GPS.
 - **Limite** : sensible aux unités et aux valeurs extrêmes.
-

2.2 Distance de Manhattan

- **Définition** : somme des différences absolues sur chaque dimension.
 - **Formule** :
[
$$d(x,y) = \sum_{i=1}^n |x_i - y_i|$$

]
 - **Exemple** : distance entre deux villes dans une ville quadrillée (New York), en suivant uniquement les rues.
 - **Limite** : peut surpondérer les petites différences répétées.
-

2.3 Distance de Chebyshev

- **Définition** : considère uniquement la plus grande différence entre deux dimensions.
- **Formule** :
[

$$d(x,y) = \max_i |x_i - y_i|$$

- **Exemple** : contrôle qualité – un produit est rejeté si un seul critère dépasse la limite.
 - **Limite** : risque d'ignorer les écarts sur les autres dimensions.
-

2.4 Distance de Minkowski

- **Définition** : généralisation des distances Euclidienne, Manhattan et Chebyshev.
 - **Formule** :
[

$$d(x,y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{1/p}$$

]
 - **Cas particuliers** :
 - $p = 1 \rightarrow$ Manhattan
 - $p = 2 \rightarrow$ Euclidienne
 - $p \rightarrow \infty \rightarrow$ Chebyshev
 - **Limite** : sensibilité aux différences dépend du choix de p .
-

2.5 Similarité du Cosinus

- **Définition** : mesure l'angle entre deux vecteurs.
 - **Formule** :
[

$$\text{Sim}(x,y) = \frac{x \cdot y}{\|x\| \cdot \|y\|}$$

]
 - **Résultat** : entre -1 et 1
 - 1 $\rightarrow$ mêmes directions (identiques dans la tendance)
 - 0 $\rightarrow$ orthogonal (pas de rapport)
 - -1 $\rightarrow$ opposé (contraires)
 - **Utilisation** : comparer profils ou comportements (ex. clients achetant les mêmes produits, indépendamment de la quantité).
 - **Limite** : ignore les différences de quantité.
-

2.6 Similarité de Jaccard

- **Définition** : mesure le rapport entre ce que deux ensembles ont en commun et ce qu'ils ont au total.
- **Formule** :
[

$$\text{Sim}(A,B) = \frac{|A \cap B|}{|A \cup B|}$$

- **Résultat** : entre 0 et 1
 - 1 → ensembles identiques
 - 0 → aucun élément en commun
 - **Exemple** : deux clients ont acheté 3 produits pareils sur 10 → Similarité = $3/10 = 0.3$
 - **Limite** : ignore le nombre d'occurrences.
-

3 Plan synthétique de la partie

1. Types de variables
 2. Mesures de tendance centrale (moyenne, médiane)
 3. Mesures de dispersion (variance, écart-type, quartiles, IQR)
 4. Covariance et Corrélation
 5. Régression linéaire (moindres carrés)
 6. **Distances et Similarités** : Euclidienne, Manhattan, Chebyshev, Minkowski, Cosinus, Jaccard
-

4 QCM – Révision Distances & Similarités

Q1 : La distance Euclidienne mesure :

- A) La somme des différences absolues
 - B) La plus grande différence entre deux dimensions
 - C) La distance “à vol d’oiseau” entre deux points ✓
 - D) L’angle entre deux vecteurs
-

Q2 : La distance de Manhattan est adaptée pour :

- A) Données continues uniquement
 - B) Données tabulaires ou entières ✓
 - C) Mesurer angles
 - D) Détecter outliers
-

Q3 : La distance de Chebyshev correspond à :

- A) Moyenne des différences
 - B) Plus grande différence entre deux dimensions ✓
 - C) Distance Euclidienne
 - D) Somme des carrés
-

Q4 : La distance de Minkowski est :

- A) Une généralisation des distances Euclidienne, Manhattan et Chebyshev ✓
 - B) Une mesure de similarité
 - C) Un type de corrélation
 - D) Une statistique descriptive
-

Q5 : Similarité du Cosinus indique :

- A) La quantité exacte achetée par les clients
 - B) La direction ou tendance des vecteurs ✓
 - C) La distance maximale
 - D) La variance
-

Q6 : Similarité de Jaccard est utile quand :

- A) La quantité importe plus que la présence
 - B) La présence/absence compte plus que la quantité ✓
 - C) Les vecteurs sont orthogonaux
 - D) On veut calculer une distance Euclidienne
-

Data Mining et Machine Learning (Partie 3)

1 Data Mining –

- **Processus interactif et itératif :**
 1. **Sélection** : choisir les données pertinentes.
 2. **Préparation** : nettoyage, traitement des valeurs manquantes, gestion des outliers.
 3. **Data Mining** : application d'algorithmes (classification, clustering, etc.).
 4. **Interprétation / Évaluation** : analyser les résultats pour la prise de décision.
- **Schéma KDD :**
 - Base/entrepôt de données → Données cibles → Données préparées → Data Mining → Informations extraites → Connaissances

2 Techniques et objectifs du Data Mining

Technique	Description	Objectif principal
Résumé / Visualisation	Statistiques descriptives, clustering exploratoire	Comprendre et résumer les données
Classification	Arbre de décision, SVM, réseaux de neurones	Attribuer une classe à de nouvelles données
Association	Règles “si A alors B”	Découvrir les relations entre variables
Estimation / Régression	Prédire un salaire, un prix	Prédire une valeur numérique continue
Segmentation / Clustering	K-Means, clustering	Diviser la population en groupes homogènes
Prévision	Séries temporelles	Prédire des valeurs futures à partir de tendances passées

3 Deux grandes approches du Data Mining

1. **Approche statistique**
 - Décrire, comprendre et résumer les relations
 - Moyenne, variance, écart-type, corrélation
 2. **Approche Machine Learning**
 - Prédire, classer ou regrouper des observations
 - Classification, régression, clustering (K-Means), association (Apriori), analyse factorielle (ACP, CAH)
-

4 Machine Learning

- **Concept** : Passer d’une logique explicative à une logique prédictive et inductive centrée sur le modèle.
- **Définitions historiques** :
 - **Arthur Samuel (1959)** : le ML permet aux ordinateurs d’apprendre à partir de l’expérience sans être explicitement programmés.
 - **Tom M. Mitchell (1997)** : un programme apprend à partir d’une expérience **E**, pour une tâche **T** et une mesure de performance **P**, si sa performance sur **T** s’améliore avec **E**.
 - **IBM (2024)** : le ML est un sous-domaine de l’IA permettant aux systèmes d’apprendre automatiquement à partir des données et d’améliorer leurs performances dans le temps.

- **Évolution :**
 1. 1959 → idée de Samuel
 2. 1997 → définition scientifique de Mitchell
 3. 2024 → vision moderne centrée sur les données et la prédiction (IBM)
-

QCM – Partie 3

1. Qui a défini le ML comme "apprendre sans être explicitement programmé" ?
 - A) Tom Mitchell
 - B) IBM
 - C) Arthur Samuel ✓
 - D) Andrew Ng
2. Quelle année Arthur Samuel a formulé l'idée du ML ?
 - A) 1959 ✓
 - B) 1997
 - C) 2004
 - D) 2024
3. Selon Tom Mitchell, qu'est-ce qui améliore la performance d'un programme ?
 - A) Algorithme
 - B) Expérience E ✓
 - C) Variable X
 - D) Base de données
4. Selon IBM, le ML permet :
 - A) Apprendre à partir de données et améliorer les performances ✓
 - B) Nettoyer les données
 - C) Dessiner des graphiques
 - D) Calculer la moyenne
5. La logique principale du ML est :
 - A) Explicative
 - B) Descriptive
 - C) Prédicative et inductive ✓
 - D) Statistique simple
6. Technique du DM utilisée pour attribuer une classe :
 - A) Classification ✓
 - B) Régression
 - C) Clustering
 - D) Association
7. Technique du DM pour prédire une valeur continue :
 - A) Classification
 - B) Régression / Estimation ✓
 - C) Clustering
 - D) Association

8. Processus KDD commence par :
 - A) Prétraitement
 - B) Sélection des données ✓
 - C) Application d'algorithmes
 - D) Interprétation
 9. Processus KDD se termine par :
 - A) Sélection
 - B) Prétraitement
 - C) Interprétation / évaluation ✓
 - D) Transformation
 10. Les deux grandes approches du DM sont :
 - A) Statistique et Machine Learning ✓
 - B) Classification et Clustering
 - C) Association et Estimation
 - D) Régression et ACP
-

Parfait Walid 🤖, voici **un résumé clair et structuré uniquement pour la Partie 3 (Machine Learning pour le Data Mining)** avec les QCM correspondants.

Résumé – Partie 3 : Machine Learning pour le Data Mining

1 Pourquoi passer au Machine Learning pour le Data Mining ?

- **Volume & Variété** : Trop de données et de types (texte, images...).
 - **Relations complexes** : Non-linéarités et interactions difficiles à gérer par les méthodes statistiques classiques.
 - **Automatisation** : Le modèle apprend les règles à partir des exemples.
 - **Performance prédictive** : Meilleure généralisation sur de nouvelles données.
 - **Mise en production** : Pipelines, réentraînement, suivi des performances.
-

2 Tâches de Data Mining réalisées avec le ML

Tâche	But	Exemple	Algorithmes
Réduction de dimension	Résumer / visualiser l'information	Projection 2D	PCA, t-SNE

Classification	Prédire une étiquette	Détection de spam	Régression logistique, Arbre de décision
Règles d'association	Découvrir des co-occurrences	"lait → céréales"	Apriori, FP-Growth
Régression	Prédire une valeur continue	Prix d'un logement	Régression linéaire, Ridge
Clustering	Segmenter sans labels	Segmentation clients	K-Means, DBSCAN

3 ☐ Catégories d'apprentissage en Machine Learning

Catégorie	Idée	Données	Tâches
Supervisé	Exemples étiquetés	$X + y$	Classification, Régression
Non supervisé	Structures sans labels	X	Clustering, Réduction de dimension, Règles d'association, Détection d'anomalies
Semi-supervisé	Peu de labels	$X + y$ partiel	Améliorer classification / régression
Renforcement	Agent et récompenses	États, Actions, Récompense	Décision séquentielle

Remarque : RL n'est pas inclus car le Data Mining classique utilise des tâches hors-ligne. RL serait pertinent si l'action modifie le système (ex. recommandation dynamique, prix dynamiques).

4 ☐ Pipeline du Machine Learning

1. **Définir le problème & la métrique :** identifier la tâche et la métrique provisoire.
2. **Comprendre les données :** évaluer qualité, déséquilibre, variables.
3. **Split :** diviser les données en ensembles d'entraînement, validation et test.
4. **Préparer :** imputation, encodage, normalisation (fit sur Train).
5. **Entraîner & valider :** entraîner le modèle et valider ses performances.
6. **Tester, Déployer & Monitorer :** tester le modèle, le déployer et surveiller ses performances.

QCM – Partie 3 : Machine Learning pour le Data Mining

1. Pourquoi utiliser le ML pour le Data Mining ?
 - A) Pour visualiser les données seulement
 - B) Volume & variété, relations complexes, automatisation, performance prédictive ✓
 - C) Pour remplacer les bases de données
 - D) Pour supprimer les données manquantes
2. Quelle tâche DM utilise PCA ou t-SNE ?
 - A) Classification
 - B) Réduction de dimension ✓
 - C) Clustering
 - D) Association
3. Quel algorithme sert à prédire un prix ?
 - A) K-Means
 - B) Arbre de décision
 - C) Régression linéaire / Ridge ✓
 - D) Apriori
4. Quelle catégorie ML utilise des exemples étiquetés ?
 - A) Apprentissage supervisé ✓
 - B) Apprentissage non supervisé
 - C) Apprentissage semi-supervisé
 - D) Apprentissage par renforcement
5. Quelle catégorie ML sert à segmenter sans labels ?
 - A) Supervisé
 - B) Non supervisé ✓
 - C) Semi-supervisé
 - D) Renforcement
6. Pourquoi le RL n'est pas inclus en Data Mining classique ?
 - A) Les tâches sont hors-ligne sur des données fixes ✓
 - B) RL est trop simple
 - C) RL n'existe pas
 - D) Les algorithmes de DM ne fonctionnent pas
7. Étape du pipeline où l'on divise les données en Train/Validation/Test ?
 - A) Préparer
 - B) Split ✓
 - C) Définir métrique
 - D) Entraîner & valider
8. Étape du pipeline où l'on effectue l'imputation et la normalisation ?
 - A) Split
 - B) Préparer ✓
 - C) Définir métrique
 - D) Tester & Monitorer
9. Quel algorithme sert à découvrir des co-occurrences ?
 - A) Régression linéaire
 - B) Arbre de décision
 - C) Apriori / FP-Growth ✓
 - D) K-Means

10. Quelle tâche ML améliore la classification ou régression avec peu de labels ?
- A) Apprentissage supervisé
 - B) Apprentissage semi-supervisé ✓
 - C) Non supervisé
 - D) Reinforcement Learning
-

Partier 4

1. Qu'est-ce qu'une métrique / un critère ?

- Une métrique est **un nombre qui résume la qualité d'un résultat**.
- Elle sert à **comparer les modèles**, leurs réglages, et **prendre une décision**.
- Elle doit **correspondre exactement au besoin** : coûts, rareté du positif, usage final.

[Une métrique = un nombre qui mesure la qualité d'un résultat.]

Elle sert à comparer différents modèles ou réglages et à prendre la meilleure décision.

Elle doit être adaptée au besoin réel : par exemple tenir compte des coûts, de la rareté des cas positifs, et de l'usage final.

Exemple :

Si on détecte des fraudes rares : il vaut mieux utiliser le rappel plutôt que l'accuracy, pour ne pas rater les fraudes.]

2. Taxonomie des mesures

- **Supervisé vs Non supervisé**
- **Point (prédiction exacte) vs Classement (ranking)**
- **Avec seuil** (précision, rappel) vs **Sans seuil** (AUC, variance)
- **Interne** (basé seulement sur les données) vs **Externe** (avec labels de référence)
- **Calibration** (qualité des probabilités) vs **Discrimination** (capacité à bien séparer les classes)

[

1Supervisé vs Non supervisé

Supervisé :

- On connaît les **labels** (la réponse correcte pour chaque donnée).
- On peut mesurer directement la performance du modèle avec les labels.

Exemple :

- Dataset : prédire si un client achète ou pas (Oui/Non).
- Modèle prédit 90 bonnes réponses sur 100 → on peut calculer **Accuracy = 90%**.

Non supervisé :

- Pas de labels connus.
- On évalue la structure des données, la cohérence des groupes, etc.

Exemple :

- Dataset : regrouper des clients similaires sans savoir leurs classes.
- On peut utiliser **Silhouette = 0.75** → mesure la qualité du clustering.

2. Point (prédiction exacte) vs Classement (ranking)

Point :

- On regarde si chaque prédiction est **exacte ou fausse**.

Exemple :

- Prédiction : “oui” ou “non” pour chaque client.
- Métrique : **Accuracy = nombre de bonnes prédictions / total**.

Classement (ranking) :

- On regarde **l'ordre ou priorité** des prédictions.

Exemple :

- Prédire la probabilité qu'un client achète.
- On classe les clients du plus probable au moins probable.
- Métrique : **AUC = capacité du modèle à bien classer les positifs avant les négatifs**.

3. Avec seuil vs Sans seuil

Avec seuil :

- On transforme une **probabilité en décision**.
- Ex : si $\text{proba} > 0.5$ → positif, sinon négatif.

Exemple :

- Probabilité d'achat = 0.7 → seuil 0.5 → positif.
- Métriques : **Précision, Rappel, F1.**

Sans seuil :

- Pas besoin de transformer en décision, on évalue directement les probabilités.

Exemple :

- ROC-AUC = 0.85 → le modèle classe bien les clients sans fixer de seuil.

4. Interne vs Externe

Interne :

- Basé uniquement sur les **données**, pas besoin de labels.

Exemple :

- Silhouette pour clustering = 0.75 → mesure interne de la qualité des groupes.

Externe :

- Compare les résultats à des **labels connus**.

Exemple :

- ARI (Adjusted Rand Index) = 0.8 → le clustering correspond bien aux labels connus.

5. Calibration vs Discrimination

Calibration :

- Mesure si les **probabilités prédites** correspondent à la réalité.

Exemple :

- Modèle prédit proba = 0.8 pour achat → dans la réalité, 80% de ces clients achètent → bonne calibration.

Discrimination :

- Capacité à **bien séparer les classes positives et négatives.**

Exemple :

- ROC-AUC = 0.9 → modèle sépare très bien les acheteurs des non-acheteurs.

Résumé très clair + simple :

Type	Quoi	Exemple
Supervisé	Labels connus	Accuracy sur achat client
Non supervisé	Pas de labels	Silhouette pour clustering
Point	Prédiction exacte	Accuracy, F1
Classement	Ordre des probabilités	ROC-AUC
Avec seuil	Proba → décision	Seuil 0.5 → positif/négatif
Sans seuil	Évalue proba directement	ROC-AUC
Interne	Données seules	Silhouette
Externe	Labels de référence	ARI
Calibration	Probabilités fiables	Proba 0.8 → 80% achat
Discrimination	Séparer classes	ROC-AUC = 0.9

I

3. Supervisé

a) Classification

Métriques possibles :

- Exactitude (Accuracy)
- Précision
- Rappel
- F1
- ROC-AUC
- PR-AUC
- Calibration

b) Régression

- MAE

- RMSE / MSE
- R^2
- MAPE (à utiliser avec prudence en présence de zéros)

[

a) Classification

Métriques possibles :

1. Exactitude (Accuracy)

- % de bonnes prédictions par rapport au total.
Exemple : 90 bonnes prédictions sur 100 $\rightarrow$ Accuracy = 90%.

2. Précision (Precision)

- Parmi les prédictions positives, combien sont réellement positives.
Exemple : Modèle prédit 20 positifs, 18 sont corrects $\rightarrow$ Précision = $18/20 = 90\%$.

3. Rappel (Recall)

- Parmi les vrais positifs, combien le modèle a correctement détectés.
Exemple : 25 vrais positifs, le modèle en détecte 20 $\rightarrow$ Rappel = $20/25 = 80\%$.

4. F1-score

- Moyenne harmonique entre précision et rappel $\rightarrow$ équilibre précision/rappel.
Exemple : Precision = 90%, Recall = 80% $\rightarrow$ F1 $\approx$ 84%.

5. ROC-AUC

- Mesure la capacité à **séparer correctement classes positives et négatives**.
Exemple : AUC = 0.9 $\rightarrow$ modèle très performant pour discriminer les classes.

6. PR-AUC

- Similaire à ROC-AUC mais adapté aux **classes déséquilibrées**.
Exemple : Détection de fraude rare.

7. Calibration

- Vérifie si les **probabilités prédites** sont fiables.
Exemple : Proba = 0.8 $\rightarrow$ dans la réalité, 80% des cas positifs se produisent $\rightarrow$ bonne calibration.

Résumé Classification :

- Accuracy = global
- Précision = exactitude sur les positifs
- Rappel = couverture des vrais positifs
- F1 = équilibre précision/rappel
- ROC-AUC / PR-AUC = discrimination globale
- Calibration = fiabilité des probabilités ✓

b) Régression

Métriques possibles :

1. MAE (Mean Absolute Error)

- Erreur moyenne absolue entre prédictions et vrais valeurs.
Exemple : vrai = 10, prédit = 8 → erreur = 2.

2. RMSE / MSE (Root Mean Squared Error / Mean Squared Error)

- Moyenne des carrés des erreurs → pénalise plus les grandes erreurs.
Exemple : erreurs = 2, 3 → $MSE = (4+9)/2 = 6$ → $RMSE \approx 2.45$

3. R^2 (coefficient de détermination)

- Indique la proportion de variance expliquée par le modèle.
Exemple : $R^2 = 0.85$ → modèle explique 85% de la variance.

4. MAPE (Mean Absolute Percentage Error)

- Erreur moyenne en % → à utiliser **prudemment si certaines valeurs réelles = 0**.
Exemple : vrai = 100, prédit = 90 → erreur = 10%

Résumé Régression :

- MAE = erreur moyenne simple
- RMSE / MSE = pénalise grandes erreurs
- R^2 = qualité d'explication du modèle
- MAPE = erreur en % (attention aux zéros) ✓

4. Non supervisé

a) Clustering

- **Internes** : Silhouette, Davies-Bouldin
- **Externes** (si labels disponibles) : ARI, NMI

b) Réduction de dimension (ex. PCA)

- Pourcentage de variance expliquée
- Erreur de reconstruction

c) Détection d'anomalies

- Si quelques labels → PR-AUC / Recall@k
- Sinon → stabilité, validation métier

d) Règles d'association

- Support
- Confiance
- Lift
- (Conviction, Leverage)

[

4. Non Supervisé – Explication simple + résumé

a) Clustering

- **But** : regrouper des données similaires sans utiliser les labels (ou avec si disponibles).

Métriques :

1. **Internes** : mesurent la qualité des groupes **sans labels**.

- **Silhouette** : mesure si chaque point est proche de son groupe et loin des autres → valeur entre -1 et 1.
Exemple : Silhouette = 0.7 → bon clustering.
- **Davies-Bouldin** : plus petit = meilleur regroupement.
Exemple : DB = 0.3 → bon clustering.
- 2. **Externes** : comparent les clusters aux **labels réels** si disponibles.
 - **ARI (Adjusted Rand Index)**, **NMI (Normalized Mutual Information)** → valeurs proches de 1 = clustering très proche des labels.

b) Réduction de dimension (ex. PCA)

- **But** : réduire le nombre de variables tout en gardant le maximum d'information.

Métriques :

- **Pourcentage de variance expliquée** : combien de l'information originale est conservée.
Exemple : PCA → 2 composantes expliquent 90% de la variance → bonne réduction.
- **Erreur de reconstruction** : différence entre données originales et reconstruites.
Exemple : erreur faible = bonne représentation.

c) Détection d'anomalies

- **But** : détecter des points « anormaux » ou rares.

Métriques :

1. **Si quelques labels sont disponibles** :
 - **PR-AUC, Recall@k** → mesurer la capacité à détecter les vrais anomalies.
Exemple : Recall@10 = 8/10 → 8 anomalies détectées parmi 10.
2. **Sinon (pas de labels)** :
 - **Stabilité** : vérifier si les anomalies détectées sont cohérentes avec le domaine.
 - **Validation métier** : vérifier si les anomalies ont un sens pratique.

d) Règles d'association

- **But** : trouver des relations fréquentes entre items.

Métriques :

- **Support** : fréquence de l'itemset.
Exemple : 100 clients, 30 achètent pain + lait → support = 30%.
- **Confiance** : probabilité qu'un item apparaisse si un autre est présent.
Exemple : Si pain acheté → 80% chance que lait soit acheté.
- **Lift** : mesure la force de l'association par rapport au hasard.
Exemple : Lift = 1.5 → association plus forte que hasard.
- **Conviction / Leverage** : autres mesures pour confirmer la fiabilité de la règle.

Résumé très clair Non Supervisé :

Type	Métriques	Exemple simple
Clustering interne	Silhouette, Davies-Bouldin	Silhouette = 0.7 → bon regroupement
Clustering externe	ARI, NMI	ARI = 0.85 → proche des labels
Réduction de dimension	% variance expliquée, Erreur reconstruction	2 composantes = 90% variance
Anomalies avec labels	PR-AUC, Recall@k	Recall@10 = 8/10 anomalies détectées
Anomalies sans labels	Stabilité, Validation métier	Vérifier cohérence avec domaine
Règles d'association	Support, Confiance, Lift, Conviction, Leverage	Pain → lait, support=30%, confiance=80%, lift=1.5

]

5. Métriques de classification et seuil (Threshold)

- Le seuil transforme **une probabilité en décision** (ex. proba > 0.5 → positif).
- On doit **toujours** choisir un seuil opérationnel.
- On fixe le seuil selon les **coûts d'erreur** (ex. imposer un rappel $\geq 95\%$), puis on cherche à **maximiser la précision**.
- **Erreur fréquente** : garder le seuil par défaut 0.5 sans analyser le contexte.

1. QU'EST-CE QU'UNE MÉTRIQUE / UN CRITÈRE ?

Q1 : Une métrique, c'est quoi ?

A) Un modèle de données

B) Un nombre qui résume la qualité du résultat ✓

- C) Un algorithme de classification
- D) Un graphique des résultats

Réponse : B

Détail : Une métrique résume la **qualité d'un résultat** et sert à **comparer modèles/réglages**.

Q2 : À quoi sert une métrique ?

- A) Comparer des modèles et réglages, et prendre des décisions ✓
- B) Créer de nouvelles données
- C) Réduire la variance seulement
- D) Stocker les résultats bruts

Réponse : A

Détail : Permet de **décider quel modèle ou réglage est le meilleur**.

Q3 : Pourquoi une métrique doit-elle coller au besoin ?

- A) Pour s'adapter aux coûts, à la rareté, et à l'usage final ✓
- B) Pour être toujours ≥ 0
- C) Pour remplacer les labels
- D) Pour simplifier le code

Réponse : A

Détail : Une métrique utile doit **refléter les contraintes réelles du problème**.

2. TAXONOMIE DES MESURES

Q4 : Supervisé vs Non supervisé

- A) Supervisé = avec labels, Non supervisé = sans labels ✓
- B) Supervisé = pas d'algorithmes, Non supervisé = algorithmes
- C) Supervisé = toujours classification, Non supervisé = toujours régression
- D) Supervisé = PCA, Non supervisé = ROC

Réponse : A

Détail :

- **Supervisé :** labels disponibles → métriques comparées aux labels.
 - **Non supervisé :** pas de labels → métriques internes ou validation métier.
-

Q5 : Point (prédiction exacte) vs Classement (ranking)

- A) Point = ordonner les modèles
- B) Point = prédiction exacte ✓, Ranking = ordonner les résultats
- C) Les deux sont identiques
- D) Ranking = pour régression uniquement

Réponse : B

Détail :

- **Point** : métriques pour chaque instance (ex. Accuracy).
 - **Ranking** : métriques pour ordonner les résultats (ex. AUC).
-

Q6 : Avec seuil vs Sans seuil

- A) Avec seuil = précision/rappel ✓
- B) Sans seuil = AUC, variance ✓
- C) Seuil = optionnel et jamais utilisé
- D) A et B ✓

Réponse : D

Détail :

- Le **seuil transforme la probabilité en décision**.
 - Sans seuil, on utilise des métriques comme **AUC**.
-

Q7 : Interne vs Externe

- A) Interne = basé sur labels
- B) Externe = basé sur les données seules
- C) Interne = basé sur données seules ✓, Externe = labels référence ✓
- D) Les deux ne concernent pas les métriques

Réponse : C

Détail :

- **Interne** : évalue la structure des données seule.
 - **Externe** : nécessite des labels de référence.
-

Q8 : Calibration vs Discrimination

- A) Calibration = séparer les classes
- B) Discrimination = qualité des probabilités

- C) Calibration = qualité des probabilités ✓, Discrimination = séparer bien ✓
D) Aucune des deux

Réponse : C

Détail :

- **Calibration** : probabilités reflètent la réalité.
 - **Discrimination** : capacité à distinguer classes positives et négatives.
-

3. SUPERVISÉ

Classification

Q9 : Quelles métriques utiliser pour la classification ?

- A) Exactitude (Accuracy) ✓
B) Précision / Rappel / F1 ✓
C) ROC-AUC / PR-AUC / Calibration ✓
D) Toutes les réponses ci-dessus ✓

Réponse : D

Régression

Q10 : Quelles métriques pour la régression ?

- A) MAE ✓
B) RMSE / MSE ✓
C) R^2 / MAPE (prudence si zéros) ✓
D) Toutes les réponses ci-dessus ✓

Réponse : D

4. NON SUPERVISÉ

Clustering

Q11 : Critères internes ?

- A) Silhouette ✓

- B) Davies-Bouldin ✓
- C) ARI / NMI
- D) A et B ✓

Réponse : D

Q12 : Critères externes ?

- A) ARI ✓
- B) NMI ✓
- C) Silhouette
- D) Davies-Bouldin

Réponse : A + B

Réduction de dimension (PCA, etc.)

Q13 : Comment mesurer ?

- A) % variance expliquée ✓
- B) Reconstruction ✓
- C) PR-AUC
- D) Lift

Réponse : A + B

Anomalies

Q14 : Avec quelques labels ?

- A) PR-AUC ✓
- B) Recall@k ✓
- C) Stabilité
- D) Validation métier

Réponse : A + B

Q15 : Sans labels ?

- A) Stabilité ✓
- B) Validation métier ✓
- C) PR-AUC
- D) Recall@k

Réponse : A + B

Règles d'association

Q16 : Quelles métriques ?

- A) Support ✓
- B) Confiance ✓
- C) Lift ✓
- D) Conviction / Leverage ✓

Réponse : A + B + C + D

5. MÉTRIQUES DE CLASSIFICATION : SEUIL (Threshold)

Q17 : Qu'est-ce qu'un seuil ?

- A) Probabilité → décision (ex. > 0.5 = positif) ✓
- B) Optionnel
- C) Toujours 0.5
- D) Aucune des réponses

Réponse : A

Q18 : Comment fixer le seuil ?

- A) Selon les coûts (ex. $\text{rappel} \geq 95\%$) ✓
- B) Puis maximiser la précision ✓
- C) Garder 0.5 par défaut
- D) A et B ✓

Réponse : D

Q19 : Piège à éviter

- A) Garder 0.5 sans réfléchir au coût d'erreur ✓
- B) Ajuster selon coût
- C) Toujours utiliser ROC
- D) Ignorer précision

Réponse : A

Résumé Métriques

1 Métriques de Classification

Accuracy (Exactitude)

- **Quoi** : % de prédictions correctes.

Quand : classes équilibrées, coûts d'erreur symétriques. [Quand les **classes sont équilibrées** (à peu près même nombre de positifs et négatifs).]

- Quand les **coûts d'erreurs sont symétriques** (erreur positive = erreur négative).]

- **Lire & agir** : viser > baseline majoritaire, comparer modèles.
- **Piège** : trompeur si la classe positive est rare.

Précision (Precision)

- **Quoi** : parmi tout ce que le modèle a prédit positif, quelle part est vraiment positive.
- **Quand** : faux positifs coûteux (alerte chère).
- **Lire & agir** : si faible → augmenter le seuil.
- **Piège** : peut augmenter en sacrifiant trop le rappel.

Rappel (Recall)

- **Quoi** : parmi tous les vrais positifs, combien sont détectés.
- **Quand** : faux négatifs coûteux (santé, fraude). [Quand les **faux négatifs sont coûteux ou dangereux**.
Exemple : santé → ne pas détecter un malade = risque grave, fraude → manquer une transaction frauduleuse]
- **Lire & agir** : si faible → baisser le seuil. [Si le rappel est faible → **baisser le seuil** pour détecter plus de positifs.]
- Toujours comparer avec la précision pour équilibrer les alertes.]
- **Piège** : rappel très haut + précision très basse = trop d'alarmes. [Rappel très haut + précision très basse → trop de fausses alertes.
Exemple : détecter tous les malades mais signaler aussi beaucoup de personnes saines → surcharge du système de soins.]

F1-score

- **Quoi** : compromis précision/rappel.

Quand : classe positive rare + besoin d'un score unique.[**Quand la classe positive est rare.**

• **Quand on a besoin d'un seul score pour comparer les modèles**]

- **Lire & agir** : comparer F1 entre modèles/paramètres.[**Comparer le F1-score entre différents modèles ou paramètres pour choisir le meilleur**]
- **Piège** : dépend du seuil, ignore vrais négatifs, ne dit rien sur calibration.

ROC-AUC

Quoi : qualité de classement global (0.5 = hasard, 1 = parfait).[**ROC-AUC mesure comment le modèle classe les positifs avant les négatifs.**

- **1.0 = parfait**
- **0.5 = au hasard** (comme tirer une pièce)
-]
- **Quand** : classes équilibrées.[**Quand les classes sont équilibrées** (même nombre de positifs et négatifs).]
- **Lire & agir** : plus haut = meilleur tri des positifs avant négatifs.[**Score plus haut = meilleur tri :**
Le modèle met **les vrais positifs en haut et les négatifs en bas.**]

Piège : peut être bon alors que PR-AUC faible si classe rare.[**ROC-AUC peut être trompeur quand :**

- **la classe positive est très rare** (maladies rares, fraudes, etc.)
-]

PR-AUC

- **Quoi** : aire précision-rappel; baseline $\approx$ prévalence classe positive.[**PR-AUC = aire sous la courbe Précision-Rappel.**
C'est la **qualité du modèle sur la classe positive rare.**]
- **Quand** : positif rare (fraude, défaut).
- **Lire & agir** : doit dépasser nettement la baseline.[Le PR-AUC doit être **nettement au-dessus de la baseline.**]

Piège : sensible au rapport de classes; annoncer prévalence.[• i la classe positive devient plus rare $\rightarrow$ PR-AUC baisse même si modèle جيد

- لذلك **il faut toujours annoncer la prévalence** avec le score.

-]

2 Métriques de Régression

MAE

- **Quoi** : erreur moyenne en unités réelles.
- **Quand** : lisibilité métier.
- **Lire & agir** : plus bas = mieux, comparer au baseline.
- **Piège** : moins sensible aux grosses erreurs que RMSE.

RMSE / MSE [MSE : **moyenne des** erreurs au carré.][**racine carrée du MSE.**]

- **Quoi** : erreur quadratique, pénalise grosses erreurs.[]
- **Quand** : grosses erreurs coûteuses.
- **Lire & agir** : plus bas = mieux, comparer au baseline.
- **Piège** : RMSE plus lisible que MSE (unités).

R²

- **Quoi** : part de variance expliquée (peut être négative).
- **Quand** : vision rapide "% d'explication".
- **Lire & agir** : se rapprocher de 1, comparer au R² baseline.
- **Piège** : attention features non linéaires → R² trompeur si modèle mal spécifié.

MAPE (prudence)

- **Quoi** : % d'erreur moyen.[**MAPE mesure le pourcentage d'erreur moyen entre les prédictions et les vraies valeurs.**]
- **Quand** : besoin métier en %, pas de zéros.
- **Lire & agir** : plus bas = mieux.
- **Piège** : instable si valeurs proches de 0.

3 Métriques de Clustering internes

Silhouette Score

- **Quoi** : points proches de leur cluster et loin des autres.[**Mesure si les points sont bien regroupés dans leur cluster et bien séparés des autres clusters.**]

Quand : K-means / agglomératif, choisir k.[• Pour évaluer K-means ou clustering agglomératif.

• Utile pour **choisir le bon nombre de clusters (k)**.

-]
- **Lire & agir** : plus haut = clusters plus nets; tester plusieurs k.
- **Piège** : dépend de l'échelle et de la distance.

Davies-Bouldin Index

- **Quoi** : compacité/séparation des groupes (plus bas = mieux).
- **Quand** : complément à Silhouette.
- **Lire & agir** : comparer modèles/k; viser le plus bas.
- **Piège** : sensible aux outliers.

Inertie & “Elbow” (K-means)

- **Quoi** : somme des distances intra-cluster.
- **Quand** : aide à choisir k (repérer le coude).
- **Lire & agir** : choisir k au changement de pente.
- **Piège** : dépend du scaling, outliers, forme des clusters (K-means aime groupes ronds).

QCM Métriques – Data Mining

1 ☐ Qu'est-ce que l'Accuracy ?

- A) % de vrais positifs détectés parmi tous les cas positifs
- B) % de prédictions correctes sur l'ensemble des données
- C) Compromis entre précision et rappel
- D) Aire précision-rappel

✓ **Réponse : B**

2 ☐ Quand utilise-t-on la Précision (Precision) ?

- A) Quand les faux négatifs sont coûteux
- B) Quand les faux positifs sont coûteux
- C) Pour mesurer la variance expliquée
- D) Pour la réduction de dimension

✓ Réponse : B

3 ☐ Que mesure le Rappel (Recall) ?

- A) La proportion de vrais positifs détectés parmi tous les vrais positifs
- B) La proportion de prédictions correctes totales
- C) La qualité de classement global
- D) L'erreur moyenne des prédictions

✓ Réponse : A

4 ☐ Le F1-score sert à :

- A) Combiner précision et rappel en un seul score
- B) Mesurer la variance expliquée
- C) Évaluer la distance intra-cluster
- D) Mesurer la fiabilité des probabilités

✓ Réponse : A

5 ☐ Que représente ROC-AUC ?

- A) % de prédictions correctes
- B) Qualité du classement global (0.5 = hasard, 1 = parfait)
- C) Erreur moyenne absolue
- D) Compacité/séparation des clusters

✓ Réponse : B

6 ☐ Que mesure PR-AUC ?

- A) La proportion de variance expliquée
- B) Aire précision-rappel, utile si classe positive rare
- C) % de prédictions correctes
- D) Distance intra-cluster

✓ Réponse : B

7 ☐ Dans la régression, MAE mesure :

- A) Erreur moyenne absolue
- B) Erreur quadratique
- C) Part de variance expliquée
- D) % d'erreur moyen

✓ Réponse : A

8 ☐ RMSE est utile quand :

- A) Les grosses erreurs sont très coûteuses
- B) Les erreurs sont toutes petites
- C) On veut un compromis précision/rappel
- D) Pour mesurer la compacité des clusters

✓ Réponse : A

9 ☐ Que mesure R^2 ?

- A) % de prédictions correctes
- B) Part de variance expliquée par le modèle
- C) Erreur quadratique moyenne
- D) Aire précision-rappel

✓ Réponse : B

10 ☐ Quand utilise-t-on MAPE avec prudence ?

- A) Quand la classe positive est rare
- B) Quand certaines valeurs réelles = 0
- C) Pour choisir le nombre de clusters
- D) Pour mesurer l'erreur intra-cluster

✓ Réponse : B

11  Silhouette Score sert à :

- A) Vérifier si les points sont proches de leur cluster et éloignés des autres
- B) Mesurer la précision d'un modèle supervisé
- C) Calculer l'erreur quadratique
- D) Évaluer le % de variance expliquée

✓ Réponse : A

12  Davies-Bouldin Index indique :

- A) La compacité et séparation des clusters (plus bas = mieux)
- B) Le % de prédictions correctes
- C) Le compromis précision/rappel
- D) L'aire précision-rappel

✓ Réponse : A

13  Inertie & “Elbow” (K-means) servent à :

- A) Choisir le nombre optimal de clusters
- B) Évaluer la précision d'un modèle supervisé
- C) Mesurer la part de variance expliquée
- D) Calculer le F1-score

✓ Réponse : A

Résumé clair – Problème & Métrique

1 Clustering externe

- **ARI / NMI** : accord avec vrais groupes (plus haut = mieux).
 - **Quand** : si on a des labels externes (rare).
 - **Lire & agir** : comparer algos / k.
 - **Piège** : ne pas confondre avec objectif prédictif.
-

2 Réduction de dimension

- **% variance expliquée (PCA)** : info conservée par les composantes.
 - **Quand** : compresser features, visualisation, prétraitement.
 - **Lire & agir** : viser 90-95% avec peu de dimensions.
 - **Piège** : PCA capte variance, pas forcément structure utile.
 - **Erreur de reconstruction (autoencodeurs)** : perte d'info après compression (plus bas = mieux).
 - **Quand** : réduction non linéaire, débruitage.
 - **Lire & agir** : ajuster bottleneck vs erreur.
 - **Piège** : sur-apprentissage si réseau trop puissant.
-

3 Détection d'anomalies

- **Recall@k** : parmi top-k, combien de vraies anomalies.
 - **Quand** : capacité humaine limitée (ex. top 50/jour).
 - **Lire & agir** : choisir k selon capacité.
 - **Piège** : comparer modèles au même k.
 - **PR-AUC (quelques labels)** : qualité sur classe rare pour tous seuils.
 - **Quand** : petit dataset annoté.
 - **Lire & agir** : dépasser baseline (prévalence).
 - **Piège** : comparaisons injustes si prévalence différente.
 - **Contamination** : taux attendu d'anomalies → règle seuil.
 - **Quand** : Isolation Forest, One-Class SVM.
 - **Lire & agir** : ajuster selon retour terrain.
 - **Piège** : trop de faux positifs ou négatifs si mal fixé.
 - **Stabilité (bootstrap)** : cohérence des anomalies après ré-échantillonnage.
 - **Quand** : sans labels.
 - **Lire & agir** : si instable → revoir features/scaling/modèle.
 - **Piège** : certaines anomalies stables peuvent être triviales.
-

4 ☐ Règles d'association

- **Support** : fréquence $X \Rightarrow Y$.
 - **Quand** : filtrer règles trop rares.
 - **Lire & agir** : fixer min_support ($>1\%$).
 - **Piège** : support élevé mais peu utile si Y omniprésent.
 - **Confiance** : $P(Y|X)$ fiabilité règle.
 - **Quand** : crédibilité opérationnelle.
 - **Lire & agir** : fixer min_confiance ($\geq 50\%$).
 - **Piège** : peut être élevé si Y très fréquent.
 - **Lift** : intérêt vs hasard (>1 = utile).
 - **Quand** : prioriser règles informatives.
 - **Lire & agir** : trier par support $\times$ lift.
 - **Piège** : lift élevé mais support minuscule = pas actionnable.
-

5 ☐ Recommandations pratiques

- **Positif rare** → PR-AUC + F1, ajuster seuil selon coût.
 - Régression → RMSE; sinon MAE pour métier.
 - Clustering → Silhouette + regard métier; Elbow pour k.
 - PCA → viser 90-95% variance, minimum de dimensions.
 - Anomalies → Recall@k top-k, ajuster contamination.
 - Association → Support / Confiance + Lift >1 , éviter règles rares.
-

6 ☐ Baseline

- **But** : transformer besoin métier en tâche ML mesurable.
 - Sorties attendues : tâche/objectif, cible, métrique principale, baseline à battre.
 - **C'est quoi ?**
 - Référence minimale : trivial (règle simple) et strong (petit modèle par défaut).
 - Permet de **mesurer progrès réel** vs modèle trivial et vs point de départ réaliste.
 - **Pourquoi indispensable ?**
 - Barre minimale : “Mon modèle $>$ trivial ?”
 - Barre réaliste : “Mon modèle bat déjà un modèle par défaut ?”
 - Sanity check : valider métrique + protocole.
 - **Quand ?**
 - Étape 1 : définir baselines sans mesurer.
 - Après EDA → Split → Prépa → mesurer sur Train/Val/CV avant algos avancés.
-

7 ☐ Choix des baselines

- **Triviale** : modèle le plus simple possible selon tâche.
 - Classification → prédire classe majoritaire
 - Régression → prédire moyenne/médiane
 - Clustering → un seul cluster
 - Réduction dimension → garder premières colonnes
 - Anomalies → prédire tout normal
 - Règles → aléatoires ou aucune
 - **Strong** : petit modèle standard selon tâche, vérifier métriques.
 - Classification → Régression logistique, RandomForest → Accuracy, F1, AUC
 - Régression → Linéaire / RandomForest → RMSE, MAE, R^2
 - Clustering → K-Means, DBSCAN → Silhouette, Calinski-Harabasz
 - Réduction dimension → PCA, t-SNE → Variance expliquée, Reconstruction error
 - Anomalies → Isolation Forest, One-Class SVM → Precision, Recall, ROC-AUC
 - Association → Apriori, FP-Growth → Support, Confiance, Lift
-
-

QCM – Problème & Métrique

1 Qu'est-ce qu'une métrique / un critère ?

Question 1 : Une métrique sert à :

- A) Résumer la qualité d'un résultat ✓
- B) Augmenter la taille des données
- C) Changer le type de modèle
- D) Supprimer les valeurs aberrantes

Réponse : A

Question 2 : Une métrique doit :

- A) Être choisie au hasard
- B) Corresponder exactement au besoin (coûts, rareté, usage final) ✓
- C) Être toujours Accuracy
- D) Ignorer les contraintes métier

Réponse : B

2 Taxonomie des mesures

Question 3 : Quelle différence entre supervisé et non supervisé ?

- A) Supervisé utilise labels ✓

- B) Non supervisé utilise labels
- C) Supervisé ne nécessite pas de données
- D) Non supervisé est toujours meilleur

Réponse : A

Question 4 : Qu'est-ce que la calibration ?

- A) Séparer bien les classes
- B) Qualité des probabilités ✓
- C) Réduire le nombre de features
- D) Détecter des anomalies

Réponse : B

3 Métriques de classification

Question 5 : Accuracy est trompeuse si :

- A) Classes équilibrées
- B) Classe positive rare ✓
- C) Coût des erreurs symétrique
- D) Baseline majoritaire élevée

Réponse : B

Question 6 : Quand utiliser la précision ?

- A) Faux négatifs coûteux
- B) Faux positifs coûteux ✓
- C) Classe positive rare
- D) Régression

Réponse : B

Question 7 : Recall est utile quand :

- A) Faux positifs coûteux
- B) Classe équilibrée
- C) Faux négatifs coûteux ✓
- D) On ne veut qu'un seul score

Réponse : C

Question 8 : F1-score combine :

- A) Précision et Rappel ✓
- B) Accuracy et Precision

- C) Rappel et MSE
- D) PR-AUC et ROC-AUC

Réponse : A

Question 9 : ROC-AUC est utile quand :

- A) Classe positive rare
- B) **Classes équilibrées ✓**
- C) On a peu de données
- D) Pour règles d'association

Réponse : B

Question 10 : PR-AUC est utile pour :

- A) Classe équilibrée
- B) **Classe positive rare ✓**
- C) Régression
- D) Clustering

Réponse : B

4 Métriques de régression

Question 11 : MAE indique :

- A) Part de variance expliquée
- B) **Erreur moyenne en unités réelles ✓**
- C) Erreur quadratique
- D) PR-AUC

Réponse : B

Question 12 : RMSE est utile quand :

- A) Petites erreurs tolérées
- B) **Grosses erreurs très coûteuses ✓**
- C) Classe positive rare
- D) Clustering

Réponse : B

Question 13 : R^2 montre :

- A) **% de variance expliquée ✓**
- B) Précision du modèle

- C) F1-score
- D) PR-AUC

Réponse : A

Question 14 : MAPE est instable si :

- A) Valeurs négatives
- B) Valeurs proches de 0 ✓
- C) Classe rare
- D) Gros dataset

Réponse : B

5 Clustering interne

Question 15 : Silhouette Score mesure :

- A) Compacité et séparation des clusters ✓
- B) Variance expliquée
- C) PR-AUC
- D) F1-score

Réponse : A

Question 16 : Davies-Bouldin Index :

- A) Plus bas = clusters plus nets ✓
- B) Plus haut = clusters meilleurs
- C) Valeur unique = clusters parfaits
- D) Utile pour régression

Réponse : A

6 Détection d'anomalies

Question 17 : Recall@k est utilisé pour :

- A) Mesurer toutes les anomalies
- B) Top-k anomalies détectées ✓
- C) Réduction de dimension
- D) Baseline strong

Réponse : B

Question 18 : PR-AUC pour anomalies :

- A) Quand beaucoup de labels
- B) Quand quelques labels ✓
- C) Sans labels
- D) Toujours inutile

Réponse : B

Question 19 : Contamination sert à :

- A) Ajuster le taux attendu d'anomalies ✓
- B) Mesurer F1-score
- C) Réduire dimension
- D) Calculer Accuracy

Réponse : A

7 Règles d'association

Question 20 : Support indique :

- A) $P(Y|X)$
- B) Fréquence de la règle ✓
- C) Lift
- D) PR-AUC

Réponse : B

Question 21 : Confiance indique :

- A) Fréquence de la règle
- B) Fiabilité de la règle $P(Y|X)$ ✓
- C) Lift
- D) $\text{Recall}@k$

Réponse : B

Question 22 : Lift >1 signifie :

- A) Règle inutile
- B) Règle utile ✓
- C) Classe rare
- D) Baseline strong

Réponse : B

8 Baselines

Question 23 : Baseline triviale classification :

- A) Random
- B) Toujours classe majoritaire ✓
- C) RandomForest
- D) PCA

Réponse : B

Question 24 : Strong baseline classification :

- A) Régression logistique ou RandomForest ✓
- B) Toujours moyenne
- C) Isolation Forest
- D) Silhouette Score

Réponse : A

Question 25 : Strong baseline régression :

- A) RMSE, MAE, R^2 ✓
- B) F1-score
- C) Recall@k
- D) Support

Réponse : A

Paetier 5

Comprendre les données – Résumé clair

But

Obtenir une vision **claire, fiable et synthétique** du dataset : structure, qualité, cible.

Sorties attendues

- Cartographier le dataset
- Contrôler la qualité des données
- Analyser la cible (y)
- Explorer les variables explicatives (features)
- Rédiger une synthèse EDA + plan d'action

1 ☐ Cartographier le dataset

- **Taille et structure** : nombre de lignes (observations), nombre de colonnes (variables)
 - **Aperçu des données** : premières lignes, noms des variables, cohérence et types
 - **Rôle des variables** : ID, features (explicatives), cible (y)
 - **Type de chaque variable** : numérique, catégorielle, booléenne, date/temps
-

2 ☐ Contrôler la qualité des données

- Vérifier **valeurs manquantes**
 - Détecter **doublons et incohérences**
 - Identifier **valeurs aberrantes (outliers)**
 - Objectif : produire un **diagnostic clair**
-

3 ☐ Analyser la cible (y)

- **Nature** :
 - Numérique → Régression
 - Binaire → Classification
 - Multi-classe → Classification multi-classes
 - **Distribution** : min, max, moyenne, médiane, quartiles, histogramme, boxplot
 - **Déséquilibre** : si certaines classes sont rares, un modèle trivial peut être trompeur (ex : 95% accuracy mais ignore la classe minoritaire)
-

4 ☐ Explorer les variables explicatives (features)

a) Analyse univariée

- **Numérique** : min, max, moyenne, médiane, quartiles, écart-type, histogramme, boxplot
 - Questions : variable concentrée ou dispersée ? outliers ?
- **Catégorielle** : liste des modalités et fréquence (tableau/barplot)
 - Questions : catégories ultra rares ? trop de catégories différentes ?

b) Lien features → cible

- **Features numériques**

- Cible numérique : scatter plot, corrélation → tendance ?
- Cible catégorielle : boxplots, moyenne par classe → différences entre classes ?
- **Features catégorielles**
 - Cible numérique : moyenne de y par catégorie, boxplots
 - Cible catégorielle : taux de classe positive par catégorie, tableau croisé, barplots empilés → certaines catégories plus importantes ?

c) Relations entre features

- **Numériques** : matrice de corrélation → identifier features redondantes
 - **Catégorielles** : regarder combinaisons fréquentes, repérer catégories rarement présentes ensemble
-
-

QCM 1 – But de l'EDA

Question : Quel est le principal objectif de l'Exploratory Data Analysis (EDA) ?

- A) Créer un modèle prédictif directement
- B) Obtenir une vision claire, fiable et synthétique du dataset
- C) Remplacer les données manquantes automatiquement
- D) Optimiser les hyperparamètres d'un modèle

Réponse : B) Obtenir une vision claire, fiable et synthétique du dataset

QCM 2 – Sorties attendues

Question : Parmi les éléments suivants, lequel fait partie des sorties attendues de l'EDA ?

- A) Cartographier le dataset
- B) Tester les algos avancés
- C) Appliquer PCA
- D) Entraîner un modèle complexe

Réponse : A) Cartographier le dataset

QCM 3 – Cartographie du dataset

Question : Que signifie "cartographier le dataset" ?

- A) Identifier taille, structure, rôle et type de chaque variable
- B) Normaliser toutes les variables

- C) Supprimer les outliers
- D) Créer un graphique pour chaque variable

Réponse : A) Identifier taille, structure, rôle et type de chaque variable

QCM 4 – Contrôle qualité

Question : Quelles actions font partie du contrôle qualité des données ?

- A) Vérifier les valeurs manquantes, doublons et outliers
- B) Calculer la corrélation entre features
- C) Appliquer un modèle prédictif
- D) Réaliser un PCA

Réponse : A) Vérifier les valeurs manquantes, doublons et outliers

QCM 5 – Analyse de la cible (y)

Question : Si la cible est binaire et déséquilibrée, que peut-il se passer avec un modèle trivial ?

- A) Il détecte toutes les classes
- B) Il peut avoir une accuracy élevée mais ignorer la classe minoritaire
- C) Il prédit parfaitement toutes les classes
- D) Il ne peut pas être évalué

Réponse : B) Il peut avoir une accuracy élevée mais ignorer la classe minoritaire

QCM 6 – Nature de la cible

Question : Une cible numérique correspond à quel type de problème ?

- A) Classification
- B) Régression
- C) Clustering
- D) Association

Réponse : B) Régression

QCM 7 – Analyse univariée des features

Question : Pour une feature numérique, que peut-on analyser en EDA ?

- A) Min, max, moyenne, médiane, quartiles, écart-type, histogramme, boxplot
- B) Taux de churn par catégorie
- C) Tableau croisé
- D) Appliquer Isolation Forest

Réponse : A) Min, max, moyenne, médiane, quartiles, écart-type, histogramme, boxplot

QCM 8 – Features catégorielles

Question : Quelle question pose-t-on lors de l'analyse d'une feature catégorielle ?

- A) La variable est-elle concentrée ou dispersée ?
- B) Y a-t-il des catégories ultra rares ?
- C) Quel est l'écart-type ?
- D) Quelle est la variance expliquée par PCA ?

Réponse : B) Y a-t-il des catégories ultra rares ?

QCM 9 – Lien features numériques → cible catégorielle

Question : Quel outil est utilisé pour explorer une feature numérique par rapport à une cible catégorielle ?

- A) Scatter plot
- B) Boxplots par classe et moyenne par classe
- C) Matrice de corrélation
- D) Histogramme uniquement

Réponse : B) Boxplots par classe et moyenne par classe

QCM 10 – Relations entre features numériques

Question : Quelle méthode permet de repérer les features redondantes ?

- A) Scatter plot
- B) Histogramme
- C) Matrice de corrélation
- D) Boxplot

Réponse : C) Matrice de corrélation

QCM 11 – Relations entre features catégorielles

Question : Que peut-on faire pour explorer les relations entre features catégorielles ?

A) Observer combinaisons fréquentes et catégories rarement présentes ensemble

B) Faire un scatter plot

C) Calculer min et max

D) Appliquer un PCA

Réponse : A) Observer combinaisons fréquentes et catégories rarement présentes ensemble

Résumé clair – Synthèse EDA

But : Résumer en quelques phrases ce qu'on a appris du dataset pendant l'EDA.

À inclure :

1. **Dataset & structure :** taille, lignes/colonnes, types de variables
2. **Qualité des données :** valeurs manquantes, doublons, outliers, incohérences
3. **Cible (y) :** nature, distribution, déséquilibre éventuel
4. **Features (variables explicatives) :** principales tendances, variables importantes, relations avec la cible
5. **Points forts / points faibles :** aspects positifs et limites du dataset

Principe : Expliquer avec tes mots la forme du dataset et les informations importantes pour guider l'analyse.

Résumé clair – Plan d'action

But : Transformer les constats de l'EDA en décisions concrètes pour la préparation et modélisation.

À préciser :

1. **Colonnes :** supprimer / garder / transformer
2. **Qualité des données :** stratégie pour valeurs manquantes, outliers, doublons/incohérences
3. **Cible (y) :** ajustements ou transformations éventuelles
4. **Features engineering :** idées pour créer ou transformer des variables
5. **Objectif :** guider les prochaines étapes (préparation + modélisation)

QCM Synthèse EDA + Plan d'action

Q1 – But de la synthèse EDA

Quel est l'objectif principal ?

- A) Résumer le dataset et guider les actions futures
- B) Créer un modèle directement
- C) Calculer uniquement les corrélations
- D) Faire des visualisations sans interprétation

Réponse : A

Q2 – Contenu de la synthèse EDA

Parmi les éléments suivants, lequel ne fait pas partie de la synthèse EDA ?

- A) Qualité des données
- B) Distribution de la cible
- C) Résultats de modélisation
- D) Relations features → cible

Réponse : C

Q3 – Plan d'action

Que doit inclure le plan d'action ?

- A) Décisions concrètes pour préparer les données et créer des features
- B) RMSE du futur modèle
- C) Nombre de clusters K
- D) Valeur de R^2

Réponse : A

Q4 – Qualité des données

Quels points vérifier dans le plan d'action ?

- A) Valeurs manquantes, doublons, outliers, incohérences
- B) Scores du modèle
- C) Valeur de la cible seulement
- D) Noms des variables uniquement

Réponse : A

Q5 – Features engineering

Pourquoi inclure le features engineering dans le plan d'action ?

- A) Créer ou transformer des variables pour améliorer le futur modèle
- B) Choisir le nombre de lignes du dataset
- C) Visualiser uniquement les corrélations
- D) Ignorer les variables inutiles

Réponse : A

Split des données – Résumé clair

But

Séparer les données en sous-ensembles pour **entraîner, choisir et évaluer un modèle** de façon honnête (sans triche).

Sorties attendues

- Choisir la **stratégie de split** : train/test ou train/validation/test
 - Séparer les **features X** et la **cible y**
 - Fixer les **proportions des ensembles** (train / validation / test)
 - Appliquer le split et **contrôler la répartition de y**
 - **Geler le jeu de test** pour l'évaluation finale
-

1 Pourquoi c'est crucial

- Éviter d'évaluer un modèle sur les mêmes données que celles utilisées pour l'entraînement
 - Obtenir une **performance réaliste** : le test simule de nouvelles données
 - Séparer les rôles :
 - **Train** → apprendre
 - **Validation** → choisir le modèle / tuner
 - **Test** → mesurer la performance finale
-

2 C'est quoi le split ?

- **Définition** : Diviser le dataset en sous-ensembles distincts
 - **Objectif** : Séparer les données utilisées pour apprendre le modèle de celles pour l'évaluer
 - **Options** :
 - **Split simple** : Train / Test
 - **Split complet** : Train / Validation / Test
-

3 Split simple : Train / Test

- **Train** : pour apprendre le modèle
 - **Test** : pour mesurer la performance finale sur des données jamais vues
 - **Usage** : projets simples, TPs, peu de modèles ou hyperparamètres
-

4 Split complet : Train / Validation / Test

Train : pour apprendre le modèle[• C'est la partie utilisée pour **apprendre** au modèle.

- Le modèle observe les exemples et ajuste ses paramètres.
 -]
 - **Validation** : comparer modèles, tuner hyperparamètres
 - **Test** : indépendant, mesure finale de performance
 - **Usage** : projets sérieux, compétition, tuning
-

5 Séparer features X et cible y

- **X** : toutes les colonnes explicatives (features)
 - **y** : colonne cible
 - **Pourquoi** : dire au modèle ce qu'il peut utiliser (X) et ce qu'il doit prédire (y)
 - **Comment** : retirer ID et cible de X, garder uniquement la cible dans y
-

6 Fixer les proportions

- **Objectif** : décider quelle part du dataset va dans train, validation et test
- **Règles** :
 - Train = plus grande partie
 - Test = petite partie (~20%)

- Validation = partie du reste si nécessaire
 - **Exemple :**
 - Sans validation : 80% train / 20% test
 - Avec validation : 70% train / 15% validation / 15% test
-

7 Appliquer le split et contrôler y

- Découper réellement le dataset en train, validation, test
 - Contrôler la répartition de la cible pour garder la même proportion de classes (si classification)
-

8 Geler le jeu de test

- Mettre le test de côté dès le début
 - **Ne jamais l'utiliser** pour l'entraînement ou le choix du modèle
 - Objectif : garder un jeu "inconnu" pour mesurer honnêtement la performance finale
-

9 Exemples Python

Split simple : Train / Test

```
from sklearn.model_selection import train_test_split

# X = features, y = cible
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=27, stratify=y
)
# 80% train / 20% test
# stratify=y pour garder même répartition des classes
```

Split complet : Train / Validation / Test

```
from sklearn.model_selection import train_test_split

# 1) Split : 60% train, 40% temporaire (val + test)
X_train, X_temp, y_train, y_temp = train_test_split(
    X, y, test_size=0.4, random_state=27, stratify=y
)

# 2) Split temporaire : moitié val / moitié test
X_val, X_test, y_val, y_test = train_test_split(
```

```
X_temp, y_temp, test_size=0.5, random_state=27, stratify=y_temp
)
# 70% train / 15% val / 15% test
```

✓ QCM (14 questions) +

Q1 — C'est quoi le but du Split ?

- A. Travailler avec toutes les données pour maximiser la performance
- B. Séparer apprentissage et évaluation
- C. Supprimer les valeurs manquantes
- D. Mélanger les colonnes du dataset

✓ ☐ Réponse : B

Explication: le split sert à séparer train/test pour éviter la triche.

Q2 — Pourquoi le split est crucial ?

- A. Pour réduire la taille du dataset
- B. Pour ne pas évaluer le modèle sur les mêmes données d'entraînement
- C. Pour augmenter le nombre de features
- D. Pour supprimer les doublons

✓ ☐ Réponse : B

Explication : sinon il y a **sur-apprentissage** et "triche involontaire".

Q3 — Le split simple contient :

- A. Train / Validation / Test
- B. Train / Test
- C. Train / Validation
- D. Test uniquement

✓ ☐ Réponse : B

Explication : split simple = 2 parties.

Q4 — Le split complet contient :

- A. Train / Test
- B. Train / Validation / Test

- C. Train / Validation
- D. Train uniquement

✓ ☐ Réponse : B

Q5 — Le jeu d'entraînement (train) sert à :

- A. Évaluer le modèle final
- B. Choisir les hyperparamètres
- C. Apprendre les paramètres du modèle
- D. Tester contre des données inconnues

✓ ☐ Réponse : C

Q6 — Le jeu de validation sert à :

- A. Apprendre les paramètres
- B. Ajuster et comparer les modèles
- C. Geler les données
- D. Tester la performance finale

✓ ☐ Réponse : B

Q7 — Le jeu de test sert à :

- A. Régler le modèle
- B. Ajuster les hyperparamètres
- C. Mesurer la performance finale
- D. Nettoyer les valeurs manquantes

✓ ☐ Réponse : C

Q8 — Pourquoi geler le jeu de test ?

- A. Pour pouvoir l'utiliser plusieurs fois
- B. Pour ne pas influencer le tuning
- C. Pour compléter les valeurs manquantes
- D. Pour équilibrer la cible

✓ ☐ Réponse : B

Explication : le test doit rester **100% inconnu** jusqu'à la fin.

Q9 — Pourquoi séparer X et y ?

- A. Pour réduire la taille du dataset
- B. Pour indiquer au modèle ce qu'il doit prédire
- C. Pour supprimer les colonnes ID
- D. Pour équilibrer les classes

✓ ☐ Réponse : B

Q10 — X contient :

- A. Les colonnes ID uniquement
- B. La variable cible y
- C. Les features (variables explicatives)
- D. Le jeu de test

✓ ☐ Réponse : C

Q11 — y contient :

- A. Les colonnes explicatives
- B. Les doublons
- C. Les valeurs manquantes
- D. La colonne cible

✓ ☐ Réponse : D

Q12 — Une proportion classique sans validation est :

- A. 50% train / 50% test
- B. 30% train / 70% test
- C. 80% train / 20% test
- D. 95% train / 5% test

✓ ☐ Réponse : C

Q13 — Une proportion classique avec validation est :

- A. 70% train / 15% val / 15% test
- B. 50% train / 25% val / 25% test
- C. 60% train / 20% val / 20% test
- D. 30% train / 30% val / 40% test

✓ ☐ Réponse : A

Q14 — Pourquoi utiliser stratify=y ?

- A. Pour augmenter la taille du dataset
- B. Pour garder la même répartition des classes dans chaque split
- C. Pour supprimer les outliers
- D. Pour éliminer les doublons

✓ ☐ Réponse : B

Préparer les données – Résumé clair

But

Transformer les données brutes en **données prêtes pour le modèle**, en respectant la règle **fit sur train, transform sur val/test**.

Sorties attendues

- Un **pipeline de préparation** : ordre typique → manquants → encodage → scaling → autres transformations.
 - Paramètres appris **uniquement sur X_train**.
 - Jeux préparés : **X_train_prepared, X_val_prepared, X_test_prepared**.
 - Aucune fuite de données depuis validation/test vers l'entraînement.
-

Pourquoi c'est crucial

- Fournir au modèle des données propres et cohérentes.
 - Éviter la **fuite de données** en apprenant les paramètres uniquement sur le train.
 - Appliquer **de façon systématique et reproductible** les décisions prises lors de l'EDA.
-

Principes à respecter

1. **Fit sur train, transform sur val/test**

- **fit** = apprendre les paramètres depuis X_train :
 - Moyennes/médianes pour l'imputation
 - Liste des catégories pour l'encodage
 - Moyenne & écart-type pour le scaling
 - **transform** = appliquer ces paramètres aux autres jeux :
 - Remplir les manquants
 - Créer les colonnes one-hot
 - Standardiser avec les mêmes valeurs
2. **Lien avec l'EDA / plan d'action**
- Les transformations appliquées viennent directement des décisions prises dans le **plan d'action EDA**.
 - Exemple : si on décide d'imputer les manquants avec la médiane pendant l'EDA → on applique exactement ça dans le pipeline.
-
-

QCM – Préparer les données

Q1. Quel est le but principal de préparer les données ?

- A) Transformer les données brutes en données prêtes pour le modèle ✓
- B) Modifier la cible pour améliorer la performance
- C) Faire fit sur validation et test pour mieux généraliser
- D) Créer de nouvelles colonnes sans règles

Réponse : A

Q2. Sur quel jeu de données doit-on apprendre les transformations (fit) ?

- A) X_train ✓
- B) X_val
- C) X_test
- D) Tous les jeux simultanément

Réponse : A

Q3. Quel est l'ordre typique des étapes dans un pipeline de préparation ?

- A) Scaling → Encodage → Manquants → Autres
- B) Manquants → Encodage → Scaling → Autres ✓
- C) Encodage → Scaling → Manquants
- D) Autres → Manquants → Scaling

Réponse : B

Q4. Pourquoi gèle-t-on le jeu de test ?

- A) Pour pouvoir faire fit dessus plus tard
- B) Pour garder un jeu "inconnu" et mesurer la performance finale ✓
- C) Pour augmenter artificiellement l'accuracy
- D) Pour l'utiliser comme validation

Réponse : B

Q5. Quelle règle d'or doit-on respecter pour éviter la fuite de données ?

- A) Fit sur X_train, transform sur X_val et X_test ✓
- B) Fit sur tous les jeux et transform sur X_train seulement
- C) Fit et transform sur X_val uniquement
- D) Faire fit sur X_test pour améliorer la généralisation

Réponse : A

Q6. Comment traite-t-on les variables catégorielles ?

- A) Label encoding ou one-hot encoding ✓
- B) Standardisation uniquement
- C) Imputation par moyenne
- D) On les ignore toujours

Réponse : A

Q7. Comment traite-t-on les variables numériques ?

- A) Label encoding
- B) One-hot encoding
- C) Normalisation / Standardisation (scaling) ✓
- D) Imputation par mode uniquement

Réponse : C

Q8. Quels problèmes de qualité des données doivent être pris en compte ?

- A) Valeurs manquantes ✓
- B) Doublons ✓
- C) Outliers ✓
- D) Incohérences ✓

Réponse : A, B, C, D

Q9. Comment relier l'EDA à la préparation des données ?

- A) Les décisions du plan d'action EDA deviennent des transformations concrètes ✓
- B) L'EDA n'a aucun rapport avec la préparation
- C) On refait toutes les analyses sur validation et test
- D) On change les transformations à chaque jeu

Réponse : A

Partier 6

Entraîner et Valider – Résumé clair

But

Mettre en pratique les étapes du pipeline ML :

- Entraîner différents modèles sur les données préparées.
- Évaluer leurs performances avec les métriques définies.
- Comparer les résultats à une baseline simple pour vérifier la valeur ajoutée du modèle.

Sorties attendues

- **Régression** : LinearRegression
 - **Classification** : LogisticRegression, Decision Tree, Random Forest
 - **Réduction de dimension** : PCA
 - **Clustering** : K-means
 - **Détection d'anomalies** : Isolation Forest
-

Linear Regression (Régression)

Type de problème

- Régression (prédire une valeur numérique)
- Exemples : prix d'une maison, montant d'achat, durée, note

But du modèle

- Apprendre une relation linéaire entre X (features) et y (cible) :
[
 $\hat{y} = a_1 x_1 + a_2 x_2 + \dots + a_p x_p + b$
]
]
- Trouver les coefficients ($a_1, \dots, a_p$) et le biais (b) pour minimiser l'erreur.

Concept clé

- En 1D : droite $y = ax + b$
- En plusieurs dimensions : “plan” dans l'espace des features
- Coefficients :
 - ($a_i > 0$) → y augmente quand x_i augmente
 - ($a_i < 0$) → y diminue quand x_i augmente
 - ($a_i \approx 0$) → feature peu utile
- Biais b : valeur de base quand toutes les features sont à 0

Fonctionnement

1. Départ : $X_{\text{train}}, y_{\text{train}}$
2. Choix du modèle linéaire
3. Initialisation des coefficients (souvent 0)
4. Calcul des prédictions sur le train
5. Mesure de l'erreur (MSE, RMSE)
6. Ajustement des coefficients pour réduire l'erreur
7. Répétition jusqu'à stabilisation → modèle entraîné

Évaluation

- **Métriques principales :**
 - MSE / RMSE : erreur moyenne ou racine carrée de l'erreur
 - MAE : erreur moyenne absolue
 - R^2 : proportion de variance expliquée
- **Baseline typique :** prédire la moyenne de y_{train}
- Objectif :
 - $\text{RMSE}_{\text{modèle}} < \text{RMSE}_{\text{baseline}}$
 - $R^2_{\text{modèle}} > R^2_{\text{baseline}}$

Hyperparamètres

- `fit_intercept` : True ou False (apprendre le biais ou non)
- Peu de réglages, la préparation des données est plus importante

Exemple avec scikit-learn

```
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

# Définir le modèle
lin_reg = LinearRegression()

# Entraîner
lin_reg.fit(X_train_prepared, y_train)

# Prédire sur validation
y_val_pred = lin_reg.predict(X_val_prepared)

# Calculer métriques
rmse_model = mean_squared_error(y_val, y_val_pred, squared=False)
r2_model = r2_score(y_val, y_val_pred)
print("RMSE modèle :", rmse_model)
print("R2 modèle :", r2_model)
print("RMSE baseline :", rmse_baseline_val)
```

QSM

Q1. Quel est le but de l'étape "Entraîner et Valider" ?

- A) Préparer les données brutes pour le modèle
- B) Mettre en pratique le pipeline ML et comparer plusieurs modèles
- C) Séparer les données en train/test
- D) Créer des graphiques pour l'EDA

Réponse : B ✓

Q2. Quels modèles sont utilisés selon le type de problème ?

- A) Régression → LinearRegression
- B) Classification → LogisticRegression, Decision Tree, Random Forest
- C) Réduction de dimension → PCA
- D) Toutes les réponses ci-dessus

Réponse : D ✓

Q3. Linear Regression sert à :

- A) Prédire une valeur numérique
- B) Prédire une classe (oui/non)
- C) Détecter des anomalies
- D) Réduire le nombre de features

Réponse : A ✓

Q4. Dans Linear Regression, que représente le coefficient a_i ?

- A) L'erreur du modèle
- B) L'influence d'une feature sur la prédiction
- C) Le biais du modèle
- D) La moyenne de y_{train}

Réponse : B ✓

Q5. Dans Linear Regression, que fait le biais b ?

- A) Mesure la performance du modèle
- B) Ajuste la valeur de base quand toutes les features = 0
- C) Supprime les outliers
- D) Encode les variables catégorielles

Réponse : B ✓

Q6. Quelle est la bonne pratique pour éviter la fuite de données ?

- A) Fit sur X_{train} , transform sur X_{val} et X_{test}
- B) Fit sur tout le dataset avant le split
- C) Transformer seulement X_{train}
- D) Ne pas normaliser les données

Réponse : A ✓

Q7. Quelles métriques sont utilisées pour évaluer Linear Regression ?

- A) RMSE / MSE
- B) MAE
- C) R^2
- D) Toutes les réponses ci-dessus

Réponse : D ✓

Q8. Quelle est la baseline typique pour Linear Regression ?

- A) Prédire aléatoirement
- B) Prédire toujours la moyenne de y_train
- C) Prédire la médiane des features
- D) Utiliser un arbre de décision

Réponse : B ✓

Q9. Hyperparamètre important de LinearRegression (scikit-learn) :

- A) max_depth
- B) n_estimators
- C) fit_intercept
- D) learning_rate

Réponse : C ✓

Entraîner et Valider – Résumé Clair

But

Mettre en pratique le pipeline ML en entraînant et évaluant plusieurs algorithmes sur les données préparées, puis comparer les modèles à la baseline avec les métriques définies.

Sorties attendues

- Régression : LinearRegression
 - Classification : LogisticRegression, Decision Tree, Random Forest
 - Réduction de dimension : PCA
 - Clustering : K-means
 - Détection d'anomalies : Isolation Forest
-

1 Linear Regression

- **Type de problème** : Régression (prédire une valeur numérique)

- **But** : Trouver coefficients ($a_1, \dots, a_p$) et biais (b) pour approximer ($\hat{y} = a_1x_1 + \dots + a_px_p + b$)
- **Idée clé** : Minimiser l'erreur entre vraie valeur et prédiction
- **Évaluation** : MSE/RMSE, MAE, R^2
- **Baseline** : Toujours prédire la moyenne de y_{train}
- **Hyperparamètre principal** : `fit_intercept` (True/False)
- **Exemple (scikit-learn)** :

```
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

lin_reg = LinearRegression()
lin_reg.fit(X_train_prepared, y_train)
y_val_pred = lin_reg.predict(X_val_prepared)
rmse_model = mean_squared_error(y_val, y_val_pred, squared=False)
r2_model = r2_score(y_val, y_val_pred)
```

2 Logistic Regression

- **Type de problème** : Classification binaire (0/1)
- **But** : Prédire la probabilité d'appartenance à la classe 1 via sigmoïde

$$p = \frac{1}{1 + e^{-z}}$$

puis seuil (souvent 0.5) • Si $p \geq 0.5 \rightarrow$ on prédit **1**

- Si $p < 0.5 \rightarrow$ on prédit **0**

- **Frontière de décision** : Linéaire dans l'espace des features
- **Évaluation** : Accuracy, F1-score, AUC-ROC
- **Baseline** : Toujours prédire la classe majoritaire ou probabilité constante
- **Hyperparamètres** :
 - C : régularisation (grand $\rightarrow$ complexe, petit $\rightarrow$ simple)
 - `Penalty` : type de régularisation ("l2")
 - `max_iter` : nombre d'itérations
- **Exemple (scikit-learn)** :

```
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, f1_score

log_reg = LogisticRegression(C=1.0, penalty="l2", max_iter=200)
log_reg.fit(X_train_prepared, y_train)
```

```
y_val_pred = log_reg.predict(X_val_prepared)
acc_model = accuracy_score(y_val, y_val_pred)
f1_model = f1_score(y_val, y_val_pred)
```

3 📦 Decision Tree

- **Type de problème** : Classification (binaire ou multi-classes), existe aussi pour régression
- **But** : Décider de la classe via des règles “SI...ALORS...” (arbre de décisions)
- **Idée clé** : Poser des questions sur les features pour séparer les classes (critères Gini/Entropy)
- **Évaluation** : Accuracy, F1-score, matrice de confusion
- **Baseline** : Prédire classe majoritaire
- **Hyperparamètres** :
 - `max_depth` : profondeur max de l’arbre
 - `min_samples_split` : nb min d’exemples pour diviser
 - `criterion` : mesure de pureté ("gini", "entropy")
- **Exemple (scikit-learn)** :

```
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import accuracy_score, f1_score

tree_clf = DecisionTreeClassifier(max_depth=5, min_samples_split=10,
criterion="gini", random_state=42)
tree_clf.fit(X_train_prepared, y_train)
y_val_pred = tree_clf.predict(X_val_prepared)
acc_model = accuracy_score(y_val, y_val_pred)
f1_model = f1_score(y_val, y_val_pred)
```

QCM – Entraîner et Valider

1 📦 Linear Regression

Q1. Quel est le type de problème résolu par Linear Regression ?

- A) Classification binaire
- B) Classification multi-classes
- C) Régression numérique ✓
- D) Clustering

Q2. Que représente le biais (b) dans Linear Regression ?

- A) La valeur prédite finale
- B) Le poids d’une feature
- C) La valeur de base lorsque toutes les features sont à 0 ✓
- D) L’erreur moyenne

Q3. Quelle métrique est typiquement utilisée pour évaluer Linear Regression ?

A) Accuracy

B) RMSE / MSE ✓

C) F1-score

D) AUC

2 Logistic Regression

Q4. Quelle est la sortie principale d'un modèle Logistic Regression ?

A) Une valeur numérique

B) Une probabilité que l'observation appartienne à la classe 1 ✓

C) Une distance à la frontière

D) Une composante PCA

Q5. Que fait la fonction sigmoïde dans Logistic Regression ?

A) Transforme les features en valeurs standardisées

B) Transforme le score linéaire en probabilité ✓

C) Sépare les données en clusters

D) Minimise l'erreur quadratique

Q6. Quel hyperparamètre contrôle la régularisation dans Logistic Regression ?

A) max_depth

B) C ✓

C) min_samples_split

D) criterion

Q7. Si la probabilité prédite est ≥ 0.5 , la classe prédite est :

A) 0

B) 1 ✓

C) Dépend du RMSE

D) Aléatoire

3 Decision Tree

Q8. Quel type de problème peut résoudre Decision Tree ?

A) Classification binaire / multi-classes ✓

B) Régression numérique ✓

C) Clustering

D) A & B ✓

Q9. Que fait Decision Tree à chaque nœud ?

- A) Calcule une probabilité
- B) Pose une question sur une feature pour séparer les classes ✓**
- C) Applique PCA
- D) Normalise les données

Q10. Quel hyperparamètre limite la profondeur de l'arbre ?

- A) max_depth ✓**
- B) min_samples_split
- C) C
- D) penalty

Q11. Quelle métrique est utilisée pour évaluer Decision Tree ?

- A) RMSE
 - B) Accuracy / F1-score ✓**
 - C) Log-loss
 - D) Silhouette score
-
-

Entraîner et Valider

Sorties attendues

- **Régression** : LinearRegression
 - **Classification** : LogisticRegression, Decision Tree, Random Forest
 - **Réduction de dimension** : PCA
 - **Clustering** : K-means
 - **Détection d'anomalies** : Isolation Forest
-

1 Random Forest

- **Type de problème** : **Classification binaire ou multi-classes**, existe aussi pour régression (RandomForestRegressor).
- **But** : Combiner plusieurs arbres pour un modèle plus robuste et moins sensible au surapprentissage.
- **Idée clé** :
 - Chaque arbre est entraîné sur un échantillon aléatoire de données et de features.
 - Pour prédire : vote majoritaire (classification) ou moyenne (régression).
- **Fonctionnement** :
 - Bootstrap : tirage aléatoire avec remise pour chaque arbre.

- Chaque split : sous-ensemble aléatoire de features.
 - Chaque arbre prédit indépendamment, la forêt combine les votes.
- **Évaluation :**
 - **Accuracy, F1-score, matrice de confusion.**
 - Baseline : prédire la classe majoritaire.
 - Objectif : meilleure performance que la baseline.
- **Hyperparamètres principaux :**
 - `n_estimators` : nombre d'arbres (100, 200...)
 - `max_depth` : profondeur maximale des arbres
 - `max_features` : nombre de features testées à chaque split
- **Exemple code :**

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, f1_score

rf_clf = RandomForestClassifier(n_estimators=100, max_depth=None,
random_state=27)
rf_clf.fit(X_train_prepared, y_train)
y_val_pred = rf_clf.predict(X_val_prepared)
acc_model = accuracy_score(y_val, y_val_pred)
f1_model = f1_score(y_val, y_val_pred)
print("Accuracy Random Forest :", acc_model)
print("F1 Random Forest :", f1_model)
```

2 PCA (Principal Component Analysis)

- **Type de problème :** **Réduction non supervisée de dimension.**
- **But :** Résumer l'information en conservant un maximum de variance, créer de nouvelles features (PC1, PC2...).
- **Idée clé :**
 - Trouver axes où la variance est maximale.
 - Projeter les données sur ces axes pour version compressée.
- **Fonctionnement :**
 1. Centrer les données (retirer la moyenne)
 2. Calculer matrice de covariance
 3. Trouver vecteurs propres (directions) et valeurs propres (importance)
 4. Trier par variance décroissante et garder k premières composantes
 5. Transformer les données sur ces axes
- **Évaluation :**
 - Variance expliquée cumulée
 - Objectif : conserver 80%-95% de la variance
- **Hyperparamètres :**
 - `n_components` : nombre de composantes à garder (entier ou pourcentage)
 - `svd_solver` : méthode de calcul interne
- **Exemple code :**

```
from sklearn.decomposition import PCA
```

```
pca = PCA(n_components=2)
pca.fit(X_train_prepared)
X_train_pca = pca.transform(X_train_prepared)
X_val_pca = pca.transform(X_val_prepared)
print("Variance expliquée :", pca.explained_variance_ratio_)
```

1 Random Forest

Q1. Random Forest est principalement utilisé pour :

- A) Régression uniquement
- B) Classification et régression ✓**
- C) Réduction de dimension
- D) Clustering

Q2. Comment Random Forest prédit la classe pour un nouvel exemple ?

- A) Par un seul arbre
- B) Vote majoritaire de tous les arbres ✓**
- C) Moyenne des features
- D) Utilise PCA

Q3. Quel est l'effet d'augmenter n_estimators ?

- A) Modèle plus rapide
- B) Modèle plus stable ✓**
- C) Moins d'arbres
- D) Réduit le surapprentissage automatiquement

Q4. Quel hyperparamètre contrôle la profondeur maximale des arbres ?

- A) max_features
 - B) n_estimators
 - C) max_depth ✓**
 - D) criterion
-

2 PCA

Q5. PCA est utilisé pour :

- A) Classification
- B) Réduction de dimension ✓**
- C) Clustering
- D) Détection d'anomalies

Q6. Quelle est la règle pour choisir le nombre de composantes principales ?

- A) Conserver toujours 2 composantes
- B) Conserver 80%-95% de la variance ✓✓
- C) Conserver toutes les features
- D) Conserver uniquement la première

Q7. PCA est :

- A) Supervised (supervisé)
- B) Non supervised (non supervisé) ✓✓
- C) Semi-supervisé
- D) Un algorithme de classification

Voici un **résumé clair et structuré** de la partie **K-means et Isolation Forest** en gardant tout le contenu essentiel :

Clustering : K-means

Type de problème :

- Clustering non supervisé.
- Regroupe les points en k clusters.

But :

- Trouver des groupes homogènes.
- Minimiser la distance intra-cluster.

Idée clé :

- Chaque cluster a un centre (centroid).
- Chaque point est affecté au centre le plus proche.
- Déplacer les centres pour mieux correspondre aux données.

Algorithme :

1. Initialisation : choisir k centres de départ.
2. Affectation : chaque point au centre le plus proche.
3. Mise à jour : recalculer le centre de chaque cluster.
4. Convergence : si les centres changent peu, arrêter.

Évaluation :

- Inertie (SSE) : plus bas = clusters plus compacts.
- Méthode du coude (Elbow) : choisir k où la baisse d'inertie ralentit.
- Silhouette score : qualité de séparation.
- Pas de baseline supervisée.

Hyperparamètres :

- `n_clusters` : nombre de clusters k.
- `init` : méthode d'initialisation (k-means++).
- `n_init` : nombre de lancements pour éviter mauvais minima.

Exemple Python :

```
from sklearn.cluster import KMeans

kmeans = KMeans(n_clusters=3, n_init=10)
kmeans.fit(X_train_prepared)
labels = kmeans.predict(X_train_prepared)
print("Inertie :", kmeans.inertia_)
```

Détection d'anomalies : Isolation Forest

Type de problème :

- Détection d'anomalies non supervisée.

But :

- Identifier les points rares, aberrants, atypiques.

Idée clé :

- Une anomalie est facile à isoler : elle est loin des autres ou dans une zone peu dense.

Algorithme :

1. Construire une forêt d'arbres aléatoires.
2. À chaque arbre, isoler les points via des splits aléatoires.
3. Mesurer la longueur du chemin moyen d'un point :
 - Court → anomalie
 - Long → normal

Évaluation :

- Scores d'anomalie : score bas → point potentiellement anormal.
- Inspection visuelle ou métier : confirmer les anomalies détectées.

- Comparaison possible avec détection aléatoire ou seuil simple.

Hyperparamètres :

- `n_estimators` : nombre d'arbres.
- `contamination` : proportion attendue d'anomalies.
- `max_samples` : taille de l'échantillon par arbre.

Exemple Python :

```
from sklearn.ensemble import IsolationForest

iso = IsolationForest(n_estimators=200, contamination=0.02, random_state=42)
iso.fit(X_train_prepared)
scores = iso.decision_function(X_train_prepared)
labels = iso.predict(X_train_prepared) # -1 = anomalie, 1 = normal
```

QCM – K-means

1 ☐ Quel type de problème K-means résout-il ?

- A) Régression supervisée
- B) Clustering non supervisé ✓
- C) Classification binaire
- D) Détection d'anomalies

2 ☐ Que représente un “centroid” dans K-means ?

- A) Un point de données aléatoire
- B) Le centre d'un cluster ✓
- C) La variance du cluster
- D) Un hyperparamètre

3 ☐ Quelle métrique est utilisée pour évaluer la compacité des clusters ?

- A) Accuracy
- B) Inertie (SSE) ✓
- C) F1-score
- D) Log-loss

4 ☐ Quelle méthode aide à choisir le nombre optimal de clusters ?

- A) Cross-validation
- B) Méthode du coude (Elbow) ✓
- C) AUC-ROC
- D) Matrice de confusion

5 ☐ **Quels sont des hyperparamètres importants de K-means ?**

- A) `n_clusters, init, n_init` ✓
 - B) `max_depth, criterion`
 - C) `C, penalty`
 - D) `n_estimators, max_samples`
-

QCM – Isolation Forest

1 ☐ **Quel type de problème Isolation Forest résout-il ?**

- A) Régression
- B) Classification
- C) Détection d'anomalies non supervisée ✓
- D) Réduction de dimension

2 ☐ **Pourquoi une anomalie est-elle facile à isoler ?**

- A) Parce qu'elle est au centre des données
- B) Parce qu'elle est loin des autres ou dans une zone peu dense ✓
- C) Parce qu'elle a un label spécial
- D) Parce qu'elle appartient au cluster majoritaire

3 ☐ **Que signifie un score faible dans Isolation Forest ?**

- A) Le point est normal
- B) Le point est potentiellement une anomalie ✓
- C) Le point est un centroid
- D) Le point appartient à tous les clusters

4 ☐ **Quels sont des hyperparamètres clés d'Isolation Forest ?**

- A) `n_estimators, contamination, max_samples` ✓
- B) `n_clusters, init, n_init`
- C) `max_depth, min_samples_split`
- D) `C, penalty`

5 ☐ **Comment l'algorithme détermine-t-il une anomalie ?**

- A) En calculant la distance au centroid du cluster
 - B) En mesurant la longueur moyenne du chemin dans les arbres aléatoires ✓
 - C) En utilisant la variance expliquée
 - D) En appliquant la fonction sigmoïde
-