

COMPTE RENDU – TP3 : Découverte et Exécution de MapReduce

1. Objectifs du TP

Ce travail pratique a pour objectifs :

- Comprendre le fonctionnement du modèle **MapReduce** (phases Map, Shuffle et Reduce).
- Exécuter un programme MapReduce déjà fourni par Hadoop : **WordCount**.
- Observer le déroulement d'un job dans YARN et analyser les résultats obtenus.

2. Introduction théorique

Le modèle **MapReduce** est un paradigme de traitement distribué permettant de manipuler de grandes quantités de données en parallèle sur un cluster de machines.

Il repose sur deux fonctions principales :

• Phase Map

- Transforme les données d'entrée en couples (*clé, valeur*).
- Dans le cas de WordCount, chaque mot devient : **(mot, 1)**.

• Phase Reduce

- Agrège les valeurs associées à chaque clé.
- Produit pour chaque mot le nombre total d'occurrences.

L'exemple traité dans ce TP consiste à compter le nombre d'apparitions de chaque mot dans un texte.

3. Préparation de l'environnement

a. Démarrage des services Hadoop

Les services nécessaires sont lancés à l'aide des commandes :

```
vboxuser@ubuntu:~$ start-dfs.sh
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [ubuntu]
vboxuser@ubuntu:~$ start-yarn.sh
Starting resourcemanager
Starting nodemanagers
vboxuser@ubuntu:~$
```

b. Création du répertoire HDFS est créé Un fichier texte localement pour être analysé

```
vboxuser@ubuntu:~$ hdfs dfs -mkdir -p /user/tp3/mapreduce/input
vboxuser@ubuntu:~$ echo "hadoop est un framowork pour le big data" > texte.txt
vboxuser@ubuntu:~$ echo "le big data repose sur le modele mapreduce " >> texte.txt
vboxuser@ubuntu:~$ echo "hadoop permet de stocker et traiter de grandes donnees >> texte.txt
> ^C
vboxuser@ubuntu:~$ ^C
vboxuser@ubuntu:~$ ^C
vboxuser@ubuntu:~$ ^C
vboxuser@ubuntu:~$ echo "hadoop permet de stocker et traiter de grandes donnees >> texte.txt
```

Il est ensuite transféré dans HDFS :

```
vboxuser@ubuntu:~$ hdfs dfs -put texte.txt /user/tp3/mapreduce/input/
vboxuser@ubuntu:~$ hdfs dfs -ls /user/tp3/mapreduce/input
Found 1 items
-rw-r--r-- 3 vboxuser supergroup      85 2025-11-18 21:27 /user/tp3/mapredu
ce/input/texte.txt
vboxuser@ubuntu:~$
```

3. Exécution du job WordCount

Hadoop fournit un programme WordCount déjà compilé.

Lancement du job :

```
vboxuser@ubuntu:~$ hadoop jar /usr/local/hadoop/share/hadoop/mapreduce/hadoop-map
reduce-examples*.jar wordcount /user/tp3/mapreduce/input /user/tp3/mapreduce/out
out
2025-11-18 22:02:47,469 INFO input.FileInputFormat: Total input files to process
: 1
```

4. Vérification des résultats

a. Lister les fichiers de sortie

```
vboxuser@ubuntu:~$ hdfs dfs -ls /user/tp3/mapreduce/output
Found 2 items
-rw-r--r-- 3 vboxuser supergroup      0 2025-11-18 22:02 /user/tp3/mapredu
ce/output/_SUCCESS
-rw-r--r-- 3 vboxuser supergroup    93 2025-11-18 22:02 /user/tp3/mapredu
ce/output/part-r-00000
vboxuser@ubuntu:~$
```

b. Affichage du résultat

```
vboxuser@ubuntu:~$ hdfs dfs -cat /user/tp3/mapreduce/output/part-r-00000
big      2
data     2
est      1
framowork      1
hadoop     1
le        3
mapreduce    1
modele     1
pour       1
repose     1
sur        1
un         1
vboxuser@ubuntu:~$
```

Chaque ligne correspond à un mot suivi du nombre d'occurrences.

5.1'interface YARN :

The screenshot shows the Hadoop YARN web interface in a browser. The URL is <http://localhost:8088/cluster>. The interface includes a sidebar with navigation links like 'Cluster', 'Nodes', 'Node Labels', 'Applications', and 'Tools'. The main content area displays various metrics:

- Cluster Metrics:** A table showing App Submitted (0), Apps Pending (0), Apps Running (0), Apps Completed (0), and Containers Running (0).
- Cluster Nodes Metrics:** A table showing Active Nodes (0), Decommissioning Nodes (0), and Decommissioned Nodes (0).
- Scheduler Metrics:** A table showing Scheduler Type (Capacity Scheduler), Scheduling Resource Type ([memory-mb (unit=Mi), vcores]), and Minimum Allocation (<memory:1024, vCores:1>).
- Applications:** A table with columns for ID, User, Name, Application Type, Application Tags, Queue, Application Priority, StartTime, LaunchTime, and FinishTime. It shows 0 entries.

6. Analyse et réponses aux questions

1. Quelle est la fonction principale de la phase Map ?

La phase Map transforme chaque ligne du fichier en couples (**mot**, **1**) afin de préparer l'agrégation.

2. Que fait la phase Reduce ?

Elle regroupe les valeurs associées à une même clé (mot) et calcule le total des occurrences.

3. À quoi sert le fichier _SUCCESS ?

Il indique que le job s'est exécuté correctement sans erreur.

4. Que se passe-t-il si on relance le job sans supprimer le dossier de sortie ?

Hadoop renvoie une erreur car il refuse d'écraser un répertoire existant.

5. Différence entre système local et HDFS dans ce contexte ?

Système local	HDFS
Stockage sur une seule machine	Stockage distribué sur plusieurs nœuds
Rapidité mais risque de perte	Tolérance aux pannes, meilleure fiabilité
Pas adapté au Big Data	Conçu pour les gros volumes et le traitement parallèle

7. Conclusion

Ce TP a permis d'exécuter un job MapReduce complet et de comprendre ses différentes phases.

WordCount a démontré le fonctionnement de MapReduce : découpage des données, traitement parallèle, agrégation et production d'un résultat final.

L'utilisation de YARN a permis de visualiser l'exécution en temps réel et de vérifier l'état du cluster.

Ce TP constitue une introduction essentielle au traitement distribué et au fonctionnement d'Hadoop dans un environnement Big Data.