


DATA MINING

Partie 3

ER-RAHMOUNY Hamza

Schéma KDD



PROCESSUS GLOBAL DE DÉCOUVERTE DE CONNAISSANCES :

- **Sélection** des données pertinentes.
- **Prétraitement** (nettoyage, valeurs manquantes, outliers).
- **Transformation** (normalisation, réduction de dimension, codage).
- **Data Mining** : application d'algorithmes (classification, clustering...).
- **Interprétation / Évaluation** : analyse des résultats, prise de décision.

Data Mining

Technique	Objectif principal
Description	Résumer ou visualiser les données pour mieux les comprendre (statistiques descriptives, clustering exploratoire...).
Classification	Attribuer une étiquette (classe) à de nouvelles données à partir d'exemples connus (ex : arbre de décision, SVM, réseaux de neurones...).
Association	Découvrir des relations entre les variables (ex : règles du type si A alors B — comme dans l'analyse de paniers d'achat).
Estimation	Prédire une valeur numérique continue à partir d'autres variables (ex : prédire un salaire ou un prix).
Segmentation	Diviser la population en groupes homogènes selon certaines caractéristiques (clustering, K-means...).
Prévision	Prédire des valeurs futures à partir de tendances passées (ex : séries temporelles).

Deux grandes approches du Data Mining !

Approche statistique

Décrire, comprendre et résumer les relations !


- Moyenne, variance, écart-type.
- Corrélation.
- Régression linéaire.
- Analyse factorielle (ACP, CAH...).

Approche par Machine Learning

Prédire, classer ou regrouper des observations !

- Classification.
- Prédiction (régression).
- Clustering (K-Means).
- Association (Apriori).

ON PASSE D'UNE LOGIQUE EXPLICATIVE/CONFIRMATOIRE À
UNE LOGIQUE PRÉDICTIVE ET INDUCTIVE CENTRÉE MODÈLE.



MACHINE LEARNING



Plan

- C'est quoi e Machine Learning ?
- Pourquoi le ML pour le DM ?
- Tâche DM réalisées en ML ?
- Catégories d'apprentissage
- Pipeline du Machine Learning

Plan

- C'est quoi e Machine Learning ?
- Pourquoi le ML pour le DM ?
- Tâche DM réalisées en ML ?
- Catégories d'apprentissage
- Pipeline du Machine Learning

LE MACHINE LEARNING EST LE DOMAINE QUI DONNE AUX
ORDINATEURS LA CAPACITÉ D'APPRENDRE À PARTIR DE
L'EXPÉRIENCE SANS ÊTRE EXPLICITEMENT PROGRAMMÉS.

(ARTHUR SAMUEL, PIONNIER DE L'IA, 1959)

UN PROGRAMME INFORMATIQUE APPREND À PARTIR D'UNE
EXPÉRIENCE E , POUR UNE TÂCHE T ET UNE MESURE DE
PERFORMANCE P , SI SA PERFORMANCE SUR T (MESURÉE PAR
 P) S'AMÉLIORE AVEC L'EXPÉRIENCE E .

(TOM M. MITCHELL, MACHINE LEARNING, MCGRAW-HILL, 1997)

« LE *MACHINE LEARNING* EST UN SOUS-DOMAIN DE L'INTELLIGENCE ARTIFICIELLE QUI PERMET À DES SYSTÈMES D'APPRENDRE AUTOMATIQUEMENT À PARTIR DE DONNÉES ET D'AMÉLIORER LEURS PERFORMANCES AU FIL DU TEMPS SANS ÊTRE EXPLICITEMENT PROGRAMMÉS.»

IBM, WHAT IS MACHINE LEARNING?, IBM THINK, 2024

LE *MACHINE LEARNING* EST PASSÉ D'UNE IDÉE D'APPRENTISSAGE AUTOMATIQUE FORMULÉE PAR ARTHUR SAMUEL (1959), À UNE DÉFINITION SCIENTIFIQUE DONNÉE PAR TOM M. MITCHELL (1997), PUIS À UNE VISION MODERNE AXÉE SUR LES DONNÉES ET LA PRÉDICTION SELON IBM (2024).

Plan

- C'est quoi e Machine Learning ?
- Pourquoi le ML pour le DM ?
- Tâche DM réalisées en ML ?
- Catégories d'apprentissage
- Pipeline du Machine Learning


POURQUOI PASSER AU MACHINE LEARNING POUR FAIRE DU DATA MINING ?

- **VOLUME & VARIÉTÉ** : TROP DE DONNÉES, TROP DE TYPES (TEXTE, IMAGES, ...).
- **RELATIONS COMPLEXES** : NON-LINÉARITÉS ET INTERACTIONS DIFFICILES POUR LES STATS.
- **AUTOMATISATION** : LE MODÈLE **APPREND** LES RÈGLES DEPUIS LES EXEMPLES
- **PERFORMANCE PRÉDICTIVE** : MEILLEURE **GÉNÉRALISATION** SUR DE NOUVELLES DATA.
- **MISE EN PRODUCTION** : PIPELINES, RÉENTRAÎNEMENT, SUIVI DES PERFORMANCES.

Plan

- C'est quoi e Machine Learning ?
- Pourquoi le ML pour le DM ?
- **Tâche DM réalisées en ML ?**
- Catégories d'apprentissage
- Pipeline du Machine Learning


Tâches de Data Mining avec le Machine Learning




Plan

- C'est quoi e Machine Learning ?
- Pourquoi le ML pour le DM ?
- Tâche DM réalisées en ML ?
- **Catégories d'apprentissage**
- Pipeline du Machine Learning

Catégories d'apprentissage en Machine Learning



Sous catégories du Machine Learning




Pourquoi ne pas inclure le RL dans ce cours ?

- En data mining classique, on n'utilise généralement pas l'apprentissage par renforcement, car il optimise des décisions séquentielles avec récompense dans un environnement interactif, alors que les tâches de DM sont surtout hors-ligne (prédire, classer, segmenter, associer) sur des jeux de données fixes.
- On envisagera le RL si l'action modifie le système (ex. recommandation/prix dynamiques).

Plan

- C'est quoi e Machine Learning ?
- Pourquoi le ML pour le DM ?
- Tâche DM réalisées en ML ?
- Catégories d'apprentissage
- Pipeline du Machine Learning

Pipeline du Machine Learning



DATA MINING

Partie 3

ER-RAHMOUNY Hamza