

Statistique Appliquée

Deuxième année DUT

Soufiane Mouchtabih

26 novembre 2025

Table des matières

1	Statistique à deux dimensions	4
1.1	Introduction	4
1.2	Tableau de contingence	5
1.3	Distributions Marginales	6
1.4	Distributions conditionnelles	8
1.5	Indépendance statistique	10
1.6	Paramètres d'une distribution statistique double	10
1.6.1	Paramètres des distributions marginales	10
1.6.2	Paramètres des distributions conditionnelles	12
1.7	Covariance	13
1.8	Régression linéaire	13
1.8.1	Notion d'ajustement	13
1.8.2	Régression linéaire	15
1.8.3	L'équation de la droite de régression	17
1.8.4	Corrélation	18
1.8.5	Qualité d'une régression	19
2	Analyse combinatoire	21

2.1	Introduction	21
2.2	Arrangements	22
2.3	Permutations	24
2.4	Combinaisons	24
3	Calcul des probabilités	27
3.1	Introduction et Motivation	27
3.2	Notions sur les ensembles	30
3.3	Les concepts probabilistes	33
3.4	Tribu d'événements et espace probabilisable	36
3.5	Probabilités	37
3.5.1	Définition générale d'une probabilité	37
3.5.2	Conséquences des axiomes de probabilité	39
3.6	Probabilités conditionnelles	40
3.7	Indépendance d'événements	41
3.8	Formule de Bayes	42
4	Variables aléatoires discrètes et lois de Probabilités	44
4.1	Introduction aux variables aléatoires	44
4.2	Variables aléatoires discrètes	45
4.3	Fonction de répartition	48
4.4	Paramètres d'une variable aléatoire discrète	49
4.4.1	Espérance Mathématique	49
4.4.2	Variance	50
4.4.3	L'écart-type	50
4.5	Indépendance de variables aléatoires	51
4.6	Lois discrètes	51
4.6.1	Loi uniforme	51
4.6.2	Loi de Bernoulli	52
4.6.3	Loi Binomiale	53
4.6.4	Loi Géométrique	54

4.6.5	Loi de poisson	55
5	Variables aléatoires continues et lois de Probabilités	59
5.1	Variables aléatoires continues	59
5.2	Les caractéristiques d'une variable aléatoire continue	63
5.3	Indépendance de deux variables	64
5.4	Lois de probabilités continues	64
5.4.1	Loi uniforme	64
5.4.2	Loi exponentielle	66
5.4.3	Loi normale	67
5.5	Théorèmes limites	71
6	Estimation d'un paramètre	77
6.1	Introduction	77
6.1.1	Estimateur statistique	79
6.2	Construction d'estimateurs	82
6.3	Estimation ponctuelle	86
6.3.1	Estimation d'une espérance	86
6.3.2	Estimation d'une variance	86
6.3.3	Estimation ponctuelle d'un pourcentage	88
6.4	Estimation par intervalle de confiance	89
6.4.1	Notion d'intervalle de confiance	89
6.4.2	Intervalle de confiance d'une moyenne	90

1.1 Introduction

Dans le cas où deux variables seront considérées simultanément il sera possible de s'interroger sur l'existence de liens ou de relations entre les données.

- le salaire augmente-t-il avec l'âge ?
- Quel est le degré de dépendance du niveau de salaire à la catégorie socio-professionnelle à laquelle appartiennent les salariés ?
- À niveau de qualification égal, le salaire est-il différent selon la région dans laquelle exerce le salarié ?
- Le taux de réussite des étudiants à l'université est-il fonction de la catégorie socio-professionnelle de leurs parents ?

Répondre à ces diverses questions nécessite de déterminer si les variables sont liées entre elles (la corrélation).

On notera

- $x_i, i = 1, \dots, k$ les k modalités d'un caractère statistique x (quantitatif, qualitatif)
- $y_i, i = 1, \dots, l$ les l modalités d'un caractère statistique y (quantitatif, qualitatif)

- Les deux caractères x et y sont étudiés simultanément sur chacun des N individus de la population. On notera n_{ij} l'effectif correspondant au couple (x_i, y_j) . (correspond au nombre des individus caractérisés simultanément par les modalités x_i et y_j)

Définition 1.1.1

On appellera *distribution jointe des effectifs de x et y* l'ensemble des informations (x_i, y_j, n_{ij}) pour $i = 1, \dots, k$ et $j = 1, \dots, l$.

1.2 Tableau de contingence

La répartition des N observations suivant les modalités croisées des deux caractères se présente sous la forme d'un tableau à double entrée appelé aussi tableau de contingence. La structure d'un tel tableau est comme suit :

$x \backslash y$	y_1	y_2	$\dots$	y_j	$\dots$	y_l
x_1	n_{11}	n_{12}	$\dots$	n_{1j}	$\dots$	n_{1l}
x_2	n_{21}	n_{22}	$\dots$	n_{2j}	$\dots$	n_{2l}
$\vdots$						
x_i	n_{i1}	n_{i2}	$\dots$	n_{ij}	$\dots$	n_{il}
$\vdots$						
x_k	n_{k1}	n_{k2}	$\dots$	n_{kj}	$\dots$	n_{kl}

On a

$$\sum_{i=1}^k \sum_{j=1}^l n_{ij} = N$$

La fréquence du couple (x_i, y_j) est

$$f_{ij} = \frac{n_{ij}}{N}$$

Exemple: 1.2.1

Le tableau suivant donne la distribution de 100 adultes selon les variables x et y .
 x représente le poids en kilogrammes et y la taille en centimètres.

$y \backslash x$	[145, 155[	[155, 165[	[165, 175[	[175, 185]
[45, 55[	4	9	2	0
[55, 65[	3	10	10	7
[65, 75[	0	5	5	15
[75, 85[	0	0	4	16
[85, 95[	0	0	2	8

Exemple: 1.2.2

Le responsable des ressources humaines d'une entreprise a effectué un sondage auprès de 200 employés, choisis au hasard à partir du fichier de l'entreprise, pour connaître leur niveau de satisfaction vis-à-vis de leurs travail. Ce caractère x a été reparti selon trois modalités : élevé, moyen, faible. On a également noté la catégorie salariale y à laquelle appartenait l'employé soit : 2 000 dhs et moins ; plus de 2 000 dhs mais moins de 3 000 dhs ; 3 000 dhs et plus.

A partir des résultats de cette enquête, on a construit le tableau de contingence suivant :

$y \backslash x$	[0, 2000[	[2000, 3000[	≥ 3000
Élevé	13	19	25
Moyen	28	29	28
Faible	24	18	16

1.3 Distributions Marginales

On ajoute au tableau de contingence les totaux en ligne et en colonne.

$\begin{matrix} y \\ x \end{matrix}$	y_1	y_2	$\cdots$	y_j	$\cdots$	y_l	total
x_1	n_{11}	n_{12}	$\cdots$	n_{1j}	$\cdots$	n_{1l}	$n_{1.}$
x_2	n_{21}	n_{22}	$\cdots$	n_{2j}	$\cdots$	n_{2l}	$n_{2.}$
$\vdots$							$\vdots$
x_i	n_{i1}	n_{i2}	$\cdots$	n_{ij}	$\cdots$	n_{il}	$n_{i.}$
$\vdots$							$\vdots$
x_k	n_{k1}	n_{k2}	$\cdots$	n_{kj}	$\cdots$	n_{kl}	$n_{k.}$
total	$n_{.1}$	$n_{.2}$	$\cdots$	$n_{.j}$	$\cdots$	$n_{.l}$	$N = n_{..}$

En marge à droite (totaux en ligne) :

la distribution de x : pour chaque indice i , l'effectif $n_{i.}$ est le nombre total d'observations de la modalité x_i de x quelle que soit la modalité de y

$$n_{i.} = \sum_{j=1}^l n_{ij} = \text{Total de la ligne } i.$$

Définition 1.3.1

Les k couples $(x_i, n_{i.})$ définissent la distribution marginale de caractère x .

La modalité x_i a pour effectif $n_{i.}$ et pour fréquence marginale $f_{i.} = \frac{n_{i.}}{N}$

$$\sum_{i=1}^k n_{i.} = N$$

En marge en bas (totaux en colonne) : la distribution de y : pour chaque indice j , l'effectif $n_{.j}$ est le nombre total d'observations de la modalité y_j de y quelle que soit la modalité de x . C'est-à-dire $n_{.j} = \sum_{i=1}^k n_{ij}$.

Définition 1.3.2

Les l couples $(y_j, n_{.j})$ définissent la distribution marginale de caractère y .

La modalité y_j a pour effectif $n_{.j}$ et pour fréquence marginale $f_{.j} = \frac{n_{.j}}{N}$

$$\sum_{j=1}^l n_{.j} = N$$

Propriétés 1.3.1

— Le total des fréquences de la ligne i est donné par :

$$f_{i.} = \sum_{j=1}^l f_{ij}$$

— Le total des fréquences de la colonne j est donné par :

$$f_{.j} = \sum_{i=1}^k f_{ij}$$

— La somme des fréquences est égale à 1

$$\sum_{i=1}^k \sum_{l=1}^l f_{ij} = \sum_{i=1}^k f_{i.} = \sum_{l=1}^l f_{.j} = 1$$

Exemple: 1.3.1

Le tableau de contingence suivant donne la répartition de salariés d'une entreprise selon le nombre d'enfants à charge (caractère x) et les salaires mensuels qu'ils perçoivent en 1000 dhs (caractère y)

$x \backslash y$	[3, 5[	[5, 9[	[9, 11[	Total
1	18	10	6	34
2	14	8	4	26
3	12	6	2	20
Total	44	24	12	80

— $n_{32} = 6$

— $n_{2.} = 26$

— $n_{.2} = 24$

— $f_{22} = \frac{8}{80} = 0.1$

— $f_{3.} = \frac{20}{80} = 0.25$

— $f_{.1} = \frac{44}{80} = 0.55$

1.4 Distributions conditionnelles

Définition 1.4.1

La distribution des observations suivant les modalités du caractère y sachant que la variable x prend la modalité x_i , est appelée distribution conditionnelle de y pour $x = x_i$.

Pour ceci, il suffit d'extraire du tableau à double entrée la ligne correspondant à $x = x_i$. On obtient des fréquences conditionnelles, notée $f_{j/i}$, en divisant ces effectifs par $n_{i.}$.

$$f_{j/i} = \frac{n_{ij}}{n_{i.}}$$

Définition 1.4.2

La distribution des observations suivant les modalités de la variable x sachant que la variable y prend la modalité y_j , est appelée distribution conditionnelle de x pour $y = y_j$

Pour obtenir cette distribution, il suffit d'extraire du tableau à double entrée la colonne correspondant à $y = y_j$.

Les fréquences conditionnelles, notée $f_{i/j}$, sont données par :

$$f_{i/j} = \frac{n_{ij}}{n_{.j}}$$

Exemples: 1.4.1

En reprenant l'exemple précédent.

La distribution conditionnelle de y sachant $x = 1$ est

$y/x = 1$	$[3, 5[$	$[5, 9[$	$[9, 11[$	Total
n_{1j}	18	10	6	$n_{1.} = 34$

$f_{2/1} = \frac{n_{12}}{n_{1.}} = \frac{10}{34} = 0,2941$. Ceci signifie que parmi les salariés ayant un seul enfant 29.41%, ont un salaire entre 5000Dhs et 9000Dhs.

La distribution conditionnelle de y sachant $x = 3$ est

$y/x = 3$	$[3, 5[$	$[5, 9[$	$[9, 11[$	Total
n_{3j}	12	6	2	$n_{3.} = 20$

$f_{1/3} = \frac{n_{31}}{n_{3.}} = \frac{12}{20} = 0,6$. Ceci signifie que parmi les salariés ayant 3 enfants, 60% ont un salaire entre 3000Dhs et 5000Dhs.

La distribution conditionnelle de $x/y = [5, 9[$

$x/y = [5, 9[$	1	2	3	Total
n_{i2}	10	8	6	$n_{.2} = 24$

$f_{2/2} = \frac{n_{22}}{n_{.2}} = \frac{8}{24} = 0.3333$. Ce qui signifie que 33.33% des salariés ayant un salaire entre 5000Dhs et 9000 Dhs ont 2 enfants.

Propriétés 1.4.1

- $\sum_{i=1}^k f_{i/j} = \sum_{i=1}^k \frac{n_{ij}}{n_{.j}} = 1$
- $\sum_{j=1}^l f_{j/i} = \sum_{j=1}^l \frac{n_{ij}}{n_{i.}} = 1$

1.5 Indépendance statistique

Deux caractères statistiques x et y sont dits indépendants si :

$$\forall i, \forall j \quad f_{ij} = f_{i.} \times f_{.j}$$

ou, ce qui revient au même :

$$n_{ij} = \frac{n_{i.} \times n_{.j}}{N} \quad \forall i, \forall j$$

1.6 Paramètres d'une distribution statistique double

1.6.1 Paramètres des distributions marginales

Les paramètres marginales du caractère x se déterminent à partir de la distribution marginale de ce même caractère, c'est-à-dire à partir des k modalités x_i et des k effectifs marginaux $n_{i.}$

De façon similaire, les paramètres marginales de y s'obtiennent à partir de la distribution marginale de ce même caractère, c'est-à-dire à partir des l modalités y_j et des l effectifs marginaux $n_{.j}$. On peut ainsi définir :

Moyennes marginales

- La moyenne marginale de x :

$$\bar{x} = \frac{1}{N} \sum_{i=1}^k n_{i.} x_i = \sum_{i=1}^k f_{i.} x_i$$

- La moyenne marginale de y :

$$\bar{y} = \frac{1}{N} \sum_{j=1}^l n_{.j} y_j = \sum_{j=1}^l f_{.j} y_j$$

Variances marginales

— La variance marginale de x

$$V(x) = \sigma_x^2 = \frac{1}{N} \sum_{i=1}^k n_{i.}(x_i - \bar{x})^2 = \sum_{i=1}^k f_{i.}(x_i - \bar{x})^2 = \frac{1}{N} \sum_{i=1}^k n_{i.}x_i^2 - \bar{x}^2$$

— La variance marginale de y

$$V(y) = \sigma_y^2 = \frac{1}{N} \sum_{j=1}^l n_{.j}(y_j - \bar{y})^2 = \sum_{j=1}^l f_{.j}(y_j - \bar{y})^2 = \frac{1}{N} \sum_{j=1}^l n_{.j}y_j^2 - \bar{y}^2$$

Exemples: 1.6.1

Le tableau de contingence suivant donne la répartition de salariés d'une entreprise selon le nombre d'enfants à charge (caractère x) et les salaires mensuels qu'ils perçoivent en 1000 dhs (caractère y).

$y \backslash x$	[3, 5[	[5, 9[	[9, 11[	<i>totaux</i>
1	18	10	6	34
2	14	8	4	26
3	12	6	2	20
<i>Totaux</i>	44	24	12	80

Considérons la distribution marginale x

x	1	2	3	$N = n_{..}$
$n_{i.}$	34	26	20	80

— Le nombre moyen d'enfants à charge par salarié est $\bar{x} = 1.82$

— La variance marginale de x est $V(x) = 0.66$

— L'écart-type correspondant est $\sigma_x = 0.81$

Considérons la distribution marginale y

y	[3, 5[	[5, 9[	[9, 11[	$N = n_{..}$
$n_{.j}$	44	24	12	80

— Le salaire mensuel moyen perçu par salarié est $\bar{y} = 5.8$, soit 5800 dhs

— La variance marginale de y est $V(y) = 4.86$

— L'écart-type correspondant est $\sigma_y = 2.2$

1.6.2 Paramètres des distributions conditionnelles

Moyennes conditionnelles

- Les moyennes conditionnelles de x selon y

$$\bar{x}_j = \frac{1}{n_{.j}} \sum_{i=1}^k n_{ij} x_i = \sum_{i=1}^k f_{i/j} x_i \quad j = 1, \dots, l$$

- Les moyennes conditionnelles de y selon x

$$\bar{y}_i = \frac{1}{n_{i.}} \sum_{j=1}^l n_{ij} y_j = \sum_{j=1}^l f_{j/i} y_j \quad i = 1, \dots, k$$

Variances conditionnelles

- Les variances conditionnelles de x selon y

$$V_j(x) = \frac{1}{n_{.j}} \sum_{i=1}^k n_{ij} (x_i - \bar{x}_j)^2 = \frac{1}{n_{.j}} \sum_{i=1}^k n_{ij} x_i^2 - \bar{x}_j^2 \quad j = 1, \dots, l$$

- Les variances conditionnelles de y selon x

$$V_i(y) = \frac{1}{n_{i.}} \sum_{j=1}^l n_{ij} (y_j - \bar{y}_i)^2 = \frac{1}{n_{i.}} \sum_{j=1}^l n_{ij} y_j^2 - \bar{y}_i^2 \quad i = 1, \dots, k$$

Exemple: 1.6.1

La distribution conditionnelle de $x/y = [5, 9[$

$x/y = [5, 9[$	1	2	3	Total
n_{i2}	10	8	6	$n_{.2} = 24$

- $\bar{x}_2 = 1,833$: Les salariés avec un salaire entre 5000Dhs et 9000Dhs ont un nombre moyen des enfants égal à 1,833.
- $V_2(x) = 4 - \bar{x}_2^2 = 4 - (1,833)^2 = 0,6401$

La distribution conditionnelle de y sachant $x = 3$ est

$y/x = 3$	$[3, 5[$	$[5, 9[$	$[9, 11[$	Total
n_{3j}	12	6	2	$n_{3.} = 20$

- $\bar{y}_3 = 5,5$: Le salaire moyen des salariés avec 3 enfants est 5500Dhs.
- $V_3(y) = 34,3 - \bar{y}_3^2 = 4,05$.

1.7 Covariance

Lorsque l'on étudie des distributions à deux caractères quantitatifs, on cherche généralement à quantifier le lien entre ceux-ci. On est amené souvent à calculer la covariance. Ainsi que nous le verrons par la suite, cet indicateur servira dans l'étude de la corrélation entre deux variables.

x et y sont deux caractères quantitatifs .

Définition 1.7.1

La covariance entre x et y est le nombre réel donné par

$$Cov(x, y) = \frac{1}{N} \sum_{i=1}^k \sum_{j=1}^l n_{ij} (x_i - \bar{x})(y_j - \bar{y}).$$

Formule pratique de calcul :

$$Cov(x, y) = \frac{1}{N} \sum_{i=1}^k \sum_{j=1}^l n_{ij} x_i y_j - \bar{x} \bar{y}.$$

Dans le cas de N couples distincts (x_i, y_i) la covariance devient

$$Cov(x, y) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{N} \sum_{i=1}^N x_i y_i - \bar{x} \bar{y}$$

- $Cov(x, x) = Var(x)$; $Cov(y, y) = Var(y)$
- $Cov(x, y) = Cov(y, x)$
- si les caractères x et y sont indépendants, alors $cov(x, y) = 0$.

La réciproque est fausse


1.8 Régression linéaire

1.8.1 Notion d'ajustement


Définition 1.8.1

Diagramme de dispersion : c'est un diagramme utile pour visualiser la forme de la tendance qui peut exister entre les deux caractères.

On représente la distribution du couple (x, y) par un nuage de points de coordonnées (x_i, y_i) .



Le nuage de points nous renseigne sur la forme de la liaison statistique entre les deux caractères observés ainsi que sur l'intensité de cette liaison



Selon l'allure du nuage, on a envie de remplacer ce nuage par le graphe d'une fonction f . (la courbe $y = f(x)$) Cette opération s'appelle un ajustement. $y = ax + b$; $y = ax^b$; $y = a \ln x + b$

1.8.2 Régression linéaire

Exemple d'étude de la relation entre le taux d'investissement en pourcentage du PIB et taux de croissance économique en 2010.

Objectif :

- On souhaite savoir si le taux d'investissement en pourcentage du PIB a une influence sur taux de croissance économique et sous quelle forme cette influence peut être exprimée
- Le but est d'expliquer au mieux comment le taux de croissance économique varie en fonction de le taux d'investissement et éventuellement de prédire le taux d'investissement à partir de le taux d'investissement.
- Population : Pays du monde. Sur cette population, on considère deux variables
 - y : le taux de croissance économique ; c'est la variable à expliquer, appelée encore variable à régresser, variable réponse, variable dépendante.
 - x : le taux d'investissement en pourcentage du PIB : c'est la variable explicative, appelée également régresseur, variable indépendante.
- pour l'étude, On considère un échantillon de 26 pays tirés au sort.


x_i	y_i	x_i	y_i
15,39	2,45	23,18	5,15
17,91	2,72	23,73	5,32
18,07	2,87	24,07	4,68
18,15	2,95	24,37	5,95
18,58	2,11	25,34	4,64
18,97	2,50	28,08	6,91
19,20	2,03	29,20	5,22
20,92	5,04	30,24	7,82
21,22	4,96	31,57	7,70
21,64	5,84	31,76	7,74
21,72	5,44	32,22	7,72
21,93	5,62	33,57	9,53
22,11	6,03	43,15	9,67

- On cherche à exprimer la relation entre la variable le taux de croissance économique et la variable taux d'investissement à l'aide d'une fonction mathématique du type $y = f(x)$.

Graphiquement cela revient à représenter cette relation à l'aide d'une courbe (graphe de la fonction).

- Afin de mettre plus clairement en évidence et de quantifier la relation entre les deux variables, le taux d'investissement et le taux de croissance économique,

Pour choisir le modèle de relation, on représente les données graphiquement à l'aide d'un nuage de points.



- À cette fin, la méthode la plus utilisée consiste à ajuster le nuage de points par une droite (D),
- On parle de droite de régression ou de droite d'ajustement ou encore de droite des moindres carrés.
- La droite (D) ne passant pas par tous les points du nuage, il existe naturellement des écarts entre les points du nuage et les points situés sur cette droite.
- notons $\hat{y}_i$ l'ordonnée d'un point de la droite (D) dont l'abscisse est x_i et désignons par e_i les écarts entre la valeur observée y_i de y et la valeur $\hat{y}_i$ située sur la droite : $e_i = y_i - \hat{y}_i$
- L'expression de la droite de régression est alors donnée par : $\hat{y}_i = ax_i + b$, où a et b sont des constantes.
- il s'agit de trouver la droite (D) telle que les écarts e_i soient les plus faibles possibles : c'est-à-dire telle que les valeurs $\hat{y}_i$ situées sur la droite soient les plus proches possibles des valeurs observées y_i .

Afin de déterminer la valeur des paramètres (ou coefficients) a et b de la droite de régression, on applique le principe des moindres carrés ordinaires (MCO) consistant à minimiser la somme des

carrés des écarts. On cherche ainsi à minimiser l'expression suivante par rapport aux paramètres a et b :

$$\sum_{i=1}^N (y_i - ax_i - b)^2$$

1.8.3 L'équation de la droite de régression

La droite des moindres carrés ou droite de régression a pour équation :

$$y = ax + b$$

avec

$$a = \frac{Cov(x, y)}{V(x)}; \quad b = \bar{y} - a\bar{x}$$

Le paramètre a est la pente de la droite de régression de y sur x il mesure la variation de la variable dépendante lorsque la variable indépendante varie d'une unité. b désignant l'ordonnée à l'origine.

$$Cov(x, y) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{N} \sum_{i=1}^N x_i y_i - \bar{x}\bar{y}$$

En effet

On cherche à minimiser la fonction $f(a, b) = \sum_{i=1}^N (y_i - ax_i - b)^2$. A cette fin, on annule les dérivées partielles de $f(a, b)$ par rapport à a et b :

$$\frac{\partial f(a, b)}{\partial a} = -2 \sum_{i=1}^N (y_i - ax_i - b)x_i = 0$$

$$\frac{\partial f(a, b)}{\partial b} = -2 \sum_{i=1}^N (y_i - ax_i - b) = 0$$

On obtient :

$$\sum_{i=1}^N x_i y_i = a \sum_{i=1}^N x_i^2 + b \sum_{i=1}^N x_i \quad \sum_{i=1}^N y_i = a \sum_{i=1}^N x_i + Nb$$

En divisant $\sum_{i=1}^N y_i = a \sum_{i=1}^N x_i + Nb$ par N , il vient

$$\bar{y} = a\bar{x} + b \implies b = \bar{y} - a\bar{x}$$

En remplaçant b par son expression dans $\sum_{i=1}^N x_i y_i = a \sum_{i=1}^N x_i^2 + b \sum_{i=1}^N x_i$, on obtient

$$\sum_{i=1}^N x_i y_i = a \sum_{i=1}^N x_i^2 + (\bar{y} - a\bar{x}) \sum_{i=1}^N x_i$$

On trouve

$$\sum_{i=1}^N x_i y_i - \frac{1}{N} \sum_{i=1}^N x_i \sum_{i=1}^N y_i = a \left(\sum_{i=1}^N x_i^2 - \frac{1}{N} \left(\sum_{i=1}^N x_i \right)^2 \right)$$

Donc

$$NCov(x, y) = aNV(x) \implies a = \frac{Cov(x, y)}{V(x)}$$

Exemple: 1.8.1

Si on reprend l'exemple de la relation entre le taux d'investissement et le taux de croissance économique. On a

- $\bar{y} = 5.33$; $\bar{x} = 24.74$
- $V(x) = 39.11$
- $Cov(x, y) = 12.14$
- On trouve $a = \frac{12.14}{39.11} = 0.31$ et $b = -2.26$

D'où l'équation de la droite de régression est $y = 0.31x - 2.26$.

On constate ainsi que la valeur de a est positive, illustrant bien l'existence d'une relation positive entre les deux variables : lorsque le taux d'investissement augmente, la croissance augmente également.

1.8.4 Corrélation

Définition 1.8.2

On appelle coefficient de corrélation linéaire entre x et y le réel r défini par :

$$r = \frac{Cov(x, y)}{\sqrt{V(x)V(y)}}.$$

Remarques:

- On a toujours $-1 \leq r \leq 1$
- Le nuage des points (x_i, y_i) est une droite si, et seulement si : $r = 1$ (droite à pente positive) ou $r = -1$ (droite à pente négative).
- Si $|r|$ est voisin de 1, on dit qu'il existe une forte corrélation linéaire entre x et y .

Commentaires sur le coefficient de corrélation linéaire

- Un coefficient de corrélation linéaire égal à zéro n'implique pas nécessairement une absence de corrélation entre les deux variables étudiées. Il peut en effet exister une forte corrélation

non linéaire entre les variables, qui ne peut être prise en compte par une droite de régression.

- Une valeur élevée du coefficient de corrélation (proche de 1 en valeur absolue) n'implique pas nécessairement une forte dépendance entre les deux variables considérées. Il se peut en effet qu'une troisième variable agisse sur les deux variables étudiées, conduisant mécaniquement à une valeur élevée du coefficient de corrélation.

Les ventes de crèmes glacées et le nombre de noyades. Il serait incorrect de déduire, de l'observation d'une hausse des valeurs prises par ces deux variables durant l'été, l'existence d'une corrélation entre les deux séries. Ces deux variables ne sont en effet liées entre elles que par l'influence d'une troisième variable : la température, qui est plus élevée en été.

- Corrélation et causalité sont deux concepts différents qu'il convient de ne pas confondre : le calcul du coefficient de corrélation linéaire entre les variables x et y nous permet de dire si ces deux variables sont ou non liées entre elles, mais ne nous permet pas d'établir un lien de causalité. En d'autres termes, il ne permet pas de déterminer si x cause y ou si y cause x .

1.8.5 Qualité d'une régression

Même si r nous permet d'apprécier le degré de corrélation linéaire entre x et y , il est possible de recourir à un indicateur plus général permettant de mesurer l'intensité de la liaison entre deux variables. Cet indicateur, appelé coefficient de détermination.

On a

$$y_i - \bar{y} = (y_i - \hat{y}_i) + (\hat{y}_i - \bar{y})$$
$$\sum_{i=1}^N (y_i - \bar{y})^2 = \sum_{i=1}^N (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Variance totale = Variance expliquée + Variance résiduelle

$$V(y) = V(\hat{y}) + V(e)$$

$\hat{y}$: est la valeur située sur la droite de régression $\hat{y} = ax + b$, la valeur estimée de y .

$e = y - \hat{y}$ l'écart entre la valeur observée de y et $\hat{y}$. (appelé aussi résidu)

Définition 1.8.3

Le coefficient de détermination, noté R^2 , est défini comme le rapport entre la variance expliquée et

la variance totale :

$$R^2 = \frac{\text{Variance expliquée}}{\text{Variance totale}} = \frac{V(\hat{y})}{V(y)} = 1 - \frac{\text{Variance résiduelle}}{\text{Variance totale}} = 1 - \frac{V(e)}{V(y)}$$

Le coefficient de détermination mesure ainsi la part ou le pourcentage de variance expliquée par la régression. R^2 fournit une mesure du pouvoir explicatif de la régression. On a par construction :

$$0 \leq R^2 \leq 1.$$

Remarques:

- $R = 0$ signifie que la variance expliquée est nulle : la régression n'explique pas le nuage de points, les variables x et y ne sont pas liées entre elles.
- $R^2 = 1$: signifie que la régression explique parfaitement le lien entre x et y et la droite d'ajustement passe par tous les points du nuage.
- Plus la valeur de R^2 est proche de 1, plus la variance expliquée est proche de la variance totale et meilleure est la qualité de la régression.
- R^2 correspondant au carré du coefficient de corrélation linéaire entre x et y

$$R^2 = \frac{\text{Cov}(x, y)^2}{V(x)V(y)}$$

Exemple: 1.8.2

Le calcul du coefficient de détermination associé à la régression du taux de croissance sur le taux d'investissement nous donne :

$$R^2 = \frac{12.14^2}{39.11 \times 4.65} = 0.81$$

On en déduit que le taux d'investissement explique 81% de la variance du taux de croissance économique.

2.1 Introduction

L'analyse combinatoire est une branche des mathématiques qui étudie comment compter les objets. Elle fournit des méthodes de dénombrements particulièrement utiles en théorie des probabilités. Les probabilités dites combinatoires utilisent constamment les formules de l'analyse combinatoire développées dans ce chapitre. On souhaite répondre à la question suivante : combien y a-t-il de façons de construire un ensemble de p éléments pris dans un ensemble de n éléments. Ce nombre est différent selon que l'on autorise ou non les répétitions (prendre plusieurs fois le même élément) et que l'on tienne compte ou pas de l'ordre des éléments.

Soient deux éléments a et b :

Si $(a, b) \neq (b, a)$, on parle de disposition **ordonnée**

Si $(a, b) \equiv (b, a)$, on parle de disposition **non ordonnée**.

Soit n un entier positif ou nul. On appelle **factorielle** n , noté $n!$, le produit des nombres entiers

de 1 à n .

$$n! = 1 \times 2 \times \cdots \times n, \quad \text{si } n > 0, \quad n! = 1, \quad \text{si } n=0$$

2.2 Arrangements

Définition 2.2.1

Étant donné un ensemble E de n objets, on appelle **arrangements** de p objets **toutes suites ordonnées** de p objets pris parmi les n objets.

Le nombre d'arrangements de p objets pris parmi n est noté A_n^p

Remarque:

Deux arrangements de p objets sont donc distincts s'ils diffèrent par la nature des objets qui les composent ou par leur ordre dans la suite

Exemples: 2.2.1

1. Le nombre de mots de 5 lettres (avec ou sans signification) formés avec les 26 lettres de l'alphabet correspond au nombre d'arrangements possibles avec $p = 5$ et $n = 26$.
2. Le tiercé dans l'ordre d'une course de 20 chevaux constitue un des arrangements possibles avec $p = 3$ et $n = 20$.

Dans les exemples précédents, l'ordre des éléments dans la suite est essentiel. Ainsi pour le premier exemple, le mot NICHE est différent du mot CHIEN. Mais une lettre de l'alphabet peut se retrouver plusieurs fois alors que dans le deuxième exemple, les trois chevaux à l'arrivée sont forcément différents.

Il faut donc distinguer le nombre d'**arrangements avec répétition** et le nombre d'**arrangements sans répétition**.

Lorsque chaque objet ne peut être observé qu'**une seule fois** dans un arrangement, le nombre d'**arrangements sans répétition** de p objets pris parmi n est alors :

$$A_n^p = \frac{n!}{(n-p)!}, \quad 1 \leq p \leq n$$

Pour le premier objet tiré, il y a n manières de ranger l'objet parmi n .

Pour le second objet tiré, il n'existe plus que $n - 1$ manières de ranger l'objet car le premier objet

ne peut plus être pris en compte. On parle de **tirage sans remise**.

Ainsi pour les p objets tirés parmi n , si $1 \leq p \leq n$, il y aura :

$$A_n^p = n(n-1)(n-2) \dots (n-p+1)$$

$$A_n^p = \frac{n!}{(n-p)!}$$

Remarque:

On a nécessairement $1 \leq p \leq n$ et $n, p \in \mathbb{N}^*$. Si $n < p$, alors $A_n^p = 0$.

Lorsqu'un objet peut être observé **plusieurs fois** dans un arrangement, le nombre d'**arrangement avec répétition** de p objets pris parmi n , est alors :

$$A_n^p = n^p$$

Pour le premier objet tiré, il existe n manières de ranger l'objet parmi n .

Pour le second objet tiré, il existe également n possibilités d'arrangements car le premier objet fait de nouveau parti des n objets.

On parle de **tirage avec remise**.

Ainsi pour les p objets tirés, il y aura $n \times n \times n \times \dots \times n$ p fois arrangements possibles, soit

$$A_n^p = n \times n \times n \times \dots \times n = n^p$$

Exemples: 2.2.2

1. Combien de mots de 3 lettres peut-on écrire avec les 26 lettres de l'alphabet avec répétitions des lettres ?

Réponse : $26^3 = 17576$ mots possibles.

2. Un coach de sport doit choisir les 3 joueurs parmi 6 avec l'ordre de passage. Combien de choix a-t-il ?

Réponse : $A_6^3 = \frac{6!}{(6-3)!} = 120$ choix possibles.

2.3 Permutations

Définition 2.3.1

Étant donné un ensemble E de n objets, on appelle *permutations* de n objets distincts *toutes suites ordonnées* de n objets ou *tout arrangement n à n* de ces objets.

Le nombre de permutations de n objets est

$$P_n = A_n^n = n!$$

La permutation de n objets constitue un cas particulier d'*arrangement sans répétition* de n objets pris parmi n .

Exemple: 2.3.1

Le nombre de manières de placer 8 convives autour d'une table est $8! = 40320$ possibilités

Dans le cas où il existerait plusieurs répétitions k d'une même objet parmi les n objets, le nombre de permutations possibles des n objets doit être rapporté aux nombres de permutations des k objets identiques. Le nombre de permutations de n objets est alors $\frac{n!}{k!}$.

Plus généralement, il y a

$$\frac{n!}{n_1!n_2!\dots n_r!}$$

permutations différentes de n objets dont n_1 sont de type 1, n_2 sont de type 2, ..., et n_r sont de type r (avec $n_1 + \dots + n_r = n$).

Exemple: 2.3.2

Considérons le mot "CELLULE". Le nombre de mots possibles (avec ou sans signification) que l'on peut écrire en permutant ces 7 lettres est $\frac{7!}{2!3!} = 420$ mots possibles.

2.4 Combinaisons

Définition 2.4.1

Étant donné un ensemble E de n objets, on appelle *combinaison* de p objets *tout ensemble* de p objets pris parmi les n objets.

On distingue les *combinaisons avec répétitions* et les *combinaisons sans répétitions*. **Combinaisons sans répétitions**

combinaisons sans répétitions (sans remise) : ce sont les combinaisons que l'on peut faire avec p objets choisis parmi n , chacun d'eux ne peut figurer qu'une seule fois dans la même combinaison.

Le nombre de combinaisons de p objets pris parmi n est noté :

$$C_n^p = \frac{n!}{p!(n-p)!}$$

On a nécessairement $1 \leq p \leq n$ et $n, p \in \mathbb{N}^*$. Si $n < p$, alors $C_n^p = 0$.

Exemple: 2.4.1

1. Le tirage au hasard de 5 cartes dans un jeu de 32 est une combinaison avec $p = 5$ et $n = 32$.
2. La formation d'une délégation de 5 personnes parmi un groupe de 50 constitue une combinaison avec $p = 5$ et $n = 50$

Pour ces deux exemples, les objets tirés sont clairement distincts.

Combinaisons avec répétitions (avec remise)

Définition 2.4.2

Combinaisons avec répétitions ce sont les combinaisons que l'on peut faire avec p objets choisis parmi n objets, chacun d'eux peut figurer plusieurs fois dans la même combinaison.

Le nombre de combinaisons de p objets parmi n , avec remise, est

$$K_n^p = C_{n+p-1}^p = \frac{(n+p-1)!}{p!(n-1)!}$$

Quelques Propriétés de combinaison

- $C_n^n = 1$
- $C_n^0 = 1$
- $C_n^p = C_n^{n-p}$

Il revient au même de donner la combinaison des p objets choisis ou bien celle des $(n - p)$ qui ne le sont pas

Formule de Binôme de Newton Lorsque n est un entier naturel (positif), on a la formule du binôme de Newton :

$$(a + b)^n = \sum_{k=0}^n C_n^k a^{n-k} b^k$$

Exemples de comparaison

— Arrangements sans répétitions

Le nombre d'arrangements sans répétitions que l'on peut faire avec deux éléments choisis parmi trois éléments a, b, c est : $A_3^2 = \frac{3!}{(3-2)!} = 6$

Ces 6 arrangements sont : (a,b), (b,a), (a,c), (c,a), (b,c), et (c,b).

— Arrangements avec répétitions Le nombre d'arrangements avec répétitions que l'on peut faire avec deux éléments choisis parmi trois éléments a, b, c est : $3^2 = 9$.

Ces 9 arrangements sont : (a,a), (a,b), (b,a), (a,c), (c,a), (b,b), (b,c), (c,b) et (c,c).

— Permutations

Le nombre de permutations que l'on peut faire avec trois éléments a, b, c est : $3! = 3 \times 2 \times 1 = 6$.

Ces 6 permutations sont : (a,b,c), (a,c,b), (b,a,c), (b,c,a), (c,a,b), et (c,b,a).

— Combinaisons sans répétitions

Le nombre de combinaisons sans répétitions que l'on peut faire avec deux éléments choisis parmi trois éléments a, b, c est :

$$C_3^2 = \frac{3!}{2! \times 1!} = 3.$$

Ces 3 combinaisons sont : (a,b), (a,c), et (b,c).

— Combinaisons avec répétitions

Le nombre de combinaisons avec répétitions que l'on peut faire avec deux éléments choisis parmi trois éléments a, b, a est : $K_3^2 = C_{3+2-1}^2 = C_4^2 = 6$.

Ces 6 combinaisons sont : (a,a), (a, b), (a,c), (b,b), (b,c), et (c,c).

3.1 Introduction et Motivation

Les phénomènes observés dans le monde réel sont souvent marqués par des incertitudes et des imprécisions. Par exemple, un client peut ou non acheter un produit, une image peut être floue ou mal étiquetée, et une mesure peut être influencée par des erreurs de capteur. Ces incertitudes sont inhérentes aux systèmes que nous tentons de comprendre et de modéliser.

Le calcul des probabilités offre une manière formelle et rigoureuse de représenter ces incertitudes. Plutôt que de fournir une réponse unique, un modèle probabiliste génère une distribution de résultats possibles, permettant ainsi de mieux appréhender la variabilité et l'incertitude qui caractérisent les phénomènes observés. Cette approche est essentielle pour raisonner de manière statistique dans un contexte incertain.

Les outils fournis par la théorie des probabilités sont utilisés dans divers domaines pour soutenir l'analyse et la prise de décision. En particulier, ils servent de fondation pour plusieurs techniques statistiques, telles que :

L'estimation : Il s'agit du calcul de paramètres comme la moyenne, la variance ou des intervalles de confiance, qui donnent une idée précise de la dispersion et de la tendance centrale des données.

Les tests statistiques : Ces tests permettent de vérifier des hypothèses sur les données, en mesurant la probabilité que les résultats observés soient dus au hasard ou à des effets réels.

La prédiction probabiliste : Un exemple courant est l'évaluation de la probabilité qu'un email soit un spam, ce qui est une forme de prédiction basée sur des modèles probabilistes.

Les modèles d'apprentissage machine (Machine Learning, ML) intègrent ces outils statistiques pour quantifier la fiabilité des décisions prises à partir de données, en tenant compte des risques d'erreur et de l'incertitude associée aux prédictions.

Diagnostic médical automatisé

Un modèle d'IA reçoit des symptômes (fièvre, toux, perte d'odorat, etc.) et doit prédire la probabilité qu'un patient soit atteint d'une maladie donnée. Le modèle applique alors le théorème de Bayes :

$$P(\text{Maladie}|\text{Symptômes}) = \frac{P(\text{Symptômes}|\text{Maladie}) \times P(\text{Maladie})}{P(\text{Symptômes})}$$

Il tient compte de l'incertitude et du recouvrement des symptômes entre maladies. Ainsi, le modèle ne dit pas simplement "malade / non malade", mais "malade avec 87

Filtrage de spams dans les emails

Un système doit classer les e-mails en "spam" ou "non spam". Chaque mot du message est une variable aléatoire, et le modèle calcule :

$$P(\text{Spam}|\text{mots}) \propto P(\text{Spam}) \times \prod_i P(\text{mot}_i|\text{Spam})$$

Si le mot "gratuit" ou "gagner" apparaît souvent, la probabilité de spam augmente. Ainsi, le système est capable de filtrer intelligemment sans règles fixes, même lorsque de nouveaux mots apparaissent.

Détection de fraude bancaire

Une banque surveille des millions de transactions par carte. Certaines sont normales, d'autres frauduleuses. Par ailleurs, chaque transaction est décrite par des variables aléatoires (montant, heure, pays, fréquence).

Le modèle estime la probabilité :

Le modèle estime la probabilité :

$$P(\text{Fraude}|\text{caractéristiques})$$

Une transaction avec $P(\text{Fraude}) > 0.8$ est signalée pour vérification.

Cela permet une détection en temps réel et fiable, malgré l'incertitude et le volume énorme de données.

Véhicules autonomes

Une voiture autonome doit décider si un objet détecté est un piéton, un vélo ou une ombre. Le capteur perçoit des données bruitées (images floues, lumière changeante). Le modèle probabiliste (réseau bayésien, filtre de Kalman, etc.) estime :

$$\mathbb{P}(\text{piéton}|\text{image}, \text{capteurs})$$

Il ne prend pas de décision binaire mais probabiliste : "probabilité de piéton = 92% $\rightarrow$ freiner".

Recommandation de produits (E-commerce)

Amazon, Netflix ou Spotify veulent recommander des articles susceptibles de plaire à l'utilisateur. Le système apprend la probabilité conditionnelle :

$$\mathbb{P}(\text{Utilisateur aime l'article}|\text{Historique}, \text{profil})$$

Plus cette probabilité est élevée, plus le produit est mis en avant, ce qui permet des recommandations personnalisées et adaptatives, basées sur des modèles probabilistes.

Traitement du langage naturel (Chatbots, traduction)

Les modèles de langage comme ChatGPT prédisent la probabilité du mot suivant dans une phrase :

$$P(\text{mot}_{t+1} | \text{mot}_1, \dots, \text{mot}_t)$$

Le calcul des probabilités permet de générer des textes naturels et cohérents. Le modèle choisit les mots ayant la probabilité la plus élevée en fonction du contexte.

3.2 Notions sur les ensembles

Définition 3.2.1

Un ensemble est une collection des objets appelés éléments.

Remarque:

Un ensemble E formé des éléments a, b, c, d s'écrit conventionnellement sous la forme suivante :
 $E = \{a, b, c, d\}$.

Définitions 3.2.1

- Un ensemble F est une **partie** (ou est un sous-ensemble) de E si tous les éléments de F sont aussi des éléments de E .

On dit que F est inclus dans E , et on note $F \subset E$.

- On note $\emptyset$ l'ensemble vide : l'ensemble qui ne contient aucun élément.

Remarque:

La paire $E = \{1, 2\}$ n'a pas les mêmes propriétés que le couple $(1, 2)$, par exemple : $(1, 2) \neq (2, 1)$ mais $\{1, 2\} = \{2, 1\}$.


Définition 3.2.2

Les parties d'un ensemble E forment elles-mêmes un ensemble noté $\mathcal{P}(E)$. En particulier, E est un élément de $\mathcal{P}(E)$.

Exemple: 3.2.1

$$E = \{1, 3, 4\}$$

$$\mathcal{P}(E) = \{\emptyset, \{1\}, \{3\}, \{4\}, \{1, 3\}, \{1, 4\}, \{3, 4\}, E\}$$



Soient A et B deux sous-ensemble d'un ensemble E

Définition 3.2.3


L'ensemble de tous les éléments qui appartient à A et B est appelé *intersection* de A et B , noté $A \cap B$.

$$A \cap B = \{x \in E \mid x \in A \text{ et } x \in B\}$$

Définition 3.2.4

On dit que E et F sont *disjoints* si leur intersection est égale à l'ensemble vide


$$A \cap B = \emptyset.$$



Définition 3.2.5

L'ensemble de tous les éléments qui appartiennent à A ou B ou aux deux est appelé *union* de A et B , noté $A \cup B$.

$$A \cup B = \{x \in E \mid x \in A \text{ ou } x \in B\}$$




Définition 3.2.6

L'ensemble de tous les éléments de E qui n'appartiennent pas à A est le **complémentaire** de A dans E , noté $\bar{A}$ (ou A^c).

$$\bar{A} = \{x \in E \mid x \notin A\}$$

En particulier,


$$A \cap \bar{A} = \emptyset \quad \text{et} \quad A \cup \bar{A} = E.$$



Définition 3.2.7

L'ensemble de tous les éléments de A qui n'appartiennent pas à B est appelé **différence** de A et B , noté $A \setminus B$.

$$A \setminus B = \{x \in E \mid x \in A \text{ et } x \notin B\}$$



Propriétés 3.2.1

A, B et C des parties de l'ensemble E

- $A \cap \emptyset = \emptyset$; $A \cup \emptyset = A$; $A \cup A = A$
- $A \cup E = E$; $A \cap E = A$
- $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$
- $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
- $A = (A \cap B) \cup (A \cap \bar{B})$
- $A \cap \bar{B} = \bar{A} \cup \bar{B}$; $A \cup B = \bar{A} \cap \bar{B}$
- $A \setminus B = A \cap \bar{B} = A \setminus (A \cap B)$

Définition 3.2.8

Soit E un ensemble fini. Le cardinal de E , noté $\text{Card}(E)$ ou $|E|$, est le nombre d'éléments que contient E .

Exemple: 3.2.3

$E = \{2, 6, 7, 9\}$, $\text{Card}(E) = 4$

Proposition: 3.2.1

Soient E et F deux ensembles finis alors :

- $\text{Card}(E \cup F) = \text{Card}(E) + \text{Card}(F) - \text{Card}(E \cap F)$
- Si A et B deux parties de E alors $\text{Card}(A \setminus B) = \text{Card}(A) - \text{Card}(A \cap B)$
- Si $A \subset E$ alors $\text{Card}(\bar{A}) = \text{Card}(E) - \text{Card}(A)$

Définition 3.2.9

Le produit cartésien de deux ensembles E et F est l'ensemble de tous les couples (x, y) , où $x \in E$ et $y \in F$. On le note

$$E \times F = \{(x, y) \mid x \in E \text{ et } y \in F\}$$

Si $E = F$, alors on note $E \times E = E^2$.

Remarque:

Généralement $E \times F \neq F \times E$

3.3 Les concepts probabilistes

Définition 3.3.1

Une **expérience aléatoire** est une expérience renouvelable, en théorie ou en pratique, et qui, renouvelée dans des conditions identiques ne donne pas forcément le même résultat à chaque renouvellement.

Exemples: 3.3.1

- Lancer de pièce. Il est possible de répéter plusieurs fois un lancer de pièce dans les mêmes conditions : à chaque lancer, on n'obtiendra pas nécessairement le même résultat, i.e. 'pile' ou 'face'.
- Deux tirages à pile ou face.

Définition 3.3.2

L'**univers des possibles** (ou univers), noté Ω , est défini par l'ensemble de tous les résultats possibles qui peuvent être obtenus au cours d'une expérience aléatoire.

Remarque:

L'univers est appelé également l'espace des observables, ou encore l'espace échantillon.

Remarque:

On distingue les univers comprenant un nombre fini de résultats de ceux comprenant un nombre infini de résultats.

Parmi les univers infinis, on distingue les univers infinis non dénombrables des univers infinis dénombrables.

Par exemple, l'univers $\Omega = \{\omega_1, \dots, \omega_n, \dots\} = \{\omega_i, i \in \mathbb{N}\}$ est un univers infini dénombrable puisque l'on peut identifier chacun des éléments de Ω , même s'il en existe une infinité.

En revanche, $\Omega = \mathbb{R}$ ou $\Omega =]-\infty, a]$ sont des exemples d'univers infinis non dénombrables.

Dans le cas d'un univers fini, la taille de l'univers est appelée cardinalité et est représentée par l'opérateur $\text{card}(\Omega)$.

Exemples: 3.3.2

— On lance une pièce de monnaie. L'univers est

$$\Omega = \{\text{pile}, \text{face}\}$$

Le cardinal $\text{card}(\Omega) = 2$.

— On considère une expérience aléatoire correspondant au lancer d'un dé à 6 faces. L'univers (fini) des possibles est alors défini par :

$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

La cardinalité de cet univers est égale à 6, i.e. $\text{card}(\Omega) = 6$.

Définitions 3.3.1

- Un événement (ou une partie) A est un sous-ensemble de l'univers des possibles Ω , vérifiant $A \subset \Omega$.
- Un singleton (c'est-à-dire un événement réduit à un unique élément de Ω) est appelé événement élémentaire. Sinon on parle d'événement composite.

- On appelle Ω l'événement certain et $\emptyset$ l'événement impossible.
- Si A est un événement, on appelle $\bar{A}$ l'événement contraire de A .
- Si A, B sont deux événements,
 - on appelle $A \cap B$ l'événement " A et B " qui est réalisé dès que les événements A et B le sont ,
 - on appelle $A \cup B$ l'événement " A ou B " qui est réalisé dès que l'un au moins des événements A ou B l'est.
 - $A \subset B$ signifie que chaque fois que A est réalisé B l'est aussi.
 - si $A \cap B = \emptyset$, A et B sont dits incompatibles.

Exemple: 3.3.1

On considère une expérience aléatoire correspondant au lancer d'un dé à 6 faces, telle que $\Omega = \{1, 2, 3, 4, 5, 6\}$.

- L'événement "nombre pair", noté A , correspond au sous-ensemble de l'univers Ω défini par $A = \{2, 4, 6\}$.
- L'événement "nombre impair", noté B , correspond au sous-ensemble $B = \{1, 3, 5\}$.
- On peut en outre définir un autre événement C , sans lui attribuer un nom particulier, tel que $C = \{1, 5\}$ par exemple.
- L'événement $D = \{1\}$ est un événement élémentaire ou singleton.

Exemple: 3.3.2

Événements associés à un lancer de dé

Événement	Interprétation
$\{1\} \cup \{2\}$	On obtient 1 ou 2
$\{1\} \cap \{2\} = \emptyset$	On obtient 1 et 2 : événement impossible
$\{1\} \cup \{2\} \cup \{3\}$	On obtient 1, 2 ou 3
$\{1\} \cup \{2\} \cup \{3\} \cup \{4\} \cup \{5\} \cup \{6\}$	On obtient 1, 2, 3, 4, 5 ou 6 : événement certain

À partir d'événements combinés ou d'événements élémentaires (singletons), il est possible de définir des ensembles d'événements ou parties d'événements.

Exemple: 3.3.3

Pour un univers $\Omega = \{a, b, c\}$, on peut définir les événements $\{a\} \cup \{b\}$, $\{b\} \cap \{c\}$ ou $\{a\} \cup \{\{b\} \cap \{c\}\}$. À partir de ces événements et du singleton $\{c\}$, on peut alors construire un ensemble d'événements (ou partie) A tel que :

$$A = \left\{ \underbrace{\{a\} \cup \{b\}}_{\text{événement}}, \underbrace{\{b\} \cap \{c\}}_{\text{événement}}, \underbrace{\{a\} \cup \{\{b\} \cap \{c\}\}}_{\text{événement}}, \underbrace{\{c\}}_{\text{événement}} \right\}$$

Une notion essentielle est celle d'ensemble de tous les événements réalisables ou d'ensemble des parties. Cet ensemble recense tous les événements qu'il est possible de définir à partir de l'univers des résultats.

Définition 3.3.3

L'ensemble des parties, noté $\mathcal{P}(\Omega)$, correspond à l'ensemble de tous les événements réalisables à partir des événements élémentaires de l'univers Ω . Par convention $\Omega \in \mathcal{P}(\Omega)$ et $\emptyset \in \mathcal{P}(\Omega)$

Remarque:

Par convention, l'événement certain (univers) et l'ensemble des événements impossibles appartiennent toujours à l'ensemble des parties $\mathcal{P}(\Omega)$. Attention, il convient de ne pas confondre l'univers de tous les résultats possibles Ω et l'ensemble $\mathcal{P}(\Omega)$ de tous les événements que l'on peut définir à partir de Ω .

Exemple: 3.3.4

Considérons l'exemple d'un lancer de dé à trois faces. L'univers des résultats possibles est $\Omega = \{1, 2, 3\}$. L'ensemble de tous les événements réalisables $\mathcal{P}(\Omega)$ est donné par

$$\mathcal{P}(\Omega) = \{\emptyset, \{1\}, \{2\}, \{3\}, \{1, 2\}, \{1, 3\}, \{2, 3\}, \Omega\}$$

3.4 Tribu d'événements et espace probabilisable**Définition 3.4.1**

Une tribu sur l'univers Ω est un sous-ensemble d'événements ou de parties, notée $\mathcal{F}$, vérifiant :

1. $\mathcal{F} \subset \mathcal{P}(\Omega)$, $\Omega \in \mathcal{F}$ et $\emptyset \in \mathcal{F}$
2. L'ensemble $\mathcal{F}$ est stable par passage au complémentaire : $\forall A \in \mathcal{F}$ alors $\bar{A} \in \mathcal{F}$

3. L'ensemble $\mathcal{F}$ est stable par réunion dénombrable : pour toute suite d'événements $(A_n)_{n \in \mathbb{N}}$ appartenant à $\mathcal{F}$, l'union de ces événements appartient à l'ensemble $\mathcal{F}$.

$$(A_n)_{n \in \mathbb{N}} \in \mathcal{F} \text{ alors } \bigcup_{n \in \mathbb{N}} A_n \in \mathcal{F}.$$

Exemple: 3.4.1

Soit un univers $\Omega = \{1, 2, 3\}$, alors l'ensemble $\mathcal{F} = \{\emptyset, \{1\}, \{2, 3\}, \Omega\}$ est une tribu sur Ω .

Définition 3.4.2

Un *espace probabilisable* est un couple $(\Omega, \mathcal{F})$ où $\mathcal{F}$ est une tribu sur l'univers Ω .

Remarque:

Dans le cas d'un univers fini ou infini dénombrable, un espace probabilisable est donné par $(\Omega, \mathcal{P}(\Omega))$ puisque $\mathcal{P}(\Omega)$ est une tribu sur Ω .

3.5 Probabilités

3.5.1 Définition générale d'une probabilité

Définition 3.5.1

Soit $(\Omega, \mathcal{F})$ est un espace probabilisable. On appelle *probabilité* toute **application** $\mathbb{P}$ permettant d'associer à tout événement A un réel $\mathbb{P}(A)$ et vérifiant les axiomes suivants :

1. Pour tout événement A , on a $0 \leq \mathbb{P}(A) \leq 1$
2. $\mathbb{P}(\Omega) = 1$
3. Pour tout événement A et B incompatibles (disjoints), on a $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$

Plus généralement, pour toute suite d'événements disjoints $(A_n)_{n \in \mathbb{N}}$ de $\mathcal{F}$ on a :

$$\mathbb{P}\left(\bigcup_{n \in \mathbb{N}} A_n\right) = \sum_{n \in \mathbb{N}} \mathbb{P}(A_n)$$

Remarques:

1. Pour tout événement $A \in \mathcal{F}$, le nombre $\mathbb{P}(A)$ correspond à la probabilité de l'événement A .
2. Étant donné un espace probabilisable $(\Omega, \mathcal{F})$ et une probabilité $\mathbb{P}$ sur cet espace, le triplet $(\Omega, \mathcal{F}, \mathbb{P})$ est appelé *espace probabilisé*.

Exemple: 3.5.1

On considère l'expérience aléatoire qui consiste à lancer un dé à trois faces parfaitement équilibrées avec $\Omega = \{1, 2, 3\}$. L'ensemble des parties $\mathcal{P}(\Omega)$ est :

$$\mathcal{P}(\Omega) = \{\emptyset, \{1\}, \{2\}, \{3\}, \{1, 2\}, \{1, 3\}, \{2, 3\}, \Omega\}$$

Le couplet $(\Omega, \mathcal{P}(\Omega))$ est un espace probabilisable, on peut donc lui associer une mesure de probabilité $\mathbb{P} : \mathcal{P}(\Omega) \rightarrow [0, 1]$, telle que $\mathbb{P}(\{1\}) = \mathbb{P}(\{2\}) = \mathbb{P}(\{3\}) = \frac{1}{3}$.

Définition 3.5.2 (Probabilité uniforme)

Soit $\Omega = \{\omega_1, \omega_2, \dots, \omega_n\}$. Considérons l'application $\mathbb{P} : \mathcal{P}(\Omega) \rightarrow [0, 1]$, telle que pour tout $A \in \mathcal{P}(\Omega)$, $\mathbb{P}(A) = \frac{\text{Card}(A)}{\text{Card}(\Omega)}$.

$\mathbb{P}(\cdot)$ est une probabilité appelé *probabilité uniforme*.


La probabilité de A est alors donnée par le quotient du "nombre de cas favorables" par le "nombre de cas total".

Exemple: 3.5.2

Une entreprise emploie 36 personnes dont 12 femmes. Un salarié de cette entreprise est tiré au sort pour répondre à un sondage. On note par :

H : L'événement « l'individu tiré est un homme ».

F : L'événement « l'individu tiré est une femme ».



Exemple: 3.5.3

Une urne contient 3 boules noires et 4 boules rouges. On tire 2 boules simultanément sans remise.



On note par :

- **A** : l'événement «Les deux boules tirées sont rouges»
- **B** : l'événement «Les deux boules tirées sont noires»
- **C** : l'événement «Les deux boules tirées de même couleur»
- **D** : l'événement «Les deux boules tirées sont de couleurs différentes»

Calculer $\mathbb{P}(A)$, $\mathbb{P}(B)$, $\mathbb{P}(C)$ et $\mathbb{P}(D)$.

Le tirage s'effectue au hasard et simultanément sans remise de 2 boules. On note Ω l'univers des possibles. $\text{Card}(\Omega) = C_7^2 = 21$ possibilités.

- A : les deux boules tirées sont rouges parmi 4 boules donc $\text{Card}(A) = C_4^2$. Donc $\mathbb{P}(A) = \frac{\text{Card}(A)}{\text{Card}(\Omega)} = \frac{C_4^2}{C_7^2} = \frac{2}{7}$
- B : Les deux boules tirées sont noires parmi 3 boules donc $\text{Card}(B) = C_3^2$. Ainsi $\mathbb{P}(B) = \frac{C_3^2}{C_7^2} = \frac{1}{7}$.
- C : les deux boules tirées de même couleur (2 rouges et 2 noires), $\text{Card}(C) = C_4^2 + C_3^2$. Donc $\mathbb{P}(C) = \frac{\text{Card}(C)}{\text{Card}(\Omega)} = \frac{C_4^2 + C_3^2}{C_7^2} = \frac{3}{7}$

Remarque:

Soit Ω un univers contenant n éléments :

$$\Omega = \{\omega_1, \omega_2, \dots, \omega_n\}$$

Alors, toute application $\mathbb{P}$ définie par la donnée des n nombre positifs ou nuls $\mathbb{P}(\omega_1), \mathbb{P}(\omega_2), \dots, \mathbb{P}(\omega_n)$ tels que

$$\sum_{i=1}^n \mathbb{P}(\omega_i) = 1$$

détermine d'une manière unique une probabilité sur Ω

3.5.2 Conséquences des axiomes de probabilité

Soient A et B deux événements associés à une expérience aléatoire.. Nous avons les résultats suivants :

Propriété 3.5.1

1. $\mathbb{P}(\emptyset) = 0$

2. $\mathbb{P}(\bar{A}) = 1 - \mathbb{P}(A)$
3. $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$
4. Si $A \subset B \implies \mathbb{P}(A) \leq \mathbb{P}(B)$
5. Si $A \subset B$ alors $\mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A)$

3.6 Probabilités conditionnelles

Définition 3.6.1

Soient A et B deux événements, tels que $\mathbb{P}(B) > 0$. On appelle probabilité conditionnelle la probabilité qu'un événement A se produise sachant que l'événement B s'est déjà produit. On la note $\mathbb{P}(A|B)$ ou $\mathbb{P}_B(A)$ et

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

Lemme: 3.6.1

Soit B un événement tel que $\mathbb{P}(B) > 0$. Alors l'application $\mathbb{P}(.|B)$ est une probabilité sur Ω .

Remarque:

Étant donnés deux événements A et B , nous avons

$$\mathbb{P}(A \cap B) = \begin{cases} \mathbb{P}(B)\mathbb{P}(A|B) & \text{si } \mathbb{P}(B) > 0 \\ \mathbb{P}(A)\mathbb{P}(B|A) & \text{si } \mathbb{P}(A) > 0 \\ 0 & \text{autrement} \end{cases}$$

Exemple: 3.6.1

Considérons une urne contenant deux boules blanches et trois boules noires. Nous effectuons un premier tirage d'une boule sans remise et nous obtenons une boule blanche. Nous appelons B cet événement. Maintenant, nous effectuons un second tirage d'une boule et nous notons par A et C les deux événements suivants :

A : le second tirage donne une boule noire

C : le second tirage donne une boule blanche

Nous avons donc $\mathbb{P}(A|B) = \frac{3}{4}$ et $\mathbb{P}(C|B) = \frac{1}{4}$.

Exemple: 3.6.2

Dans une certaine population, il y a 45 % de fumeurs et 35 % de personnes atteintes de bronchite. Sachant que parmi les fumeurs il y a 65 % de bronchiteux, calculer la probabilité pour qu'une personne atteinte de bronchite soit fumeur.

Notons les événements : F : « c'est un fumeur » ; B : « c'est un bronchiteux »

les hypothèses s'écrivent : $\mathbb{P}(F) = 0.45$, $\mathbb{P}(B) = 0.35$ et $\mathbb{P}(B|F) = 0.65$.

Alors,

$$\mathbb{P}(F|B) = \frac{\mathbb{P}(F \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(F)\mathbb{P}(B|F)}{\mathbb{P}(B)} = \frac{0.45 \times 0.65}{0.35} = 0.8357$$

3.7 Indépendance d'événements

Soient A et B deux événements associés à une expérience aléatoire.

Définition 3.7.1

On dit que les événements A et B sont indépendants par rapport à la probabilité $\mathbb{P}$ si :

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \times \mathbb{P}(B)$$

Remarque:

Il est important de noter que la définition de l'indépendance est donc relative à une probabilité $\mathbb{P}$. Les événements A et B sont indépendants pour une certaine probabilité. Pour une autre probabilité, ils peuvent ne pas être indépendants. Par ailleurs, deux événements peuvent être indépendants dans une expérience aléatoire, et non indépendants dans une autre.

Remarque:

Si A et B sont indépendants c'est-à-dire : $\mathbb{P}(A \cap B) = \mathbb{P}(A) \times \mathbb{P}(B)$. Alors, $\mathbb{P}(A|B) = \mathbb{P}(A)$ et $\mathbb{P}(B|A) = \mathbb{P}(B)$ ça veut dire que la réalisation d'un événement n'affecte pas la réalisation du second.

Exemple: 3.7.1

Nous jetons un dé équilibré, et nous considérons les deux événements suivants :

A = " le résultat est pair "

et

B = " le résultat est au moins égale à 5 ".

En considérant, $\Omega = \{1, 2, 3, 4, 5, 6\}$, nous avons donc $A = \{2, 4, 6\}$ et $B = \{5, 6\}$. D'où $A \cap B = \{6\}$, $\mathbb{P}(A) = \frac{1}{2}$, $\mathbb{P}(B) = \frac{1}{3}$, et $\mathbb{P}(A \cap B) = \frac{1}{6}$.

Par conséquent, $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$. Donc A et B sont indépendants et pourtant $A \cap B \neq \emptyset$.

Proposition: 3.7.1

Si A et B sont deux événements indépendants alors il en est de même pour $\bar{A}$ et B , A et $\bar{B}$, et $\bar{A}$ et $\bar{B}$.

3.8 Formule de Bayes

Définition 3.8.1

Une famille d'événements $(B_i)_{i \in I}$, I fini ou dénombrable, forme un système complet d'événements (partition) de l'univers Ω si :

$$B_i \cap B_j = \emptyset, \text{ pour tout } i \neq j, \text{ et } \bigcup_{i \in I} B_i = \Omega$$

Théorème 3.8.1 (Loi de la probabilité totale)

Soit $(B_i)_{i \in I}$ un système complet tel que $\mathbb{P}(B_i) > 0$, pour tout $i \in I$, et soit un événement A , alors

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(A|B_i)\mathbb{P}(B_i).$$

Exemple: 3.8.1

Une population animale comporte $\frac{1}{3}$ de mâles et $\frac{2}{3}$ de femelles. L'albinisme frappe 6% des mâles et 0.36% des femelles. Notons que $A = \{\text{Mâle}\}$ et $\bar{A} = \{\text{Femelle}\}$ constitue un système complet d'événements. et on considère les événements $B = \{\text{Albinos}\}$ et $\bar{B} = \{\text{Non albinos}\}$. D'après loi de probabilité totale,

on a la probabilité pour qu'un individu pris au hasard (dont on ignore le sexe) soit albinos est

$$\mathbb{P}(B) = \mathbb{P}(B|A)\mathbb{P}(A) + \mathbb{P}(B|\bar{A})\mathbb{P}(\bar{A})$$

$$\mathbb{P}(B) = 0.06 \times \frac{1}{3} + 0.0036 \times \frac{2}{3} = 0.0224$$

soit **2.24%** d'albinos dans cette population.

Théorème 3.8.2 (Formule de Bayes)

Soit $(B_i)_{i \in I}$ un système complet tel que $\mathbb{P}(B_i) > 0$, pour tout $i \in I$, et soit un événement A , si $\mathbb{P}(A) > 0$, alors

$$\mathbb{P}(B_i|A) = \frac{\mathbb{P}(A|B_i)\mathbb{P}(B_i)}{\sum_{j \in I} \mathbb{P}(A|B_j)\mathbb{P}(B_j)}.$$

Remarque:

La formule de Bayes est utilisée de façon classique pour calculer des *probabilités de causes* dans des diagnostics (maladies, pannes, etc).

Exemple: 3.8.2

Dans une population pour laquelle 1 habitant sur 100 est atteint d'une maladie génétique A , on a mis au point un test de dépistage. Le résultat du test est soit positif (T) soit négatif ($\bar{T}$). On sait que : $\mathbb{P}(T|A) = 0.8$ et $\mathbb{P}(\bar{T}|\bar{A}) = 0.9$.

On soumet un patient au test. Celui-ci est positif. Quelle est la probabilité que ce patient soit atteint de la maladie A c'est-à-dire $\mathbb{P}(A|T)$?

D'après la formule de Bayes :

$$\mathbb{P}(A|T) = \frac{\mathbb{P}(T|A)\mathbb{P}(A)}{\mathbb{P}(T|A)\mathbb{P}(A) + \mathbb{P}(T|\bar{A})\mathbb{P}(\bar{A})}$$

Or, $\mathbb{P}(T|\bar{A}) = 1 - \mathbb{P}(\bar{T}|\bar{A})$ et $\mathbb{P}(\bar{A}) = 1 - \mathbb{P}(A)$ d'où,

$$\mathbb{P}(A|T) = \frac{0.8 \times 0.01}{0.8 \times 0.01 + 0.1 \times 0.99} = 0.075$$


Ainsi *avant le test*, la probabilité d'être malade était de $\mathbb{P}(A) = 0.01$ et *après le test* la probabilité d'être malade est de $\mathbb{P}(A|T) = 0.075$. Ainsi le test apporte un supplément d'information.

Variables aléatoires discrètes et lois de Probabilités

4.1 Introduction aux variables aléatoires

Définition 4.1.1

Étant donné un univers Ω muni d'une probabilité $\mathbb{P}$. On appelle **variable aléatoire**, toute application X permettant d'associer à chaque événement élémentaire ω une valeur numérique $X(\omega)$



variable X pour l'évènement élémentaire ω

Remarque:

Une variable aléatoire réelle X est un caractère quantitatif, discret ou continu, dont la valeur est fonction du


La valeur x correspond à la **réalisation** de la **résultat de l'expérience**.

L'ensemble des réalisations de X sera désigné par $X(\Omega) = \{x_i/x_i = X(\omega), \omega \in \Omega\}$

Exemple Si on lance une pièce de monnaie 3 fois de suite. Alors l'univers est

$$\Omega = \{FFF; FFP; FPF; PFF; PPP; PPF; PFP; FPP\}$$

X = Le nombre de faces obtenues



4.2 Variables aléatoires discrètes

Définition 4.2.1

Une *variable aléatoire* est dite *discrète* si elle ne prend que des valeurs discontinues dans un intervalle donné.



Exemples: 4.2.1

- Nombre de clients arrivant dans un magasin en une heure,
- Nombre de clients dans une file d'attente : Si un serveur traite des demandes, une variable aléatoire discrète pourrait être utilisée pour décrire le nombre de clients qui attendent à un moment donné. Cette variable peut prendre des valeurs de 0 à n , où n est le nombre maximum de clients que le système peut gérer à la fois.
- Nombre de paquets dans un réseau : Lors de la simulation de réseaux, une variable aléatoire discrète peut être utilisée pour décrire le nombre de paquets arrivant à un routeur à un instant donné. Le nombre de paquets pourrait être un nombre entier entre 0 et un maximum défini.
- Choix aléatoire d'un produit à recommander Sur une plateforme de commerce en ligne, une recommandation de produit peut être faite de manière aléatoire parmi une liste de 10 produits. La variable aléatoire discrète représente le produit recommandé, qui peut être une valeur entre 1 et 10.

Application : Le site utilise cette variable pour suggérer des produits au hasard à l'utilisateur.

Sont des variables aléatoires discrètes.

Exemple 2 On lance deux dés. On note X l'application qui, à chaque lancer, on associe la somme des résultats obtenus



Une variable aléatoire est caractérisée par l'ensemble des valeurs qu'elle peut prendre et par l'expression mathématique de la probabilité de ces valeurs. Cette expression s'appelle **la loi de probabilité** (ou **distribution de probabilité**) de la variable aléatoire.

Soit X une variable aléatoire discrète définie sur un espace probabilisé $(\Omega, \mathbb{P})$.

$$X(\Omega) = \{x_1, x_2, x_3, \dots, x_{n-1}, x_n, \dots\}$$

Définition 4.2.2

On appelle **loi de probabilité** ou **fonction de distribution** de X , l'application qui, à chaque valeur possible x_i de la variable aléatoire X associe la probabilité $\mathbb{P}(X = x_i)$

Remarques:

1. Les quantités $\mathbb{P}(X = x_i)$ représentent les probabilités des événements définis par : $(X = x_i) = \{\omega \in \Omega : X(\omega) = x_i\}$
2. La loi de probabilité d'une variable aléatoire discrète est entièrement déterminée par les probabilités $\mathbb{P}(X = x_i) = p_i$.
3. Toute loi de probabilité vérifie la propriété suivante :

$$\sum_i \mathbb{P}(X = x_i) = 1.$$

Exemple On jette deux dés équilibrés et on s'intéresse à $X =$ "somme des deux numéros obtenus".

$$\begin{aligned} \Omega &= \{(1, 1), (1, 2), \dots, (6, 5), (6, 6)\} & \{2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12\} & \mathbb{P}(X = 2) = \\ X : \Omega &\rightarrow \mathbb{R} & \mathbb{P}(\{(1, 1)\}) &= \frac{1}{36} \\ (\omega_1, \omega_2) &\mapsto \omega_1 + \omega_2 & \mathbb{P}(X = 4) &= \mathbb{P}(\{(1, 3), (2, 2), (3, 1)\}) = \frac{3}{36} \end{aligned}$$

Les valeurs possibles de X , $X(\Omega) =$

$X(\Omega) (x_i)$	2	3	4	5	6	7	8	9	10	11	12
$\mathbb{P}(X = x_i)$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{3}{36}$	$\frac{4}{36}$	$\frac{5}{36}$	$\frac{6}{36}$	$\frac{5}{36}$	$\frac{4}{36}$	$\frac{3}{36}$	$\frac{2}{36}$	$\frac{1}{36}$

Remarque:

Exemple: 4.2.1

On jette deux dés équilibrés.

$$\begin{aligned} \Omega &= \{(1, 1), (1, 2), \dots, (6, 5), (6, 6)\} & \text{Les valeurs possibles de } Y, & Y(\Omega) = \\ Y : \Omega &\rightarrow \mathbb{R} & \{1, 2, 3, 4, 5, 6\} & \\ (\omega_1, \omega_2) &\mapsto \max(\omega_1, \omega_2) & & \end{aligned}$$

$Y(\Omega) (x_i)$	1	2	3	4	5	6
$\mathbb{P}(Y = x_i)$	$\frac{1}{36}$	$\frac{3}{36}$	$\frac{5}{36}$	$\frac{7}{36}$	$\frac{9}{36}$	$\frac{11}{36}$

$$\sum_{i=1}^6 \mathbb{P}(Y = x_i) = 1$$

4.3 Fonction de répartition

Définition 4.3.1

On appelle *fonction de répartition* (ou *fonction de distribution cumulative*) de X , l'application F_X qui, à chaque réel t , associe la probabilité pour que la variable X prenne une valeur inférieure ou égale à t

$$\begin{aligned} F_X &: \mathbb{R} \rightarrow [0, 1] \\ t &\mapsto \mathbb{P}(X \leq t) \end{aligned}$$

Remarque:

On dit que deux variables aléatoires X et Y ont la *même loi* si elles ont la même fonction de répartition $F_X = F_Y$.

Propriétés de la fonction de répartition Soit F_X la fonction de répartition d'une variable aléatoire discrète X alors :

- $\forall t \in \mathbb{R}, 0 \leq F_X(t) \leq 1$
- F_X est croissante sur $\mathbb{R}$
- $\lim_{t \rightarrow -\infty} F_X(t) = 0$ et $\lim_{t \rightarrow +\infty} F_X(t) = 1$

Si X est une variable aléatoire discrète à valeurs dans $\{x_1, x_2, \dots, x_n\}$ avec $x_1 < \dots < x_n$ alors pour $t \in \mathbb{R}$

$$F_X(t) = \sum_{i=1}^k \mathbb{P}(X = x_i), \text{ avec } k \text{ tel que } x_k \leq t < x_{k+1}$$

Exemples: 4.3.1

Reprenons les deux exemples précédents

1. Les valeurs possibles de X , $X(\Omega) = \{2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12\}$

$X(\Omega) (x_i)$	2	3	4	5	6	7	8	9	10	11	12
$\mathbb{P}(X = x_i)$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{3}{36}$	$\frac{4}{36}$	$\frac{5}{36}$	$\frac{6}{36}$	$\frac{5}{36}$	$\frac{4}{36}$	$\frac{3}{36}$	$\frac{2}{36}$	$\frac{1}{36}$
F_X	$\frac{1}{36}$	$\frac{3}{36}$	$\frac{6}{36}$	$\frac{10}{36}$	$\frac{15}{36}$	$\frac{21}{36}$	$\frac{26}{36}$	$\frac{30}{36}$	$\frac{33}{36}$	$\frac{35}{36}$	1

2. Les valeurs possibles de Y , $Y(\Omega) = \{1, 2, 3, 4, 5, 6\}$

$Y(\Omega) \ (x_i)$	1	2	3	4	5	6
$\mathbb{P}(Y = x_i)$	$\frac{1}{36}$	$\frac{3}{36}$	$\frac{5}{36}$	$\frac{7}{36}$	$\frac{9}{36}$	$\frac{11}{36}$
F_Y	$\frac{1}{36}$	$\frac{4}{36}$	$\frac{9}{36}$	$\frac{16}{36}$	$\frac{25}{36}$	1

Exemple On lance une pièce de monnaie 3 fois de suite. On introduit une variable aléatoire $X(\omega)$: "nombre de piles de l'événement ω ". La loi de probabilité de X est La loi de probabilité de


X est :

x_i	0	1	2	3
$\mathbb{P}(X = x_i)$	$\frac{1}{8}$	$\frac{3}{8}$	$\frac{3}{8}$	$\frac{1}{8}$

La fonction de répartition F associée à X est donnée par :

$$F(x) = \begin{cases} 0 & \text{si } x \in]-\infty, 0[\\ \frac{1}{8} & \text{si } x \in [0, 1[\\ \frac{1}{8} + \frac{3}{8} = \frac{4}{8} = \frac{1}{2} & \text{si } x \in [1, 2[\\ \frac{1}{8} + \frac{3}{8} + \frac{3}{8} = \frac{7}{8} & \text{si } x \in [2, 3[\\ \frac{1}{8} + \frac{3}{8} + \frac{3}{8} + \frac{1}{8} = 1 & \text{si } x \in [3, +\infty[\end{cases}$$

La représentation de la fonction de répartition F :



4.4 Paramètres d'une variable aléatoire discrète

4.4.1 Espérance Mathématique

Espérance Mathématique Soit X une variable aléatoire discrète définie sur un espace probabilisé $(\Omega, \mathbb{P})$. On note par

$$X(\Omega) = \{x_1, x_2, \dots, x_{n-1}, x_n, \dots\}$$

Définition 4.4.1

On appelle *l'espérance mathématique* de X , la valeur que l'on s'attend à trouver, en moyenne, si l'on répète un grand nombre de fois la même expérience aléatoire. Elle se note par $E(X)$, et se lit « espérance de X » :

$$E(X) = \sum_i x_i \mathbb{P}(X = x_i)$$

Remarque:

Lorsque le nombre de valeurs possibles de la variable aléatoire X est fini ($\text{Card}(X(\Omega)) < \infty$), l'espérance de X est donc la *moyenne arithmétique* des valeurs de X pondérées par leur probabilités.

Propriété: 1

Soient X et Y deux variables aléatoires, alors

- $E(X + Y) = E(X) + E(Y)$
- $E(\alpha X + \beta) = \alpha E(X) + \beta, \forall \alpha, \beta \in \mathbb{R},$

Exemple: 4.4.1

On reprend l'exemple de lancer de deux dés. On note par X "la somme des résultats obtenus"

$$\begin{aligned} E(X) &= 2 \times \frac{1}{36} + 3 \times \frac{2}{36} + 4 \times \frac{3}{36} + 5 \times \frac{4}{36} + 6 \times \frac{5}{36} + 7 \times \frac{6}{36} \\ &\quad + 8 \times \frac{5}{36} + 9 \times \frac{4}{36} + 10 \times \frac{3}{36} + 11 \times \frac{2}{36} + 12 \times \frac{1}{36} \\ &= 7 \end{aligned}$$

4.4.2 Variance**Définition 4.4.2**

On appelle **variance** de X , qu'on note par $V(X)$, la valeur définie par :

$$V(X) = E([X - E(X)]^2) = \sum_i (x_i - E(X))^2 \mathbb{P}(X = x_i).$$

Elle mesure la tendance de X à la dispersion autour de son espérance.

Remarque:

Pour le calcul numérique de la variance, on utilise souvent la formule suivante :

$$V(X) = E(X^2) - E(X)^2 = \sum_i x_i^2 \mathbb{P}(X = x_i) - E(X)^2$$

Propriété: 2

Soit X une variable aléatoire discrète et α et β deux réels. Alors on a $V(\alpha X + \beta) = \alpha^2 V(X)$.

Exemple: 4.4.2

Dans l'exemple précédent $V(X) = 54.83 - 49 = 5.83$

4.4.3 L'écart-type**Définition 4.4.3**

On appelle **écart-type** de X , qu'on note par σ_X , la racine carrée de la variance

$$\sigma_X = \sqrt{V(X)}$$

L'écart-type mesure également la tendance à la dispersion de la variable aléatoire, et ce dans les mêmes unités que celle des x_i .

Application Une petite agence loue des voitures à la journée. Elle dispose d'un parc de 6 véhicules. On introduit X : "le nombre de voiture louées par jour"
Après une étude sur une grande période, le responsable a établi que la loi de la variable aléatoire X est donnée par le tableau suivant :

x_i	0	1	2	3	4	5	6
$\mathbb{P}(X = x_i)$	0.05	0.10	0.37	0.27	0.17	0.03	0.01

1. Déterminer l'espérance, la variance et l'écart type de X .
2. Le bénéfice B (en dirhams) rapporté par la location des voitures est $B = 450X - 375$.

Déterminer l'espérance, la variance et l'écart type de B .

$E(X) = 2.54$ voitures/ jour, $V(X) = 1.3884$ et $\sigma_X = 1.18$ voitures/ jour

4.5 Indépendance de variables aléatoires

Définition 4.5.1

Deux variables aléatoires $X : \Omega \rightarrow \{x_1, x_2, \dots, x_n, \dots\}$ et $Y : \Omega \rightarrow \{y_1, y_2, \dots, y_m, \dots\}$ sont indépendantes si pour tous i et j

$$\mathbb{P}(X = x_i, Y = y_j) = \mathbb{P}(X = x_i) \times \mathbb{P}(Y = y_j)$$

4.6 Lois discrètes

4.6.1 Loi uniforme

Définition 4.6.1

On dit qu'une variable aléatoire X suit une loi *uniforme discrète* lorsque toutes les valeurs prises par X sont *équiprobables*. Si $X(\Omega) = \{1, 2, \dots, n\}$ est l'ensemble des valeurs prises par X , alors

$$\mathbb{P}(X = i) = \frac{1}{n}, \quad \forall i$$

Les paramètres de X sont :

$$E(X) = \frac{n+1}{2}; \quad V(X) = \frac{n^2-1}{12}$$

Exemple: 4.6.1

Soit La variable aléatoire X donnant le nombre obtenu lors d'un lancer d'un dé équilibré, suit une loi uniforme

$$\mathbb{P}(X = 1) = \mathbb{P}(X = 2) = \mathbb{P}(X = 3) = \mathbb{P}(X = 4) = \mathbb{P}(X = 5) = \mathbb{P}(X = 6) = \frac{1}{6}$$

4.6.2 Loi de Bernoulli

Définition 4.6.2

Soit une variable aléatoire discrète. On dit que X suit une loi de **Bernoulli** de paramètre p , si et seulement si, l'ensemble des valeurs possible de X est réduit à $\{0, 1\}$ ($X(\Omega) = \{0, 1\}$) et sa loi de probabilité est définie par :

$$\mathbb{P}(X = 0) = q = (1 - p) \text{ et } \mathbb{P}(X = 1) = p$$

Remarque:

Une variable aléatoire discrète de **Bernoulli** modélise souvent le résultat d'une épreuve aléatoire (dite **épreuve de Bernoulli**) n'ayant que **deux issues possibles** :

- L'une, appelée « succès », a la probabilité p de se réaliser ;
- L'une, appelée « échec », a la probabilité q de se réaliser ;

Les valeurs caractéristiques d'une variable aléatoire discrète X qui suit une loi de **Bernoulli** sont données par : $X \sim \mathcal{B}(p)$

$$E(X) = p, \quad V(X) = pq = p(1 - p)$$

Exemple: 4.6.2

On prélève au hasard un échantillon d'une pièce d'un lot important de pièces fabriquées dont 3 % de pièces sont défectueuses. On pose : $X = 1$ si la pièce obtenu est défectueuse et $X = 0$ sinon. $X(\Omega) = \{0, 1\}$. On a $\mathbb{P}(X = 1) = 0.03$ et $\mathbb{P}(X = 0) = 0.97$.

La variable aléatoire $X \sim \mathcal{B}(0.03)$ D'autre part,

$$E(X) = 0.03, \quad V(X) = 0.0291, \quad \sigma = \sqrt{0.0291} = 0.17$$

4.6.3 Loi Binomiale

La loi binomiale est une loi de probabilité discrète définie sur le $X(\Omega) = \{0, 1, \dots, n\}$. Cette loi correspond à une expérience aléatoire dans laquelle on répète n fois de manière indépendante une expérience de Bernoulli avec une probabilité de succès égale à p . On compte alors le nombre de succès, c'est-à-dire le nombre de fois où la réalisation de la variable de Bernoulli est égale à 1. Le nombre total de succès, noté X , est une variable aléatoire admettant une distribution binomiale de paramètres n et p .

Définition 4.6.3

Soit X une variable aléatoire discrète. On dit que X suit une loi **Binomiale** de paramètres n et p , si et seulement si, l'ensemble des valeurs possible de X est $\{0, 1, \dots, n\}$ ($X(\Omega) = \{0, 1, \dots, n\}$) et sa loi de probabilité est définie par :

$$\mathbb{P}(X = k) = C_n^k p^k q^{n-k}; \quad \forall k \in \{0, \dots, n\}$$

Remarque:

Une variable aléatoire discrète Binomiale de paramètres n et p , modélise souvent le résultat d'une épreuve aléatoire de n tirage avec remise dont l'objectif est de compter le nombre de succès :

- n : le nombre de tirages ;
- p : la probabilité de succès au cours de chacune des n tirages.

On note $X \sim \mathcal{B}(n, p)$.

Les valeurs caractéristiques d'une variable aléatoire discrète X qui suit une loi de Binomiale sont données par :

$$E(X) = np; \quad V(X) = npq$$

Exemple: 4.6.3

On prélève au hasard un échantillon (tirage successif avec remise) de 7 pièces d'un lot important de pièces fabriquées dont 3 % de pièces sont défectueuses. On pose :

X = le nombre de pièces défectueuses obtenu

Alors, la variable aléatoire $X \sim \mathcal{B}(7, 0.03)$.

$$X(\Omega) = \{0, 1, \dots, 7\}$$

$$\mathbb{P}(X = k) = C_7^k p^k q^{7-k}$$

$$E(X) = np = 0.21, \quad V(X) = npq = 0.20$$

Exemple: 4.6.4

Grâce aux tarifs réduits de toutes sortes, 90 % des voyageurs de la compagnie de transport bénéficient de tarifs réduites. Chaque soir, un contrôleur prend les billets de 5 passagers choisis au hasard dans 5 voitures différentes. On note par X la variable aléatoire définie par :

X = le nombre de billets tarif réduit que trouve le contrôleur.

La variable aléatoire $X \sim \mathcal{B}(5, 0.9)$

Exemples: 4.6.1

1. Un réseau informatique comporte 15 routeurs. Chaque routeur a une probabilité de 0,95 de fonctionner correctement pendant une période donnée $p = 0,95$.

Calculer la probabilité qu'au moins 12 routeurs fonctionnent correctement pendant cette période.

NB : Cela permet de modéliser la fiabilité des composants dans un réseau informatique, en prenant en compte la probabilité de panne de chaque composant.

2. Un serveur a une probabilité de répondre correctement à une requête de 0,98. Lors d'une période de test, on envoie 1000 requêtes au serveur.

Calculer la probabilité que le serveur répond correctement à au moins 980 requêtes.

NB : Cela pourrait être utilisé pour évaluer la performance d'un serveur ou d'un service web pendant une période de test.

3.

4.6.4 Loi Géométrique

On répète de manière indépendante une **expérience de Bernoulli** avec une probabilité de succès égale à p jusqu'au premier succès. Soit X la variable qui correspond au **rang du premier succès** : ce rang est nécessairement supérieur ou égal à 1 et inférieur ou égal à n , donc $X(\Omega) = \{1, 2, \dots, n, \dots\}$.

Définition 4.6.4

Soit X une variable aléatoire discrète. On dit que X suit une loi **géométrique** de paramètres p (on note $X \sim \text{Geom}(p)$), si et seulement si, l'ensemble des valeurs possible de X est $\{1, \dots, n, \dots\}$ ($X(\Omega) = \{1, \dots, n, \dots\}$) et sa loi de probabilité est définie par :

$$\mathbb{P}(X = k) = (1 - p)^{k-1}p; \quad \forall k \in \mathbb{N}^*$$

Les valeurs caractéristiques d'une variable aléatoire discrète X qui suit une loi de Géométrie sont données par :

$$E(X) = \frac{1}{p}; \quad V(X) = \frac{1-p}{p^2}$$

Exemples: 4.6.2

1. Un serveur a une probabilité de succès de 0,8 à chaque tentative de réponse. Si une tentative échoue, le client réessaie jusqu'à obtenir une réponse réussie.
Calculer le nombre moyen de tentatives nécessaires avant d'obtenir une réponse réussie.
2. Un système de validation de mot de passe dispose d'un mécanisme de sécurité qui bloque un utilisateur après 3 tentatives infructueuses. La probabilité qu'un mot de passe saisi soit correct est de 0,2.
Combien de tentatives faut-il en moyenne avant d'obtenir un échec dans ce système ?
3. Un serveur a une probabilité de répondre correctement à une requête de 0,9.
Si le serveur échoue à chaque tentative de réponse, quelle est la probabilité qu'il faille au moins 4 tentatives avant d'obtenir une réponse correcte ?

4.6.5 Loi de poisson

La loi de Poisson décrit la probabilité qu'un événement se réalise durant un intervalle de temps donné, lorsque la probabilité de réalisation d'un événement est très faible et que le nombre d'essais est très grand. C'est une loi qui est en général utilisée pour modéliser des événements rares tels que des pannes

Définition 4.6.5

Soit X une variable aléatoire discrète. On dit que X suit une **loi de Poisson** de paramètre $\lambda > 0$ (on note : $X \sim \mathcal{P}(\lambda)$), si et seulement si, l'ensemble des valeurs possible de X est $\{0, 1, \dots, n, \dots\}$

$(X(\Omega) = \mathbb{N})$ et sa loi de probabilité est de la forme :

$$\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad \forall k \in \mathbb{N}.$$

Les valeurs caractéristiques d'une variable aléatoire discrète X qui suit une loi de Poisson de paramètre λ , sont données par :

$$E(X) = \lambda, \quad V(X) = \lambda$$

Exemples: 4.6.3

1. Un serveur web recevant des requêtes aléatoires. La loi de Poisson peut aider à estimer la probabilité de recevoir un certain nombre de requêtes pendant une période donnée. Ce serveur reçoit en moyenne 20 requêtes HTTP par minute. Le nombre de requêtes reçues en 1 minute est une variable aléatoire ayant pour loi la loi de Poisson.

Calculer la probabilité que le serveur reçoive exactement 15 requêtes en 1 minute.

2. Un programme présente en moyenne 0,5 erreur par heure.

Calculer la probabilité qu'il n'y ait aucune erreur pendant une heure d'exécution.

3. Un serveur reçoit en moyenne 12 connexions simultanées par minute.

Utiliser la loi de Poisson pour déterminer la probabilité qu'il y ait exactement 10 connexions simultanées dans la prochaine minute.

Lorsque n devient grand, le calcul des probabilités d'une loi binomiale $X \sim \mathcal{B}(n, p)$ $\mathbb{P}(X = k) = C_n^k p^k (1 - p)^{n-k}$ devient très fastidieux. On va donc, sous certaines conditions, trouver une approximation de $\mathbb{P}(X = k)$ plus maniable.

Comportement asymptotique

Si $n \rightarrow \infty$ et $p \rightarrow 0$

alors $X \sim \mathcal{B}(n, p) \rightarrow \mathcal{P}(\lambda)$ avec $np \rightarrow \lambda$

Remarque:

Cette approximation est correcte si $n \geq 50$ et $np \leq 5$.

Exemple: 4.6.5

Supposons qu'un serveur reçoit des requêtes avec une probabilité de $p = 0.002$ à chaque seconde. Le nombre total de secondes dans une période de surveillance est $n = 3600$ secondes (soit une heure). Le nombre de requêtes X suit alors une loi binomiale $B(3600, 0.002)$. Nous cherchons à estimer la probabilité que le serveur reçoive exactement 10 requêtes pendant cette heure.

La probabilité d'obtenir exactement $k = 10$ requêtes avec la loi binomiale $B(n, p)$ est donnée par la formule de la probabilité binomiale :

$$\mathbb{P}(X = k) = C_n^k p^k (1 - p)^{n-k}$$

Dans notre cas, avec $n = 3600$, $p = 0.002$, et $k = 10$, la probabilité devient :

$$\mathbb{P}(X = 10) = C_{3600}^{10} (0.002)^{10} (1 - 0.002)^{3590}$$

La loi binomiale peut être approximée par la loi de Poisson lorsque n est grand et p est petit. Dans ce cas, la loi de Poisson a pour paramètre $\lambda = n \times p$. Nous avons donc :

$$\lambda = 3600 \times 0.002 = 7.2$$

La probabilité d'obtenir exactement $k = 10$ requêtes avec la loi de Poisson est donnée par la formule suivante :

$$\mathbb{P}(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

Ainsi, pour $\lambda = 7.2$ et $k = 10$, la probabilité devient :

$$\mathbb{P}(X = 10) = \frac{7.2^{10} e^{-7.2}}{10!}$$

Les probabilités calculées avec la loi binomiale et la loi de Poisson donnent les résultats suivants :

$$\mathbb{P}_{\text{binomiale}}(X = 10) \approx 0.07705$$

$$\mathbb{P}_{\text{Poisson}}(X = 10) \approx 0.07703$$

Les deux probabilités sont très proches, ce qui montre que l'approximation de la loi de Poisson par la loi binomiale est valable dans ce cas où n est grand et p est petit. Cette approximation est donc utile pour simplifier les calculs dans des situations comme la gestion des requêtes d'un serveur.

Soit une loi binomiale de paramètres $(100 ; 0,01)$, les valeurs des probabilités pour k de 0 à 5 ainsi que leur approximation à 10^{-3} avec une loi de Poisson de paramètre $(\lambda = np = 1)$ sont données dans le tableau ci-dessous :

k	0	1	2	3	4	5
$P(X=k)$	0,366	0,370	0,185	0,061	0,015	0,000
Approximation	0,368	0,368	0,184	0,061	0,015	0,003

Dans le cas de cet exemple où $n = 100$ et $np = 1$, l'approximation de la loi binomiale par une loi de poisson donne des valeurs de probabilités identiques à 10^{-3} près.

Exercice d'application

Dans une population très nombreuse, des études régulières ont montré qu'il y avait 2 % d'individus de type A. Calculer la probabilité, dans un échantillon de 100 individus tirés au hasard, d'obtenir :

1. aucun individu du type A ;
2. au moins deux individus du type A.

Soit X le nombre d'individus du type A figurant dans l'échantillon. Chacun des $n = 100$ individus a la probabilité $p = 0,02$ d'être du type A. Et les tirages des individus peuvent être considérés comme indépendants car la population est très nombreuse.

Dans ce cas, X suit la loi binomiale $\mathcal{B}(100; 0,02)$.

1. $\mathbb{P}(X = 0) = 0.1326$
2. $\mathbb{P}(X \geq 2) = 1 - \mathbb{P}(X = 0) - \mathbb{P}(X = 1) = 1 - (0.98)^{100} - 100 \times 0.02 \times (0.98)^{99} = 0.5967$

Variables aléatoires continues et lois de Probabilités

5.1 Variables aléatoires continues

Définition 5.1.1

Une variable aléatoire est dite *continue* si elle peut prendre *toutes les valeurs* dans un intervalle (borné ou non borné). En règle générale, toutes les variables qui résultent d'une mesure sont de type continu.

Exemples: 5.1.1

Les variables aléatoires :

- Le temps que met un serveur pour répondre à une requête
- La latence d'un réseau, c'est-à-dire le temps qu'il faut pour qu'un paquet de données soit envoyé d'une machine à une autre et retourne
- Le temps qu'un programme met pour s'exécuter (ou le temps d'exécution d'une fonction spécifique)
- Dans les systèmes de stockage ou de transmission de données, la taille des fichiers ou des paquets de données envoyés ou reçus

Sont des *variables aléatoires continues*

Dans le cas d'une variable aléatoire continue, la loi de probabilité associe une probabilité à


chaque ensemble de valeurs définies dans un intervalle donné. En effet, pour une variable aléatoire continue, la probabilité de l'événement $\{X = a\}$ est nulle, car il est impossible d'observer exactement cette valeur.

On considère alors la probabilité que la variable aléatoire X prenne des valeurs comprises dans un intervalle $[a, b]$ tel que $\mathbb{P}(a \leq X \leq b)$.

Définition 5.1.2

On appelle *densité de probabilité* toute application continue (sauf peut-être en un nombre fini de points où elle admet une limite à gauche et une limite à droite finies) $f : \mathbb{R} \rightarrow \mathbb{R}$ telle que

- $\forall x \in \mathbb{R} \quad f(x) \geq 0$
- $\int_{-\infty}^{+\infty} f(x) dx = 1$



Soit une **fonction densité de probabilité** $f(x)$:

- (1) l'aire hachurée **en vert** correspond à la probabilité $P(X < -10)$
- (2) l'aire hachurée **en bleu** correspond à la probabilité $P(+10 < X < +15)$

Soit X une v.a continue définie sur un espace probabilisé $(\Omega, \mathbb{P})$.

Définition 5.1.3

On appelle *fonction de répartition* de X , l'application F_X qui, à chaque réel t , associe la probabilité pour que la variable X prenne une valeur inférieure ou égale à t .

$$F_X(t) = \mathbb{P}(X \leq t) \quad \text{pour tout } t \in \mathbb{R}$$

La relation entre la fonction de répartition et la fonction densité de probabilité $f(x)$ est la suivante :

$$\forall t \in \mathbb{R} \quad F_X(t) = \mathbb{P}(X \leq t) = \int_{-\infty}^t f(u) du$$

Remarque:

La fonction de répartition F_X est une primitive de la fonction densité de probabilité f .

Soit X une v.a. continue de fonction densité de probabilité f et de fonction de répartition F_X , alors

1. $\mathbb{P}(a \leq X \leq b) = F_X(b) - F_X(a) = \int_a^b f(u)du$ avec $a < b$
2. $\forall a \in \mathbb{R} \quad \mathbb{P}(X = a) = 0$

Propriété: 3

Soit X une variable aléatoire continue et F_X sa fonction de répartition. On a les assertions suivantes :

- F_X est continue sur $\mathbb{R}$, dérivable en tout point où f est continue et $F'_X = f$
- F_X est croissante sur $\mathbb{R}$
- F_X est à valeurs dans $[0, 1]$
- $\lim_{t \rightarrow -\infty} F_X(t) = 0$ et $\lim_{t \rightarrow +\infty} F_X(t) = 1$

Exemple: 5.1.2

La latence (temps de réponse) d'un serveur est une variable aléatoire ayant pour fonction de densité la fonction suivante :

$$f(x) = \lambda e^{-\lambda x}, \quad \text{pour } x \geq 0$$

où $\lambda = 0.05$ est le taux moyen de latence (par exemple, une requête est traitée en moyenne toutes les 20 secondes).

Calculer la probabilité que la latence d'une requête soit inférieure à 10 secondes.


La probabilité que la latence soit inférieure à 10 secondes est :

$$\mathbb{P}(X \leq 10) = 0.3935$$


La probabilité que la latence d'une requête soit inférieure à 10 secondes est d'environ 0.3935, soit environ 39.35%. Cela signifie que, dans environ 39.35% des cas, le serveur traitera la requête en moins de 10 secondes.

Exemple: 5.1.3


La quantité de café (en kg) vendu par semaine par un vendeur est une variable aléatoire X prenant ses valeurs dans l'intervalle $[10, 70]$ de densité de probabilité f définie par :



La fonction de répartition F_X associée à la variable aléatoire X est donnée par :



Une illustration graphique du calcul des probabilités de l'exemple est donnée par le schéma suivant :



5.2 Les caractéristiques d'une variable aléatoire continue

Soit X une variable aléatoire continue de densité de probabilité f ,

Définition 5.2.1

On appelle *espérance* de X , qu'on note par $E(X)$, la quantité définie par :

$$E(X) = \int_{-\infty}^{+\infty} t f(t) dt$$

Propriété: 4

Si X et Y sont deux variables aléatoires définies sur un même univers Ω , admettant une espérance, alors :

- $E(X + Y) = E(X) + E(Y)$
- $E(\alpha X + \beta) = \alpha E(X) + \beta$

Définition 5.2.2

On appelle *variance* de X , qu'on note par $V(X)$, la valeur définie par :

$$V(X) = E[X - E(X)]^2 = \int_{-\infty}^{+\infty} (t - E(X))^2 f(t) dt = \int_{-\infty}^{+\infty} t^2 f(t) dt - E(X)^2$$

Propriété: 5

$$V(\alpha X + \beta) = \alpha^2 V(X)$$

Définition 5.2.3

On appelle *écart type* de X , qu'on note par σ_X ou $\sigma(X)$, la valeur définie par :

$$\sigma(X) = \sqrt{V(X)}$$

$$f_X(x) = \begin{cases} 0 & \text{si } x < 14 \\ 2(15 - x) & \text{si } 14 \leq x \leq 15 \\ 0 & \text{si } x > 15 \end{cases}$$

On a

$$E(X) = \int_{-\infty}^{+\infty} x f_X(x) dx = \int_{14}^{15} (30x - 2x^2) dx = \left[15x^2 - \frac{2}{3}x^3 \right]_{14}^{15} = 14.33$$

$$E(X^2) = \int_{-\infty}^{+\infty} x^2 f_X(x) dx = \int_{14}^{15} (30x^2 - 2x^3) dx = \left[10x^3 - \frac{1}{2}x^4 \right]_{14}^{15} = 205.5$$

Ainsi

$$\text{Var}(X) = E(X^2) - E(X)^2 = 0.0565$$

et

$$\sigma(X) = 0.24$$

5.3 Indépendance de deux variables

Soient X et Y deux variables aléatoires continues définies sur un espace probabilisé $(\Omega, \mathbb{P})$.

Définition 5.3.1

On dit que les deux variables aléatoires X et Y sont indépendantes si pour tous couples (s, t) de valeurs possibles pour X et Y , les événements $\{X \leq s\}$ et $\{Y \leq t\}$ sont indépendants. Ce qui est équivalent à :

$$\mathbb{P}(X \leq s, Y \leq t) = \mathbb{P}(X \leq s) \times \mathbb{P}(Y \leq t) = F_X(s) \times F_Y(t)$$

5.4 Loïs de probabilités continues

5.4.1 Loi uniforme

Soient $a, b \in \mathbb{R}$, tels que $b \geq a$

Définition 5.4.1

On dit qu'une variable aléatoire continue, X , suit une loi uniforme continue ($X \sim \mathcal{U}_{[a,b]}$) sur $X(\Omega) = [a, b]$ si sa fonction de densité est définie par :

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{si } x \in [a, b] \\ 0 & \text{si } x \notin [a, b] \end{cases}$$

Exemple: 5.4.1

Considérons une variable aléatoire X distribuée selon une loi uniforme continue sur $X(\Omega) = [0, 20]$, sa fonction de densité est définie par

$$f(x) = \begin{cases} \frac{1}{20} & \text{si } x \in [0, 20] \\ 0 & \text{si } x \notin [0, 20] \end{cases}$$

Si $X \sim \mathcal{U}_{[a,b]}$, alors la fonction de répartition de X est donnée par

$$F_X(t) = \begin{cases} 0 & \text{si } x < a \\ \frac{t-a}{b-a} & \text{si } a \leq t \leq b \\ 1 & \text{si } x > b \end{cases}$$

Exemple: 5.4.2

Soit $X \sim \mathcal{U}_{[0,20]}$, alors $F_X(5) = \frac{1}{4}$. Le premier quartile est égal à 5


Propriété: 6

Si $X \sim \mathcal{U}_{[a,b]}$, alors

$$E(X) = \frac{a+b}{2} \quad V(X) = \frac{(b-a)^2}{12}$$

Exemple: 5.4.3

Fonctions de densité et de répartition de la loi uniforme continue $\mathcal{U}_{[3,6]}$



5.4.2 Loi exponentielle

Les lois exponentielles modélisent des durées aléatoires, comme des durées de vie de particules en physique.

Définition 5.4.2

Soit X une v.a. continue. On dit que X suit une loi Exponentielle de paramètre $\lambda > 0$ (intensité) si l'ensemble des valeurs possible $X(\Omega) = \mathbb{R}^+$ et sa densité de probabilité est définie par :

$$f_X(t) = \begin{cases} 0 & \text{si } t < 0 \\ \lambda e^{-\lambda t} & \text{si } t \geq 0 \end{cases}$$

Si X suit une loi exponentielle d'intensité $\lambda > 0$ on note : $X \sim \text{Exp}(\lambda)$.

Propriété: 7

Si $X \sim \text{Exp}(\lambda)$, alors la fonction de répartition de X , F_X est donnée par :

$$F_X(t) = \begin{cases} 0 & \text{si } t < 0 \\ 1 - e^{-\lambda t} & \text{si } t \geq 0 \end{cases}$$


Remarque:

La loi exponentielle est souvent utilisée pour modéliser des événements qui se produisent à un rythme constant, mais de manière aléatoire, tels que ou

- les temps d'attente
- les temps de défaillance dans des systèmes informatiques
- analyse des performances des réseaux

Exemple: 5.4.4

Fonctions de densité et de répartition de la loi exponentielle



Propriété: 8

Si $X \sim \text{Exp}(\lambda)$, alors

$$E(X) = \frac{1}{\lambda} \quad V(X) = \frac{1}{\lambda^2}$$

Exemple: 5.4.5

Un serveur web qui reçoit des requêtes à un taux moyen de 2 requêtes par minute. Nous pouvons modéliser le temps entre deux requêtes successives comme une variable aléatoire continue suivant une loi exponentielle.

Calculer la probabilité que le temps entre deux requêtes soit inférieur à 5 secondes.

5.4.3 Loi normale

La loi normale, ou loi de Laplace-Gauss, est une loi de probabilité continue définie sur l'ensemble des réels $\mathbb{R}$. C'est sans conteste la loi de probabilité continue la plus utilisée, notamment en raison du théorème central limite. La densité de la loi normale dépend d'un paramètre de location (qui correspond à son espérance) noté μ et d'un paramètre d'échelle (qui correspond à sa variance) noté σ^2 .

Définition 5.4.3

On dit qu'une v.a. X suit une loi normale d'espérance μ et de variance σ^2 , notée $\mathcal{N}(\mu, \sigma^2)$, si sa fonction de densité est définie sur $X(\Omega) = \mathbb{R}$ par :

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2} \left(\frac{x-\mu}{\sigma}\right)^2\right) \quad \forall x \in \mathbb{R}$$

avec $\mu \in \mathbb{R}$ et $\sigma \in \mathbb{R}^+$.


Proposition: 5.4.1

Si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors :

$$E(X) = \mu \quad ; \quad V(X) = \sigma^2.$$

Exemple: 5.4.6

Exemple de fonctions de densité de lois normales



Exemples: 5.4.1

- Le temps d'exécution d'un programme ou d'un algorithme peut varier en fonction de nombreux facteurs tels que la charge du processeur, la quantité de mémoire disponible, et les entrées spécifiques au programme. Dans de nombreux cas, le temps d'exécution d'un programme suit une loi normale
- Dans un système informatique, la taille des fichiers stockés peut être modélisée par une variable aléatoire qui suit une loi normale
- Les performances des réseaux informatiques, comme la latence et la bande passante, peuvent souvent être modélisées par des lois normales.

Parmi les lois normales générales, on distingue la loi normale centrée réduite ou loi normale standard, d'espérance nulle et de variance égale à 1.

Définition 5.4.4

On dit qu'une v.a. X suit une loi normale centrée réduite, notée $\mathcal{N}(0, 1)$, si sa fonction de densité est définie par :

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \quad \forall x \in \mathbb{R}.$$

Remarques:

- Si X est une v.a. aléatoire de loi normale centrée réduite, alors $E(X) = 0$ et $V(X) = 1$.
- On admet que

$$X \sim \mathcal{N}(\mu, \sigma^2) \iff \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1)$$

Propriété: 9

Si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors sa fonction de répartition F_X est donnée par :

$$F_X(t) = \int_{-\infty}^t f_X(u) du = \int_{-\infty}^t \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2}\left(\frac{u-\mu}{\sigma}\right)^2\right) du \quad \forall t \in \mathbb{R}$$

Définition 5.4.5

La fonction de répartition de la loi normale centrée réduite $\mathcal{N}(0, 1)$, notée $\Phi(t)$, est définie par :


$$\Phi(t) = \int_{-\infty}^t \varphi(x) dx = \int_{-\infty}^t \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx \quad \forall t \in \mathbb{R}$$

Remarque:

Pour de nombreuses lois continues usuelles (loi normale, loi du khi-deux, loi de Student, loi de Fisher-Snedecor, etc.), il est impossible d'exprimer la fonction de répartition avec des fonctions simples. Toutefois, il est possible de déterminer numériquement la valeur de $F_X(x)$: pour cela on utilise soit des logiciels, soit des tables de loi.

Exemple: 5.4.7

Exemple de répartition de lois normales



Exemples: 5.4.2

Soit X une variable aléatoire qui suit la loi normale centrée réduite.

- $\Phi(0,52) = \mathbb{P}(X \leq 0,52) = 0,6985$
- $\mathbb{P}(X > 0,33) = 1 - \mathbb{P}(x \leq 0,33) = 1 - \Phi(0,33) = 1 - 0,6293 = 0,3707$
- $\mathbb{P}(0 \leq X \leq 0,6) = \Phi(0,6) - \Phi(0) = 0,7257 - 0,5 = 0,2257$

x	0,00	0,01	0,02	0,03	0,04
0,0	0,500 0	0,504 0	0,508 0	0,512 0	0,516 0
0,1	0,539 8	0,543 8	0,547 8	0,551 7	0,555 7
0,2	0,579 3	0,583 2	0,587 1	0,591 0	0,594 8
0,3	0,621 7	0,625 5	0,629 3	0,633 1	0,636 9
0,4	0,655 4	0,659 1	0,662 8	0,666 4	0,670 0
0,5	0,691 5	0,695 0	0,698 5	0,701 9	0,705 4
0,6	0,725 7	0,729 1	0,732 4	0,735 7	0,738 9
0,7	0,758 0	0,761 1	0,764 2	0,767 3	0,770 4

Remarque:

Si $X \sim \mathcal{N}(\mu, \sigma^2)$ et on veuille calculer $F_X(c) = \mathbb{P}(X \leq c)$ où c est une valeur réelle. On peut alors exprimer cette probabilité cumulée à l'aide de la fonction de répartition $\Phi(\cdot)$ de la loi $\mathcal{N}(0,1)$,

$$F_X(c) = \mathbb{P}(X \leq c) = \mathbb{P}\left(\frac{X - \mu}{\sigma} \leq \frac{c - \mu}{\sigma}\right) = \Phi\left(\frac{c - \mu}{\sigma}\right)$$

Exemple: 5.4.8

Soit X une variable aléatoire réelle telle que $X \sim \mathcal{N}(0, 8, 4)$. Calculons la probabilité cumulée $F_X(1, 84)$.

$$F_X(1, 84) = \mathbb{P}(X \leq 1, 84) = \mathbb{P}\left(\frac{X - 0,8}{2} \leq \frac{1,84 - 0,8}{2}\right) = \Phi(0,52) = 0,6985$$

Remarque:

- La table e la loi normale donne les valeurs de $\Phi(x)$ en fonction de x pour $0 \leq x \leq 4,09$ avec 0,01 comme pas.
- La table donne $\Phi(x)$ uniquement pour des valeurs positives de x . Pour des valeurs négatives, on utilise le fait que $\Phi(x) = 1 - \Phi(-x)$ pour $x \leq 0$.

Exemple: 5.4.9

Soit X une variable aléatoire réelle telle que $X \sim \mathcal{N}(0, 8, 4)$. Calculons la probabilité cumulée $F_X(-0, 4)$.

$$\begin{aligned} F_X(-0, 4) &= \mathbb{P}(X \leq -0, 4) = \mathbb{P}\left(\frac{X - 0,8}{2} \leq \frac{-0,4 - 0,8}{2}\right) \\ &= \mathbb{P}\left(\frac{X - 0,8}{2} \leq -0,6\right) \\ &= \Phi(-0,6) \\ &= 1 - \Phi(0,6) \\ &= 1 - 0,7257 = 0,2743 \end{aligned}$$

5.5 Théorèmes limites

Toutes les variables aléatoires sont définies sur le même espace probabilisé $(\Omega, \mathcal{F}, \mathbb{P})$. Soit $(X_n)_{n \in \mathbb{N}}$ une suite de variables aléatoires et X une autre variable aléatoire.

Définition 5.5.1

On dit que la suite $(X_n)_{n \in \mathbb{N}}$ converge en probabilité vers X si

$$\forall \varepsilon > 0, \quad \lim_{n \rightarrow +\infty} \mathbb{P}(|X_n - X| > \varepsilon) = 0$$

On note $X_n \xrightarrow{\mathbb{P}} X$.




FIGURE 5.1 – Illustration de la notion de convergence en loi

Définition 5.5.2

Soit une suite de variables aléatoires (X_n) ayant pour fonction de répartition F_n . On dit que (X_n) converge en loi (ou en distribution) vers une variable aléatoire X définie sur $X(\Omega)$ et ayant pour fonction de répartition F si

$$\lim_{n \rightarrow +\infty} F_n(x) = F(x) \quad \forall x \in X(\Omega)$$

On note $X_n \xrightarrow{d} X$.

Théorème 5.5.1

Soient des variables aléatoires $X_1, \dots, X_n$ indépendantes telles que $E(X_i) = m$ et $V(X_i) = \sigma^2$, $\forall i = 1, \dots, n$. La moyenne empirique de ces variables converge en probabilité vers l'espérance m :

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\mathbb{P}} E(X_i) = m$$

Exemple: 5.5.1

On considère n variables aléatoires discrètes $X_1, \dots, X_n$ indépendantes et identiquement distribuées telles que $X_i \sim \mathcal{P}(\lambda)$. D'après les propriétés de la loi de Poisson, on sait que $E(X_i) = \lambda$. Par




FIGURE 5.2 – Illustration de la loi faible des grands nombres

conséquent, d'après la loi faible des grands nombres, on a :

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\mathbb{P}} \lambda$$

Exemple: 5.5.2

On considère des variables aléatoires indépendantes et identiquement distribuées selon une loi uniforme $X_i \sim \mathcal{U}_{[0,10]}$, $\forall i = 1, \dots, n$ avec $E(X_i) = 5$. On applique la procédure suivante :

1. Grâce à un logiciel, on tire des réalisations $\{x_1, \dots, x_n\}$ des n variables $\{X_1, \dots, X_n\}$. Si $n = 3$, on obtient par exemple trois réalisations $\{1,7363; 4,9926; 7,6626\}$.
2. On calcule une réalisation de la moyenne empirique $\bar{Y}_n$. Cette réalisation est notée $\bar{y}_n = \frac{1}{n} \sum_{i=1}^n y_i$. Dans l'exemple précédent, on obtient $\bar{Y}_n = 4,8105$.
3. On répète 5000 fois les étapes 1 et 2. On obtient ainsi 10000 réalisations de la variable $\bar{Y}_n$.
4. On construit l'histogramme de ces 10000 réalisations.
5. On répète l'expérience pour différentes valeurs de la dimension n (taille d'échantillon). Il convient de ne pas confondre ici la taille d'échantillon n (par exemple 3) et le nombre de répliques 10000.

On observe que lorsque la dimension n est très grande, les réalisations de la moyenne empirique $\bar{Y}_n$ tendent à se concentrer autour de la valeur de l'espérance $E(Y_i) = 5$.

Le théorème central limite est sans conteste le théorème fondamental de la statistique inférentielle.

Théorème 5.5.2

Soient $X_1, \dots, X_n$ une séquence de variables aléatoires indépendantes et identiquement distribuées avec une espérance finie $E(X_i) = m$ et une variance finie $V(X_i) = \sigma^2, \forall i = 1, \dots, n$. Alors

$$\frac{\frac{1}{n} \sum_{i=1}^n X_i - m}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1)$$

Remarque:

Le théorème central limite s'applique quelle que soit la distribution des variables aléatoires $X_1, \dots, X_n$.

La seule hypothèse est que ces variables doivent être indépendantes et identiquement distribuées.


On considère des variables aléatoires indépendantes et identiquement distribuées selon une loi du khi-deux $X_i \sim \chi(2), \forall i = 1, \dots, n$ avec $E(X_i) = 2$ et $V(X_i) = 4$. On applique la procédure suivante :

1. Grâce à un logiciel, on tire des réalisations $\{x_1, \dots, x_n\}$ des n variables $\{X_1, \dots, X_n\}$. Si $n = 3$, on obtient par exemple trois réalisations $\{0,7444; 1,5487; 1,8604\}$.
2. On calcule une réalisation de la moyenne empirique $\bar{X}_n$. Dans l'exemple précédent, on obtient $\bar{x}_n = 1,3845$.
3. On considère la variable aléatoire transformée :

$$Z_n = \frac{\frac{1}{n} \sum_{i=1}^n X_i - m}{\sigma/\sqrt{n}}$$

À partir de la réalisation de la moyenne empirique $\bar{x}_n$ on calcule une réalisation de cette variable transformée comme $z_n = \frac{\bar{x}_n - 2}{2/\sqrt{3}}$. Dans l'exemple précédent on obtient une valeur de $z_n = -0,5331$.

4. On répète cette procédure 5000 fois (étapes 1 à 3). On obtient alors 5 000 réalisations de la variable z_n .
5. On construit un histogramme de ces 5000 réalisations et l'on compare cet histogramme à la densité d'une loi normale centrée réduite $\mathcal{N}(0, 1)$.



Sur la figure sont reportés l'histogramme des 5000 réalisations Z_n , la fonction de densité d'une loi normale centrée réduite, et un estimateur kernel de la densité de la variable Z_n , obtenus pour deux valeurs de n , à savoir $n = 10$ et $n = 10000$. On observe que lorsque la dimension n est très grande, la distribution empirique de la variable transformée Z_n tends vers une distribution normale centrée et réduite.

Propriété: 10

Lorsque le nombre de degrés de liberté tend vers l'infini, la distribution de Student converge (en distribution) vers la loi normale centrée réduite.





FIGURE 5.3 – Fonction de densité de la loi de Student

6.1 Introduction



L'**estimation** a pour objectif de déterminer les valeurs inconnues des paramètres de la population (p = proportion, μ = moyenne, σ^2 = variance) à partir des données de l'échantillon (f , $\bar{x}$, $V(x)$).

On sait calculer des indicateurs numériques à partir d'un échantillon de données...

- Mais comment généraliser à la population entière ?
- Quelles informations sur la population obtient-on en étudiant l'échantillon ?

— Quelle confiance peut-on accorder à ces informations ?

Pour résoudre les problèmes d'estimation de paramètres inconnus, il faut d'abord étudier les **distributions d'échantillonnage**, c'est à dire la loi de probabilité suivie par l'estimateur.

En théorie de l'estimation, il s'agit de distinguer soigneusement trois concepts différents :

- les paramètres de la **population** comme la moyenne μ dont la valeur est **certaine mais inconnue**.
- les résultats de **l'échantillonnage** comme la moyenne $\bar{x}$ dont la valeur est **certaine mais connue**.
- les **variables aléatoires des paramètres**, comme la moyenne aléatoire $\bar{X}$ dont la valeur est **incertaine puisque aléatoire mais dont la loi de probabilité est souvent connue**.

A partir d'échantillons représentatifs, on va introduire des résultats sur la population. On étudie une variable X , dont on observe des réalisations. On suppose que X suit une loi connue, i.e. on choisit parmi les modèles existants la loi la plus appropriée au phénomène observé. Seule la valeur numérique du paramètre θ intervenant dans cette loi de probabilité est inconnue.

$$X \sim \mathcal{L}(\theta), \quad \theta \text{ inconnu}$$

Exemple: 6.1.1

soit X la taille des habitants de Marrakech. On suppose que X suit une loi normale, de moyenne inconnue μ et de variance connue. On va donc chercher à estimer μ à partir d'un échantillon de données.

Définition 6.1.1

Un échantillon aléatoire est un échantillon dont les individus sont tirés au hasard parmi la population.

Définition 6.1.2

Un n -échantillon aléatoire est une collection (ou une suite) de variables aléatoires, noté :

$$(X_1, \dots, X_n)$$

où X_i désigne la valeur de la caractéristique d'intérêt associée au i -ème individu sélectionné au hasard parmi la population pour constituer l'échantillon.

- On suppose que la caractéristique d'intérêt dans la population, notée X , est une variable aléatoire.

- La loi de probabilité de cette variable aléatoire est représentée, soit par une fonction de densité si X est une variable continue, soit par une fonction de masse si X est une variable discrète.
 - On suppose que cette fonction de densité ou de masse dépend d'un paramètre θ , qui est a priori inconnu et que l'on cherche à estimer.
 - Soit $f_X(x; \theta)$ la fonction de densité ou de masse de la variable X .
- On note les données (observations) $x_1, x_2, \dots, x_n$.
- On regardera x_i comme le i -ème tirage d'une variable aléatoire X

$$X \sim \mathcal{L}(\theta)$$

- Ou de façon équivalente comme une réalisation d'une variable X_i de même loi que X . De plus, les X_i sont supposées indépendantes :

$$X_i \sim \mathcal{L}(\theta)$$

Exemple: 6.1.2

On suppose que la durée de vie d'un équipement, notée X , peut être représentée par une variable aléatoire positive, admettant une distribution exponentielle de paramètre λ . Ce paramètre est inconnu. Afin de l'estimer, on dispose de six relevés pour lesquels on a pu observer la durée écoulée (exprimée en heures) avant la rupture de l'équipement : (100, 102, 95, 78, 135, 98). Ces six valeurs correspondent à la réalisation d'un échantillon aléatoire de taille $n = 6$, noté $(X_1, X_2, X_3, X_4, X_5, X_6)$, où les variables X_i pour $i = 1, \dots, 6$ sont i.i.d. de même loi que X (loi exponentielle).

6.1.1 Estimateur statistique

Soient $(x_1, x_2, \dots, x_n)$ réalisation (observations) de l'échantillon $(X_1, \dots, X_n)$.

Définitions 6.1.1

- Une statistique t est une fonction des observations $x_1, x_2, \dots, x_n$:

$$\begin{aligned} t &: \mathbb{R}^n \rightarrow \mathbb{R} \\ (x_1, \dots, x_n) &\mapsto t(x_1, \dots, x_n) \end{aligned}$$

- Un estimateur de θ est une fonction construite à l'aide des $\{X_i\}$:

$$T_n = t(X_1, \dots, X_n)$$

- Une estimation est une réalisation $t_n = t(x_1, \dots, x_n)$ de l'estimateur T_n . On note la valeur numérique de cette estimation par

$$\hat{\theta}(x) = t(x_1, \dots, x_n)$$

- La distribution de probabilité d'un estimateur est appelée distribution d'échantillonnage.

Exemple: 6.1.3

Soit un échantillon (X_1, X_2) de variables i.i.d. telles que $X_i \sim \mathcal{N}(\mu, \sigma^2)$ pour $i = 1, 2$. On admet que $\hat{\mu} = \frac{X_1 + X_2}{2}$ est un estimateur du paramètre μ . La loi exacte de l'estimateur $\hat{\mu}$ est alors la suivante :

$$\hat{\mu} = \frac{X_1 + X_2}{2} \sim \mathcal{N}(\mu, \sigma^2)$$

Pour une réalisation $(x_1, x_2) = (10, 4)$ de l'échantillon, on obtient une estimation (ponctuelle) du paramètre μ égale à :

$$\hat{\mu}(x_1, x_2) = \frac{10 + 4}{2} = 7$$

Exemple: 6.1.4

1. On observe un phénomène de production de pièces manufacturées. Chaque pièce est associée à une mesure (un indicateur de qualité par exemple). Comme on ne peut pas vérifier chaque mesure, on procède à un échantillonnage qui nous fournit donc un échantillon.
2. Supposons que la connaissance de la nature de cet indicateur nous permet de faire l'hypothèse qu'il obéit à une loi de probabilité normale.
3. Le problème est maintenant, au vue de l'échantillon $\{x_i\}$, de proposer une valeur pour la moyenne de cette loi normale. Il faut procéder à une estimation du paramètre vrai θ qui se traduit par la valeur $\hat{\theta}$. Il y a une infinité de manière possible parmi lesquelles :
 - $\hat{\theta}$ = la moyenne
 - $\hat{\theta}$ = la médiane
 - $\hat{\theta}$ = le mode
 - ...

⇒ *Quel est le meilleur estimateur de la moyenne ? Existe-t-il ? Qu'est ce que cela veut dire meilleur ?*

Il n'existe pas de "meilleur estimateur" ! mais il existe des **critères de comparaison** :

- **Biais** : On souhaite que l'estimation ne soit pas systématiquement décalée par rapport à la valeur vraie.
- **Précision** : Si l'on répète l'estimation sur un autre échantillon, on souhaite obtenir une estimation cohérente, donc peu de variation d'un échantillon à l'autre. On parlera aussi d'efficacité.
- **Convergence** : Si l'on peut estimer la valeur du paramètre sur toute la population-mère, la valeur de l'estimation obtenue doit être la valeur vraie du paramètre.
- **Complexité** : Toute estimation nécessite un calcul donc un temps. On s'attachera donc à évaluer la complexité du calcul en fonction de la taille des données.
- **Robustesse** : Dans tout cas concret, il existe des sources de perturbations. On souhaite que l'estimation ne soit pas sensible à la présence de valeurs aberrantes.

Définitions 6.1.2

- **Estimateur sans biais**


Un estimateur T_n est dit sans biais lorsque son espérance mathématique est égale à la valeur vraie du paramètre.

$$\text{Biais} = E(T_n) - \theta$$

- **Précision d'un estimateur**

On mesure généralement la précision d'un estimateur par l'erreur quadratique moyenne :

$$EQM(T_n) = E((T_n - \theta)^2)$$



Exemple: 6.1.5

Soit $(Y_1, \dots, Y_n)$ un n -échantillon de variables aléatoires discrètes i.i.d. telles que Y_i admette une distribution de Bernoulli avec une probabilité de succès $p \in [0, 1]$. La moyenne empirique est un estimateur sans biais de p :

$$\hat{p} = \frac{Y_1 + \dots + Y_n}{n}$$

En effet, les Y_i sont i.i.d, $E(Y_i) = p$ $E(\hat{p}) = \frac{1}{n}E(Y_1 + \dots + Y_n) = \frac{1}{n}(E(Y_1) + \dots + E(Y_n)) = \frac{n \times p}{n} = p$

Exemple: 6.1.6

Soit $(X_1, \dots, X_n)$ un n -échantillon de variables aléatoires i.i.d. telles que $E(X_i) = \mu$ et $V(X_i) = \sigma^2$.

Considérons les deux estimateurs sans biais de la moyenne μ : $\hat{\mu}_1 = \frac{X_1 + X_2 + \dots + X_n}{n}$ et $\hat{\mu}_2 = X_1$.

Comment choisir entre ces deux estimateurs non biaisés. Comparons l'erreur quadratique moyenne des deux estimateurs

$$EQM(\hat{\mu}_1) = E((\hat{\mu}_1 - \mu)^2) = V(\hat{\mu}_1) = \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{\sigma^2}{n}$$

$$EQM(\hat{\mu}_2) = E((\hat{\mu}_2 - \mu)^2) = V(\hat{\mu}_2) = \sigma^2$$

On obtient $EQM(\hat{\mu}_1) \leq EQM(\hat{\mu}_2)$ dès que la taille d'échantillon n est supérieure ou égale à 1.

L'estimateur $\hat{\mu}_1$ est meilleur que $\hat{\mu}_2$.

6.2 Construction d'estimateurs

Il existe de nombreuses méthodes d'estimations suivant le problème étudié et les hypothèses retenues. Par exemple on cite :

- la méthode des moindres carrés ordinaires
- **la méthode du maximum de vraisemblance**
- la méthode des moments
- la méthode des variables instrumentales ;
- la méthode des doubles moindres carrés ordinaires.

La méthode du maximum de vraisemblance est la plus utilisée en statistique. Les paramètres de la plupart des modèles non-linéaires considérés de nos jours en marketing, en finance, en gestion des risques (scoring bancaire), en assurance, apprentissage automatique etc., sont estimés par maximum de vraisemblance.

Soit X une variable aléatoire réelle de loi paramétrique (discrète ou continue), dont on veut estimer le paramètre θ . Alors on définit une fonction f telle que :

$$f_X(x; \theta) = \begin{cases} f_X(x) & \text{si } X \text{ est une v.a. continue de densité } f_X \\ \mathbb{P}_X(X = x) & \text{si } X \text{ est une v.a. discrète de fonction de masse } \mathbb{P}_X \end{cases}$$

Définition 6.2.1

On appelle fonction de vraisemblance de θ de l'échantillon $(x_1, x_2, \dots, x_n)$ la fonction de θ définie par :

$$L(\theta; x_1, x_2, \dots, x_n) = \prod_{i=1}^n f_X(x_i; \theta)$$

Définition 6.2.2

La fonction de log-vraisemblance de l'échantillon $(x_1, x_2, \dots, x_n)$ est définie par :

$$l(\theta; x_1, x_2, \dots, x_n) = \ln L(\theta; x_1, x_2, \dots, x_n) = \sum_{i=1}^n \ln f_X(x_i; \theta)$$

Remarque:

L'intuition de l'estimation par maximum de vraisemblance consiste à déterminer la valeur du paramètre θ qui maximise la probabilité d'apparition de l'échantillon $(x_1, x_2, \dots, x_n)$, c'est-à-dire qui maximise la vraisemblance de l'échantillon.

$$\hat{\theta} = \arg \sup_{\theta \in \mathbb{R}^+} \{L(\theta; x_1, x_2, \dots, x_n)\}$$

Remarque:

Dans la pratique, il est souvent plus facile de maximiser la log-vraisemblance que de maximiser la fonction de vraisemblance.

1. La condition nécessaire

$$\frac{\partial L(\theta; x_1, x_2, \dots, x_n)}{\partial \theta} = 0 \quad \text{ou} \quad \frac{\partial \ln L(\theta; x_1, x_2, \dots, x_n)}{\partial \theta} = 0$$

permet de trouver la valeur de $\hat{\theta}(x)$

2. $\theta = \hat{\theta}(x)$ est un maximum local si la condition suffisante est remplie au point critique $\hat{\theta}(x)$

$$\frac{\partial^2 L(\theta; x_1, x_2, \dots, x_n)}{\partial \theta^2} (\hat{\theta}(x)) \leq 0 \quad \text{ou} \quad \frac{\partial^2 \ln L(\theta; x_1, x_2, \dots, x_n)}{\partial \theta^2} (\hat{\theta}(x)) \leq 0$$

Exemple: 6.2.1

On souhaite estimer le paramètre $p \in]0, 1[$ d'une loi géométrique à partir d'un n -échantillon. On a $f_X(x; p) = \mathbb{P}_X(X = x) = p(1 - p)^{x-1}$ pour $x \in \mathbb{N}^*$. Soit un n -échantillon $(X_1, \dots, X_n)$ où les variables X_i sont i.i.d. de même loi $\mathcal{G}(p)$. La fonction de vraisemblance de l'échantillon $(x_1, \dots, x_n)$ s'écrit

$$L(x_1, x_2, \dots, x_n; p) = \prod_{i=1}^n f_X(x_i; p) = p^n (1 - p)^{\sum_{i=1}^n x_i - n}$$

La log-vraisemblance de l'échantillon $(x_1, \dots, x_n)$ est égale à

$$l(x_1, x_2, \dots, x_n; p) = \sum_{i=1}^n \ln f_X(x_i; p) = n \ln(p) + \left(\sum_{i=1}^n x_i - n \right) \ln(1 - p)$$

$$\frac{\partial l(x_1, x_2, \dots, x_n; p)}{\partial p} = \frac{n}{p} - \frac{\sum_{i=1}^n x_i - n}{1 - p} = 0 \iff \hat{p}(x) = \frac{n}{\sum_{i=1}^n x_i}$$

$$\begin{aligned} \frac{\partial^2 l(x_1, x_2, \dots, x_n; p)}{\partial p^2} &= -\frac{n}{p^2} - \frac{\sum_{i=1}^n x_i - n}{(1 - p)^2} \\ \frac{\partial^2 l(x_1, x_2, \dots, x_n; p)}{\partial p^2} (\hat{p}(x)) &= -\left(\sum_{i=1}^n x_i \right)^2 \frac{\sum_{i=1}^n x_i}{n(\sum_{i=1}^n x_i - n)} \leq 0 \end{aligned}$$

Par conséquent, l'estimateur du maximum de vraisemblance de p est

$$\hat{p} = \frac{n}{\sum_{i=1}^n X_i}$$

Sa réalisation (estimation du maximum de vraisemblance) est égale à :

$$\hat{p}(x) = \frac{n}{\sum_{i=1}^n x_i}$$

Exemple: 6.2.2

On cherche à estimer le paramètre d'une loi de Poisson. On a $f(x; \lambda) = \mathbb{P}_X(X = x) = e^{-\lambda} \frac{\lambda^x}{x!}$. Soit un n -échantillon $(X_1, \dots, X_n)$ où les X_i sont i.i.d de même loi de Poisson $\mathcal{P}(\lambda)$. La fonction de log-vraisemblance s'écrit

$$l(x_1, \dots, x_n; \lambda) = -n\lambda + \ln(\lambda) \cdot \sum_{i=1}^n x_i - \sum_{i=1}^n \ln(x_i!)$$

la dérivée première

$$\frac{\partial l(x_1, x_2, \dots, x_n; \lambda)}{\partial \lambda} = -n + \frac{\sum_{i=1}^n x_i}{\lambda}$$

s'annule pour $\hat{\lambda}(x) = \frac{\sum_{i=1}^n x_i}{n}$. La dérivée seconde

$$\frac{\partial^2 l(x_1, x_2, \dots, x_n; \lambda)}{\partial \lambda^2} = -\frac{\sum_{i=1}^n x_i}{\lambda^2}$$

est toujours négative ou nulle.

Donc l'estimateur du maximum de vraisemblance de λ est

$$\hat{\lambda} = \frac{\sum_{i=1}^n X_i}{n}$$

Exemple: 6.2.3

Soit X une variable aléatoire caractérisée par une fonction de densité

$$f_X(x; \mu) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2}\right)$$

La fonction de vraisemblance pour une réalisation d'un n -échantillon $(X_1, X_2, \dots, X_n)$ est égale

$$L(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f_X(x_i; \mu) = \frac{1}{(2\pi)^{\frac{n}{2}}} \exp\left(-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2}\right)$$

ainsi

$$L(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f_X(x_i; \mu) = \frac{1}{(2\pi)^{\frac{n}{2}}} \exp\left(-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2}\right)$$

$$l(x_1, x_2, \dots, x_n; \mu) = \ln L(x_1, x_2, \dots, x_n; \mu) = -\frac{n}{2} \ln(2\pi) - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2}$$

$$l(x_1, x_2, \dots, x_n; \mu) = \ln L(x_1, x_2, \dots, x_n; \mu) = \prod_{i=1}^n f_X(x_i; \mu) = -\frac{n}{2} \ln(2\pi) - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2}$$

$$\frac{\partial l(x_1, x_2, \dots, x_n; \mu)}{\partial \mu} = \sum_{i=1}^n (x_i - \mu)$$

cette dérivée s'annule en $\hat{\mu}(x) = \frac{\sum_{i=1}^n x_i}{n}$ La dérivée seconde

$$\frac{\partial^2 l(x_1, x_2, \dots, x_n; \mu)}{\partial \mu^2} = -n \leq 0$$

donc l'estimateur du maximum de vraisemblance de μ est $\hat{\mu} = \frac{\sum_{i=1}^n X_i}{n}$

Remarque:

Une fois un **bon** estimateur est construit, il est utilisé soit pour donner une **estimation ponctuelle** ou une **estimation par intervalle de confiance**.

6.3 Estimation ponctuelle

6.3.1 Estimation d'une espérance

On définit la variable aléatoire :

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

qui prend pour valeurs les moyennes des échantillons de taille n .

$\bar{X}$ est un estimateur **sans biais** de l'espérance $\mu = E(X)$.

Dans la pratique, on retient comme estimation de la moyenne théorique μ la moyenne $\bar{x}$ de l'échantillon.

$$\begin{aligned} E(\bar{X}) &= \frac{1}{n} E(X_1 + X_2 + \dots + X_n) = \frac{1}{n} (E(X_1) + E(X_2) + \dots + E(X_n)) \\ &= \frac{1}{n} (E(X) + E(X) + \dots + E(X)) = \frac{1}{n} (\mu + \mu + \dots + \mu) = \mu \end{aligned}$$

6.3.2 Estimation d'une variance

On définit :

$$V_e = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$$

Si μ est connue, alors V_e est un estimateur **sans biais** de $\sigma^2 = V(X)$.

En effet

$$\begin{aligned} E(V_e) &= \frac{1}{n} E \left(\sum_{i=1}^n X_i^2 \right) - E(\mu^2) \\ &= \frac{1}{n} \sum_{i=1}^n E(X_i^2) - \mu^2 \\ &= E(X^2) - \mu^2 = V(X) \end{aligned}$$

Estimation d'une variance (la moyenne est inconnue)

On définit :

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$$

qui prend pour valeurs les variances des échantillons de taille n .

Si μ est inconnue, alors S^2 est un estimateur **biaisé** de $\sigma^2 = V(X)$.

$$\begin{aligned} E(S^2) &= \frac{1}{n} \sum_{i=1}^n E(X_i^2) - E(\bar{X}_n^2) = \frac{1}{n} \sum_{i=1}^n (V(X_i) + E(X_i)^2) - V(\bar{X}_n) - E(\bar{X}_n)^2 \\ &= \frac{1}{n} (nV(X) + nE(X)^2) - \frac{1}{n} V(X) - E(X)^2 \\ &= V(X) - \frac{1}{n} V(X) = \frac{n-1}{n} V(X) \end{aligned}$$

Estimation d'une variance (la moyenne est inconnue)

On définit :

$$\hat{\sigma}^2 = \frac{n}{n-1} S^2$$

Si μ est inconnue, alors $\hat{\sigma}^2$ est un estimateur **sans biais** de $\sigma^2 = V(X)$.

En effet

$$\begin{aligned} E(\hat{\sigma}^2) &= E \left(\frac{n}{n-1} S^2 \right) \\ &= \frac{n}{n-1} \frac{n-1}{n} V(X) \\ &= V(X) \end{aligned}$$

6.3.3 Estimation ponctuelle d'un pourcentage

Si la population est formée d'individus ayant ou non un caractère A , on définit la variable aléatoire $\hat{p}$ qui prend pour valeurs les fréquences observées de A sur des échantillons de taille n , supposés tirés avec remise. Soit p la probabilité pour qu'un individu, pris au hasard dans la population, présente le caractère A .

Si k est le nombre d'individus possédant le caractère A dans un échantillon de taille n alors $\hat{p} = \frac{k}{n}$

$\hat{p}$ est un estimateur sans biais de p .

$$E(\hat{p}) = p \quad V(\hat{p}) = \frac{p(1-p)}{n}$$

Exercice On a mesuré le poids de raisins produits par souche sur 10 souches prises au hasard dans la vigne. On a obtenu les résultats suivants exprimés en kilogrammes :

2,4 3,4 3,6 4,1 4,3 4,7 5,4 5,9 6,5 6,9

1. Calculer la moyenne et la variance de l'échantillon.
2. En déduire les estimation ponctuelles non biaisées de la moyenne et de la variance de la population dont sont extraites les souches

Exercice Des études statistiques montrent que le taux de glucose dans le sang est une variable normale X d'espérance $\mu = 1 \text{ g/l}$ et d'écart-type $\sigma = 0.1 \text{ g/l}$.

1. En prenant 9 individus au hasard dans la population, quelle est l'espérance et l'écart-type théorique attendu de la variable aléatoire $\bar{X}$

6.4 Estimation par intervalle de confiance

6.4.1 Notion d'intervalle de confiance

Exemple: 6.4.1

Considérons un vote avec un assez grand nombre d'électeurs. Quand le scrutin est clôt, on commence à dépouiller les bulletins. Assez vite on est en mesure de donner une estimation du résultat final. En pratique, on ne donne pas une estimation numérique (telle liste obtient 18% des votes) mais une fourchette, c'est-à-dire un petit intervalle dans lequel on estime que le pourcentage exact figure.

- La *taille de la fourchette* dépend de la confiance qu'on souhaite avoir dans l'estimation.
- On peut vouloir que la probabilité que le pourcentage exact d'une liste soit bien dans la fourchette dépasse 0,95 (le *niveau de confiance*).
- *Plus on exige un haut niveau de confiance, plus la fourchette sera large*

Il est souvent plus réaliste et plus intéressant de fournir un renseignement de type $a < \theta < b$ plutôt que de calculer $\hat{\theta}$.

On cherche à déterminer l'intervalle $]a, b[$, centré sur la valeur numérique estimée du paramètre inconnu θ , contenant la valeur vraie avec une probabilité $1 - \alpha$ ($0 < \alpha < 1$).

Données de départ : l'échantillon et la connaissance de la loi de probabilité du paramètre à estimer.

Définition 6.4.1


Un intervalle de confiance du paramètre θ pour un niveau de confiance de $1 - \alpha$ (ou α est *niveau de risque*), est un encadrement du type :

$$\mathbb{P}(A < \theta < B) = 1 - \alpha$$

où A et B sont des variables aléatoires, fonctions des variables de l'échantillon $X_1, \dots, X_n$.


Remarque:

Une réalisation de l'intervalle de confiance $]A, B[$ est un *intervalle* $]a, b[$, où a et b sont les réalisations respectives des variables A et B , obtenues à partir de la réalisation de l'échantillon $(x_1, \dots, x_n)$.




$$\alpha = 0,01$$

99 chances sur 100 que la valeur du paramètre recherché se trouve dans l'intervalle de confiance mais **la précision** autour de la valeur prédite est **faible**



$$\alpha = 0,05$$

95 chances sur 100 que la valeur du paramètre recherché se trouve dans l'intervalle de confiance et la **précision** autour de la valeur prédite est **correcte**.



$$\alpha = 0,10$$


90 chances sur 100 que la valeur du paramètre recherché se trouve dans l'intervalle de confiance mais la **précision** autour de la valeur prédite est **élevée**.

6.4.2 Intervalle de confiance d'une moyenne

En fonction de la nature de la variable aléatoire continue X , de la taille de l'échantillon n et de la connaissance que nous avons sur le paramètre σ^2 , l'établissement de l'intervalle de confiance autour de μ sera différent.

Quelque soit la valeur de n , si $X \sim \mathcal{N}(\mu, \sigma^2)$ et σ^2 est connue

Etablir un intervalle de confiance autour de la moyenne μ revient à déterminer la valeur de i pour :




Loi normale réduite (table de l'écart réduit)

Si Z est une variable aléatoire qui suit la loi normale réduite, la table donne pour α choisi, la valeur z_α telle que :

$$P(|Z| \geq z_\alpha) = \alpha$$

La valeur α s'obtient par addition des nombres inscrits en marge.




α	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	∞	2,576	2,326	2,170	2,054	1,960	1,881	1,812	1,751	1,695
0,1	1,645	1,598	1,555	1,514	1,476	1,440	1,405	1,372	1,341	1,311
0,2	1,282	1,254	1,227	1,200	1,175	1,150	1,126	1,103	1,080	1,058
0,3	1,036	1,015	0,994	0,974	0,954	0,935	0,915	0,896	0,878	0,860
0,4	0,842	0,824	0,806	0,789	0,772	0,755	0,739	0,722	0,706	0,690
0,5	0,674	0,659	0,643	0,628	0,613	0,598	0,583	0,568	0,553	0,539
0,6	0,524	0,510	0,496	0,482	0,468	0,454	0,440	0,426	0,412	0,399
0,7	0,385	0,372	0,358	0,345	0,332	0,319	0,305	0,292	0,279	0,266
0,8	0,253	0,240	0,228	0,215	0,202	0,189	0,176	0,164	0,151	0,138
0,9	0,126	0,113	0,100	0,088	0,075	0,063	0,050	0,038	0,025	0,013

FIGURE 6.1 – Extrait de la table de l'écart-réduit

L'intervalle de confiance de la **moyenne** μ pour un coefficient de **risque** α est

$$\bar{X} - z_\alpha \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_\alpha \frac{\sigma}{\sqrt{n}}$$

où z_α est le quantile d'ordre $(1 - \frac{\alpha}{2})$ de la loi normale centrée réduite, soit $z_\alpha = \Phi^{-1}(1 - \frac{\alpha}{2})$.



Coefficient de risque	Ecart-réduit
$\alpha = 0,01$	$\varepsilon_\alpha = 2,576$
$\alpha = 0,05$	$\varepsilon_\alpha = 1,960$
$\alpha = 0,10$	$\varepsilon_\alpha = 1,645$

Remarque:

La largeur de l'intervalle de confiance obtenu est $2 \times z_\alpha \frac{\sigma}{\sqrt{n}}$. On remarque donc que plus la taille n de l'échantillon est grande plus l'intervalle est petit.

Exemple: 6.4.3

On s'intéresse à l'âge moyen dans une population de 500 personnes. Au lieu de sonder l'ensemble de la population, nous avons calculé à partir d'un échantillon de 30 personnes la moyenne d'âge qui est de 25 ans (avec une erreur standard ou écart type de 2 ans). La moyenne d'âge de l'ensemble de la population diffère certainement de cette moyenne observée. On aimerait estimer cette marge d'erreur avec un risque d'erreur de 5% ou encore un niveau de confiance de 95%. Si on suppose que l'âge des individus de la population estimée suit une loi normale, on peut utiliser l'intervalle de confiance vu ci-dessus.

On a $\bar{x} = 25$, $\sigma = 2$ $\alpha = 0,05$ donc $1 - \alpha/2 = 0.975$ et $z_\alpha = 1.96$.

On obtient comme réalisation de l'intervalle de confiance pour l'espérance au niveau de confiance 5% l'intervalle :

$$25 - 1,96 \times \frac{2}{\sqrt{30}} < \mu < 25 + 1,96 \times \frac{2}{\sqrt{30}}$$
$$24,28 < \mu < 25,72$$

Quelque soit la valeur de n , si $X \sim \mathcal{N}(\mu, \sigma^2)$ et σ^2 est inconnue

La variable aléatoire $T = \frac{\bar{X} - \mu}{\hat{\sigma}/\sqrt{n}}$ suit la loi de Student à $\nu = n - 1$ degrés de liberté.

Le raisonnement reste le même mais la variance de la population σ^2 doit être estimée par $\hat{\sigma}^2 = \frac{n}{n-1} s^2$ L'intervalle de confiance de l'espérance μ pour un coefficient de risque α est donc


$$\bar{X} - t_\alpha \frac{\hat{\sigma}}{\sqrt{n}} < \mu < \bar{X} + t_\alpha \frac{\hat{\sigma}}{\sqrt{n}}$$

le nombre t_α est le quantile d'ordre $(1 - \frac{\alpha}{2})$ de la loi de Student à $n - 1$ degrés de liberté.

Lorsque $n > 30$, la loi de Student converge vers une loi normale centrée réduite. Ainsi la valeur de t_α est égale à z_α

Taille de l'échantillon	Ecart-réduit	Variable de student
$n = 10$	$\varepsilon_\alpha = 1,960$	$t_\alpha = 2,228$
$n = 20$	$\varepsilon_\alpha = 1,960$	$t_\alpha = 2,086$
$n = 30$	$\varepsilon_\alpha = 1,960$	$t_\alpha = 2,042$
$n = 40$	$\varepsilon_\alpha = 1,960$	$t_\alpha = 1,960$

Si T est une variable aléatoire qui suit la loi de Student à ν degrés de liberté, la table donne pour α choisi, le nombre t_α tel que $P(|T| \geq t_\alpha = \alpha)$.



$\nu \backslash \alpha$	0,90	0,50	0,30	0,20	0,10	0,05	0,02	0,01	0,001
1	0,158	1,000	1,963	3,078	6,314	12,706	31,821	63,657	636,619
2	0,142	0,816	1,386	1,886	2,920	4,303	6,965	9,925	31,598
3	0,137	0,765	1,250	1,638	2,353	3,182	4,541	5,841	12,924
4	0,134	0,741	1,190	1,533	2,132	2,776	3,747	4,604	8,610
5	0,132	0,727	1,156	1,476	2,015	2,571	3,365	4,032	6,869
6	0,131	0,718	1,134	1,440	1,943	2,447	3,143	3,707	5,959
7	0,130	0,711	1,119	1,415	1,895	2,365	2,998	3,499	5,408
8	0,130	0,706	1,108	1,397	1,860	2,306	2,896	3,355	5,041
9	0,129	0,703	1,100	1,383	1,833	2,262	2,821	3,250	4,781
10	0,129	0,700	1,093	1,372	1,812	2,228	2,764	3,169	4,587
11	0,129	0,697	1,088	1,363	1,796	2,201	2,718	3,106	4,437
12	0,128	0,695	1,083	1,356	1,782	2,179	2,681	3,055	4,318
13	0,128	0,694	1,079	1,350	1,771	2,160	2,650	3,012	4,221
14	0,128	0,692	1,076	1,345	1,761	2,145	2,624	2,977	4,140
15	0,128	0,691	1,074	1,341	1,753	2,131	2,602	2,947	4,073
16	0,128	0,690	1,071	1,337	1,746	2,120	2,583	2,921	4,015
17	0,128	0,689	1,069	1,333	1,740	2,110	2,567	2,898	3,965
18	0,127	0,688	1,067	1,330	1,734	2,101	2,552	2,878	3,922
19	0,127	0,688	1,066	1,328	1,729	2,093	2,539	2,861	3,883
20	0,127	0,687	1,064	1,325	1,725	2,086	2,528	2,845	3,850
21	0,127	0,686	1,063	1,323	1,721	2,080	2,518	2,831	3,819
22	0,127	0,686	1,061	1,321	1,717	2,074	2,508	2,819	3,792
23	0,127	0,685	1,060	1,319	1,714	2,069	2,500	2,807	3,767
24	0,127	0,685	1,059	1,318	1,711	2,064	2,492	2,797	3,745
25	0,127	0,684	1,058	1,316	1,708	2,060	2,485	2,787	3,725

Exemple: 6.4.4

On suppose que la durée de vie d'un certain modèle de lampe suit une loi normale.

Sur un échantillon de $n = 30$ durées de vie d'un certain modèle de lampe on a obtenu comme moyenne empirique $\bar{x} = 2000h$ et écart-type empirique $\sigma = 300h$.

L'intervalle de confiance de niveau 0,95 pour la durée de vie moyenne μ est donc :

$$\bar{X} - t_\alpha \frac{\hat{\sigma}}{\sqrt{30}} < \mu < \bar{X} + t_\alpha \frac{\hat{\sigma}}{\sqrt{30}}$$

avec $t_\alpha = 2.045$ d'où

$$1888 < \mu < 2112$$