




Analyse multidimensionnelle et OLAP

Plan

- OLAP
- Représentation multidimensionnelle
- Analyse multidimensionnelle
- Manipulation des cubes
 - Slicing
 - Scoping ou Dicing
 - Roll-up Drill-up
 - Drill-down
- Serveurs ROLAP, MOLAP et HOLAP

Rappel



OLAP: OnLine Analytical Processing

- C'est quoi:
 - Catégorie de logiciel (moteur) dont le rôle est l'exploration et l'analyse rapide des données dans le DW suivant une approche multidimensionnelle utilisant plusieurs niveaux d'agrégation.
- Avantage:
 - L'utilisateur n'a pas à maîtriser des langages d'interrogation et des interfaces complexes
 - L'utilisateur interagit avec les données.

OLAP

- Données à analyser:
 - Les données sources OLAP sont souvent stockées dans les magasins de données (datamart, dimensions et faits)
 - Les fonctions OLAP permettent à partir des entrepôt de données, d'analyser l'activité de l'entreprise grâce à des statistiques: moyennes mobiles, coefficient de corrélation ...
- L'élément principal de l'infrastructure OLAP est le cube (ou hypercube).
 - Une base de données multidimensionnelle, qui permet l'analyse de ces données.

Cube

Une cube est aussi appelé source de données multidimensionnelles ou encore OLAP. Ces type des sources ont une structure différentes de celle d'une source de données relationnelle. On ne parle plus d'une table de données mais d'un cube données.

Un cube est basée sur un modèle multidimensionnel, qui facilite l'analyse suivant différentes dimensions et granularité. Ce modèle organise les données en terme de **table de faits et dimension**, selon le schémas en étoile en flocon ou encore en constellation.

Utilité d'une source de type Cube

- Nous avons une grande volumétrie, mais nous ne pouvons pas l'exploiter.
- Nous voulons croisé les données de différentes manières.
- Nous voulons voir rapidement les informations les plus importantes.
- Atout de la visualisations (mieux que des résultats textuels)
- Supporte les opération interactives OLAP.

Cube

En Informatique, et plus particulièrement dans le domaine des bases de données, le traitement analytique en ligne (olap) est un type d'application informatique orienté vers l'analyse sur le champ d'informations selon plusieurs axes, dans le but d'obtenir des rapports de synthèse.

Les applications d'analyse OLAP sont couramment utilisées en informatiques décisionnelle, dans le but d'aider la direction a avoir une vue transversale sur les activités de l'entreprise.

OLap

Olap fournit dans un cadre générique permettant l'analyse des données sur plusieurs dimensions.

Définit principalement les opérations génériques sur les hypercubes permettant l'analyse des données.

Repose sur des technologies permettant le calcul et la mise à jour des hypercubes.

Définit aussi un langage de requête permettant l'interrogation d'un hypercube

Décrit une technologie conçue pour optimiser le stockage et la consultation d'un large volume de données multidimensionnelles agrégés sur plusieurs niveaux de détails en vue de faciliter leur analyse.


Représentation multidimensionnelle

- Données représentées par une structure à plusieurs Dimensions:
 - Clients
 - Produits
 - Vendeurs
 - Géographie
 - Temps
- Les cellules contiennent des données agrégées: Faits
 - Quantité vendue
 - Chiffre d'affaire
 - Coût
- Le résultat sous forme
 - Relations
 - Cube de données
 - Hyper cube de données

Représentation multidimensionnelle


- Exemple
 - Analyser les ventes de produits par zone géographique et par temps
 - 3 dimensions: Produits, Géographie et Temps
 - Granularités:
 - Géographie: Pays, Région et Ville
 - Temps: Année, Trimestre, Mois et Semaine
 - Faits: Chiffre d'affaire, Marge ...
- Représentation multidimensionnelle
 - Dimensions représentées comme axes d'analyse
 - Faits comme les cellules

Entrepôt de données: Exemple



Représentation multidimensionnelle

- Résultat de l'analyse



Représentation multidimensionnelle

- Agrégation des données
 - Les données seront groupées à différents niveaux de granularité (niveau de détail des données)
 - Les groupements sont pré-calculés / granularité
 - Total des ventes / mois
 - Total des ventes / années
 - Total des ventes / mois 12
- Sur les granularités:
 - Temps: Jours, Mois, Trimestre, Semestre, Années, ...
 - Produit: Types, Gammes, Marques, ...
 - Zone géographique: Quartiers, Villes, Régions, Pays, ...
 -


L'implémentation du OLAP

Description de la base multidimensionnelle suivant la technologie utilisée :

- Relationnel OLAP (ROLAP)
- Multidimensionnel OLAP (MOLAP)
- Hybride OLAP (HOLAP)

ROLAP

- C'est la stratégie la plus couramment utilisée pour le stockage des entrepôts. Les données sont stockées dans une base de données relationnelle.
- Les tables constituant le schéma en Etoile (ou flocon) sont directement stockées dans la base relationnelle. Plusieurs calculs d'agrégations sont réalisés à différents niveaux.
- Un moteur OLAP est ajouté comme une surcouche à la base de données pour simuler le comportement d'une base de données multidimensionnelle
- La force de ce mode de stockage réside dans sa technologie relationnelle mure et un stockage de très grand volume de données. Néanmoins, le temps de réponse peut être potentiellement élevé, due aux transformations des requêtes. Il est également impossible de réaliser certains types de requêtes qui demandent des calculs trop complexes.




MOLAP

- MOLAP se base sur un système purement multidimensionnel pour le stockage des cubes. Pour ce faire, il utilise la structure de tableaux.
- Les données sont stockées comme des matrices à plusieurs dimensions: Cube[1:m,1:n,1:p] (mesure)
- Correspondance directe avec la vue multidimensionnelle.
- Rapide mais difficile à mettre en place
- Ne supporte pas de très gros volume de données.



HOLAP

- Solution hybride entre ROLAP et MOLAP.
- Données de base stockées dans un SGBD relationnels (table de fait et dimensions) + données agrégées stockées dans cubes. (serveur MOLAP)




Manipulation des cubes

• Représentation et manipulation

Le cube de données est traditionnellement représenté sous forme de table multidimensionnelle et manipulé via différents opérateurs.

La table multidimensionnelle

- Présente les valeurs des mesures d'un fait en fonction des valeurs des paramètres des dimensions représentées en lignes et en colonnes étant données des valeurs des autres dimensions
 - les lignes et les colonnes sont les axes selon lesquels le cube est exploré et chaque cellule contient la (ou les) mesure(s) calculée(s).
- correspond à une tranche du cube multidimensionnel



Manipulation des cubes

Il existe trois catégories d'opérations élémentaires :

- **Granularité** : concerne un changement de niveau de détail : opérations liées au niveau de granularité des données :
 - roll-up
 - drill-down
- **Restructuration** : concerne la représentation, permet un changement de points de vue selon différentes dimensions : opérations liées à la structure, manipulation et visualisation du cube :
 - Rotate/pivot
 - Switch
 - Split, nest, push, pull
- **Ensemble** : concerne l'extraction et l'OLTP classique :
 - slice, dice
 - selection/projection
 - jointure (drill-across)

Manipulation d'un cube


• Drill-up (Roll-up) / Drill-down

- Sont des opérations liées à la granularité.
- Ils permettent à l'utilisateur de naviguer entre les différents niveaux de données (granularité) allant de la plus résumée (granularité supérieure) au plus détaillé (granularité inférieure)

Manipulation d'un cube

• Drill-up (Roll-up)

- Consiste à représenter les données du cube à un niveau de granularité supérieur sur une dimension
- Agréger selon une dimension
 - Utilisation des fonctions d'agrégation (somme, moyenne, ect) spécifiées pour la mesure et la dimension




Quantité des ventes		Géographie.Département					
		Loiret	Eure et Loir	Indre	Indre et Loire	Loir et Cher	Gironde
Temps.Année	2005	100	200	100	150	1	2
	2006	250	210	120	200	2	2
	2007	260	230	250	200	4	5
	2008	280	220	220	200	5	4
Véhicules.AIV							

Roll-Up



sur la dimension Géographie



Drill-down

Quantité des ventes		Géographie.Région	
		Aquitaine	Centre
Temps.Année	2005	2	551
	2006	2	782
	2007	5	944
	2008	4	925
Véhicules.AllV			

Manipulation d'un cube

• Drill-down

- Consiste à représenter les données du cube à un niveau de granularité de niveau inférieur, donc sous une forme plus détaillée.
- On fait un « zoom » sur une dimension.




Manipulation d'un cube/ Opérations sur les cubes

Opérations de sélections / projection:

• Slicing:


- Sélection de tranches du cube par des prédicats selon une dimension.
- Filtrer une dimension selon une valeur
- Extraire des informations représentées par un cube en fonction d'une seule dimension (critère de sélection).
- **Notation: slice(Formule, Dimension)**



Manipulation d'un cube

• Scoping ou Dicing:

- Extraction d'un sous-cube (bloc de données). C'est une opération plus générale que le slicing
- Application d'une sélection sur plusieurs dimensions
- Combinaison de plusieurs slices.
- **Notation: slice(Formule 1, Dimension 1) and slice(Formule 2, Dimension 2) and slice(Formule n, Dimension n)**



Quantité des ventes		Géographie.Département					
		Loiret	Eure et Loir	Indre	Indre et Loire	Loir et Cher	Gironde
Temps.Année	2005	100	200	100	150	1	2
	2006	250	210	120	200	2	2
	2007	260	230	250	200	4	5
	2008	280	220	220	200	5	4
Véhicules.AIV							

Slice (Année = « 2005 »)

Quantité des ventes		Géographie.Département					
		Loiret	Eure et Loir	Indre	Indre et Loire	Loir et Cher	Gironde
Temps.Année	2005	100	200	100	150	1	2
Véhicules.AIV							

Quantité des ventes		Géographie.Département					
		Loiret	Eure et Loir	Indre	Indre et Loire	Loir et Cher	Gironde
Temps.Année	2005	100	200	100	150	1	2
	2006	250	210	120	200	2	2
	2007	260	230	250	200	4	5
	2008	280	220	220	200	5	4
Véhicules.AIV							

Dice (Département = « Loiret et Cher » ou « Gironde », Année = « 2007 » ou « 2008 »)

Quantité des ventes		Géographie Département	
		Loiret et Cher	Gironde
Temps Année	2007	4	5
	2008	5	4
Véhicules AIIV			


Manipulation d'un cube/ Opérations sur les cubes

Opérations de sélections / projection:

- Slicing:**

- Exemple: tranche

slice(mois = « janvier » or mois = « Mars », Temps)




Manipulation d'un cube

- Scoping ou Dicing:**

- Exemple: sous cube

slice(mois=«Mars» or mois= «Février», Temps) and slice(Couleur=P2 or Couleur = P3, Voiture) and slice(Région=R2 or Région=R3 , Géographie)



Manipulation d'un cube


- Opérations de restructuration/ réorientation**

- Pivot (Rotate) :**

- Tourne le cube pour visualiser une face différente.
- Rotation par rapport à l'un des axes des dimensions.
- (Région, Produit) -> (Région, Mois)**

Manipulation d'un cube

- Opérations de restructuration/ réorientation
- Pivot (Rotate) :




Quantité des ventes		Géographie			
Temps: Année		Rabat	Agadir	Marrakech	Kelaï des Segharna
	2022	200	120	160	10
	2023	250	180	190	15

Pivot(Temps.année, Géographie.ville) -> (Temps.année, Voiture.Couleurs)

Manipulation d'un cube

- Opérations de restructuration/ réorientation
- Pivot (Rotate) :



Quantité des ventes		Voiture		
Temps: Année		Blanc	Noir	Rouge
	2022	200	120	160
	2023	250	180	190

Quantité des ventes		Géographie.Département					
		Loiret	Eure et Loir	Indre	Indre et Loire	Loiret et Cher	Gironde
Temps.Année	2005	100	200	100	150	1	2
	2006	250	210	120	200	2	2
	2007	260	230	250	200	4	5
	2008	280	220	220	200	5	4
Véhicules.AIV							

Véhicules.AIV

Pivot
(Temps.Année, Géographie.Département
-> Temps.Année, Véhicules.Couleur)




Quantité des ventes		Véhicules.Couleur			
Temps.Année		Blanc	Noir	Bleu	Rouge
	2005	120	200	150	83
	2006	130	220	150	284
	2007	140	250	259	300
	2008	150	280	249	250

Géographie.AIG

Manipulation d'un cube


- Switch (Permutation) :

- Inter-change la position des membres d'une dimension.
- Permutation de valeurs de dimensions




Exercice 1

- Prenons un exemple de cube OLAP.
- Nous allons nous intéresser aux ventes de tous les magasins pendant une année




Exercice 1

- Comment utiliser ce cube?
- Voir les différentes vues de ce cube.
- **Vue 1:** On s'intéresse à toutes les ventes du magasin numéros A22 ((toutes catégories confondues durant toutes l'année))



Exercice 1

- Comment utiliser ce cube?
- Voir les différentes vues de ce cube.
- **Vue 2:** On s'intéresse à toutes les ventes du magasin numéros A22 dans la catégorie « vêtements pour enfant » durant le mois de Février.



Exercice 2

- Soit la quantité de vente des véhicules collectés par Année et département

Quantité des ventes		Géographie.Département					
		Loiret	Eure et Loir	Indre	Indre et Loire	Loir et Cher	Gironde
Temps.Année	2005	100	200	100	150	1	2
	2006	250	210	120	200	2	2
	2007	260	230	250	200	4	5
	2008	280	220	220	200	5	4
Véhicules.AIV							

- Donner le résultat de l'opération **Slice** (Année = « 2005 »)
- Donner le résultat de l'opération **Dice** (Département = « Loir et Cher » ou « Gironde », Année = « 2007 » ou « 2008 »)

1-

Quantité de ventes	Géographie Département					
	Loiret	Eure et Loir	Inde	INdre et Loire	Loire et Cher	Gironde
Année 2005	100	200	100	150	1	2

2-

Quantité de ventes	Géographie Département	
Année	Loire et cher	Gironde
2007	4	5
2008	5	4

Rappel : Recherche de données

- Sélection :
- SELECT : définit les attributs de la relation résultante
- FROM : spécifie les relations sur lesquelles porte la recherche
- WHERE : indique des conditions de restriction
- Les autres clauses seront traitées ultérieurement

Langages d'interrogation de données

Extension du langage SQL pour OLAP

Le langage SQL a connu des extensions qui ont permis de répondre aux exigences des outils OLAP.

Ces dernières permettent de créer et de naviguer dans des cubes multidimensionnelles.

• Fonctions d'agrégations :

Calculer la somme, la moyenne, le nombre, le max et le min se fait grâce aux fonctions d'agrégations classiques de SQL.

Count, Min, Max, Sum, Avg

Langages d'interrogation de données

Extension du langage SQL pour OLAP

Parmi les nouvelles fonctions ajoutées, nous trouvons :

✓ Fonctions Rank:

- La fonction rank permet de calculer le classement d'un enregistrement comparé aux autres enregistrements basé sur les mêmes mesures. La requête suivante retourne le classement des régions par rapport aux quantités de pièces vendues.

```
SELECT region, rank() OVER (ORDER BY qte DESC) AS qte
FROM ventes
ORDER BY qte
```

La clause ORDER BY est nécessaire pour retourner les résultats triés.

Langages d'interrogation de données

Extension du langage SQL pour OLAP

Il est possible d'utiliser la fonction Rank pour répondre à la question : Quel est le top 3 des régions ?

```
SELECT region, rank() OVER (ORDER BY qte DESC) AS qte
FROM ventes
ORDER BY qte
FETCH FIRST 3 ROWS ONLY
```

Langages d'interrogation de données

Extension du langage SQL pour OLAP

✓ Fonctions EVERY / ANY / SOME:

La fonction **EVERY** prend en considération les tuples que s'ils vérifient tous l'expression passée en argument.

Every(expression) : vrai ssi la valeur de son argument (expression) est vraie pour tous les tuples, sinon faux (∀)

La requête suivante retourne le maximum et le minimum de quantité de pièces vendues pour chaque région enregistrant un taux de ventes important.

```
SELECT COUNT(*), MAX(qte), MIN(qte)
FROM ventes
GROUP BY region
Having EVERY (qte > 2000000)
```

Dans la même logique les fonctions ANY et SOME permettent de prendre en considération les tuples si au moins un vérifie l'expression passée en argument.

Langages d'interrogation de données

Extension du langage SQL pour OLAP

✓ Fonctions N-tile:

Prend en entrée deux paramètres, une expression et un nombre n. La fonction calcule le domaine de l'expression en fonction des valeurs qui apparaissent dans la colonne. Ce domaine est alors divisé en n intervalles de tailles approximativement égales.

La fonction N-tile permet de retourner le numéro de l'intervalle qui contient la valeur de l'expression.

```
SELECT Min(qte), Max(qte), Avg(qte)
FROM ventes
GROUP BY N_tile(qte,10) as Percentile
HAVING Percentile = 10;
```


Langages d'interrogation de données

Extension du langage SQL pour OLAP

✓ Fonctions de la clause GROUP BY:

Pour mieux comprendre les différentes fonctions, nous déroulerons les différents résultats sur un sous ensemble des données du cube ver

Pour des raisons de simplification, nous prendrons en considération que les ventes des pièces écrous et clous, dans les régions est et ouest des années 2019 et 2018.



Langages d'interrogation de données

Extension du langage SQL pour OLAP

✓ Fonctions de la clause GROUP BY:


ROLLUP permet de calculer des agrégats (SUM, COUNT, MAX, MIN, AVG) à tous les niveaux d'agrégation sur une hiérarchie de dimensions. Il calcule également le total général selon l'ordre de gauche à droite dans la clause Group By. Prenons l'exemple suivant :

```
SELECT annee, region, piece, SUM(qte)
FROM ventes
GROUP BY ROLLUP (annee, region, piece)
```

Langages d'interrogation de données

Extension du langage SQL pour OLAP

✓ Fonctions de la clause GROUP BY:



Langages d'interrogation de données

Années	Région	Pièces	Sum(qte)	Signification
2019	est	écrous	50	
2019	est	clous	70	
2019	est	-	120	Total est/2019
2019	ouest	écrous	60	
2019	ouest	-	60	Total ouest/2019
2019	-	-	180	Total 2019
2018	est	écrous	70	
2018	est	clous	70	
2018	est	-	140	Total est/2018
2018	ouest	écrous	10	
2018	ouest	clous	10	
2018	ouest	-	20	Total ouest/2018
2018	-	-	160	Total 2018
-	-	-	340	Grand Total

Langages d'interrogation de données

Extension du langage SQL pour OLAP

✓ Fonctions de la clause GROUP BY:


CUBE Comme la fonction ROLLUP, la fonction CUBE calcule des agrégats (SUM, COUNT, MAX, MIN, AVG) à différents niveaux d'agrégation, mais de plus, permet de calculer toutes les combinaisons d'agrégations possibles d'un ensemble de colonnes de regroupement.

```
SELECT annee, region, piece, SUM(qte)
FROM ventes
GROUP BY CUBE (annee, region, piece)
```

Langages d'interrogation de données

Extension du langage SQL pour OLAP

✓ Fonctions de la clause GROUP BY:



Années	Région	Pièces	Sum(qte)	Signification
2019	est	écrous	50	
2019	est	clous	70	
2019	est	-	120	Total est/2019
2019	ouest	écrous	60	
2019	ouest	-	60	Total ouest/2019
2019	-	écrous	110	Total écrous/2019
2019	-	clous	70	Total clous/2019
2019	-	-	180	Total 2019
2018	est	écrous	70	
2018	est	clous	70	
2018	est	-	140	Total est/2018
2018	ouest	écrous	10	
2018	ouest	clous	10	
2018	ouest	-	20	Total ouest/2018
2018	-	écrous	80	Total écrous/2018
2018	-	clous	80	Total clous/2018
2018	-	-	160	Total 2018
-	est	écrous	120	Total écrous/est
-	est	clous	140	Total clous/est
-	est	-	260	Total est
-	ouest	écrous	70	Total écrous/ouest
-	ouest	clous	10	Total clous/ouest
-	ouest	-	80	Total ouest
-	-	écrous	190	Total écrous
-	-	clous	150	Total clous
-	-	-	340	Grand Total

Langages d'interrogation de données

Extension du langage SQL pour OLAP

✓ Fonctions de la clause GROUP BY:

GROUPING SETS Permet de spécifier des groupements multiples.


```
SELECT annee, region, piece, SUM(qte)
FROM ventes
GROUP BY GROUPING SETS ((annee, region), (annee, piece) )
```

Langages d'interrogation de données

Années	Région	Pièces	Sum(qte)	Signification
2019	est	-	120	Total est/2019
2019	ouest	-	60	Total ouest/2019
2019	-	écrous	110	Total écrous/2019
2019	-	clous	70	Total clous/2019
2018	est	-	140	Total est/2018
2018	ouest	-	20	Total ouest/2018
2018	-	écrous	80	Total écrous/2018
2018	-	clous	80	Total clous/2018

Langages d'interrogation de données

Exemple: Soit ce Schéma en étoile:



Langages d'interrogation de données

GROUP BY ROLLUP :

! calcule des agrégats (SUM, COUNT, MAX, MIN, AVG) à tous les niveaux de totalisation sur une hiérarchie de dimensions

! et calcule le total général :

- Selon l'ordre de gauche à droite dans la clause GROUP BY
- S'il y a n colonnes de regroupements, GROUP BY ROLLUP génère n+1 niveaux de totalisation

Exemples :

GROUP BY ROLLUP (year, month, day)

GROUP BY ROLLUP (country, city)

GROUP BY ROLLUP (month, city, producer)

...

Simplifie et accélère la maintenance des tables de synthèse.