

4.1 Introduction

Dans le cas où deux variables seront considérées simultanément il sera possible de s'interroger sur l'existence de liens ou de relations entre les données.

- le salaire augmente-t-il avec l'âge ?
- Quel est le degré de dépendance du niveau de salaire à la catégorie socio-professionnelle à laquelle appartiennent les salariés ?
- À niveau de qualification égal, le salaire est-il différent selon la région dans laquelle exerce le salarié ?
- Le taux de réussite des étudiants à l'université est-il fonction de la catégorie socio-professionnelle de leurs parents ?

Répondre à ces diverses questions nécessite de déterminer si les variables sont liées entre elles (la corrélation).

On notera

- $x_i, i = 1, \dots, k$ les k modalités d'un caractère statistique x (quantitatif, qualitatif)
- $y_i, i = 1, \dots, l$ les l modalités d'un caractère statistique y (quantitatif, qualitatif)

- Les deux caractères x et y sont étudiés simultanément sur chacun des N individus de la population. On notera n_{ij} l'effectif correspondant au couple (x_i, y_j) . (correspond au nombre des individus caractérisés simultanément par les modalités x_i et y_j)

Définition 4.1.1

On appellera *distribution jointe des effectifs de x et y* l'ensemble des informations (x_i, y_j, n_{ij}) pour $i = 1, \dots, k$ et $j = 1, \dots, l$.

4.2 Tableau de contingence

La répartition des N observations suivant les modalités croisées des deux caractères se présente sous la forme d'un tableau à double entrée appelé aussi tableau de contingence. La structure d'un tel tableau est comme suit :

$x \backslash y$	y_1	y_2	$\dots$	y_j	$\dots$	y_l
x_1	n_{11}	n_{12}	$\dots$	n_{1j}	$\dots$	n_{1l}
x_2	n_{21}	n_{22}	$\dots$	n_{2j}	$\dots$	n_{2l}
$\vdots$						
x_i	n_{i1}	n_{i2}	$\dots$	n_{ij}	$\dots$	n_{il}
$\vdots$						
x_k	n_{k1}	n_{k2}	$\dots$	n_{kj}	$\dots$	n_{kl}

On a

$$\sum_{i=1}^k \sum_{j=1}^l n_{ij} = N$$

La fréquence du couple (x_i, y_j) est

$$f_{ij} = \frac{n_{ij}}{N}$$

Exemple: 4.2.1

Le tableau suivant donne la distribution de 100 adultes selon les variables x et y . x représente le poids en kilogrammes et y la taille en centimètres.

$y \backslash x$	$[145, 155[$	$[155, 165[$	$[165, 175[$	$[175, 185]$
$[45, 55[$	4	9	2	0
$[55, 65[$	3	10	10	7
$[65, 75[$	0	5	5	15
$[75, 85[$	0	0	4	16
$[85, 95[$	0	0	2	8

Exemple: 4.2.2

Le responsable des ressources humaines d'une entreprise a effectué un sondage auprès de 200 employés, choisis au hasard à partir du fichier de l'entreprise, pour connaître leur niveau de satisfaction vis-à-vis de leurs travail. Ce caractère x a été reparti selon trois modalités : élevé, moyen, faible. On a également noté la catégorie salariale y à laquelle appartenait l'employé soit : 2 000 dhs et moins ; plus de 2 000 dhs mais moins de 3 000 dhs ; 3 000 dhs et plus.

A partir des résultats de cette enquête, on a construit le tableau de contingence suivant :

$y \backslash x$	$[0, 2000[$	$[2000, 3000[$	≥ 3000
Élevé	13	19	25
Moyen	28	29	28
Faible	24	18	16

4.3 Distributions Marginales

On ajoute au tableau de contingence les totaux en ligne et en colonne.

$\begin{matrix} y \\ x \end{matrix}$	y_1	y_2	$\cdots$	y_j	$\cdots$	y_l	total
x_1	n_{11}	n_{12}	$\cdots$	n_{1j}	$\cdots$	n_{1l}	$n_{1.}$
x_2	n_{21}	n_{22}	$\cdots$	n_{2j}	$\cdots$	n_{2l}	$n_{2.}$
$\vdots$							$\vdots$
x_i	n_{i1}	n_{i2}	$\cdots$	n_{ij}	$\cdots$	n_{il}	$n_{i.}$
$\vdots$							$\vdots$
x_k	n_{k1}	n_{k2}	$\cdots$	n_{kj}	$\cdots$	n_{kl}	$n_{k.}$
total	$n_{.1}$	$n_{.2}$	$\cdots$	$n_{.j}$	$\cdots$	$n_{.l}$	$N = n_{..}$

En marge à droite (totaux en ligne) :

la distribution de x : pour chaque indice i , l'effectif $n_{i.}$ est le nombre total d'observations de la modalité x_i de x quelle que soit la modalité de y

$$n_{i.} = \sum_{j=1}^l n_{ij} = \text{Total de la ligne } i.$$

Définition 4.3.1

Les k couples $(x_i, n_{i.})$ définissent la distribution marginale de caractère x .

La modalité x_i a pour effectif $n_{i.}$ et pour fréquence marginale $f_{i.} = \frac{n_{i.}}{N}$

$$\sum_{i=1}^k n_{i.} = N$$

En marge en bas (totaux en colonne) : la distribution de y : pour chaque indice j , l'effectif $n_{.j}$ est le nombre total d'observations de la modalité y_j de y quelle que soit la modalité de x . C'est-à-dire $n_{.j} = \sum_{i=1}^k n_{ij}$.

Définition 4.3.2

Les l couples $(y_j, n_{.j})$ définissent la distribution marginale de caractère y .

La modalité y_j a pour effectif $n_{.j}$ et pour fréquence marginale $f_{.j} = \frac{n_{.j}}{N}$

$$\sum_{j=1}^l n_{.j} = N$$

Propriétés 4.3.1

— Le total des fréquences de la ligne i est donné par :

$$f_{i.} = \sum_{j=1}^l f_{ij}$$

— Le total des fréquences de la colonne j est donné par :

$$f_{.j} = \sum_{i=1}^k f_{ij}$$

— La somme des fréquences est égale à 1

$$\sum_{i=1}^k \sum_{l=1}^l f_{ij} = \sum_{i=1}^k f_{i.} = \sum_{l=1}^l f_{.j} = 1$$

Exemple: 4.3.1

Le tableau de contingence suivant donne la répartition de salariés d'une entreprise selon le nombre d'enfants à charge (caractère x) et les salaires mensuels qu'ils perçoivent en 1000 dhs (caractère y)

$x \backslash y$	$[3, 5[$	$[5, 9[$	$[9, 11[$	Total
1	18	10	6	34
2	14	8	4	26
3	12	6	2	20
Total	44	24	12	80

— $n_{32} = 6$

— $n_{2.} = 26$

— $n_{.2} = 24$

— $f_{22} = \frac{8}{80} = 0.1$

— $f_{3.} = \frac{20}{80} = 0.25$

— $f_{.1} = \frac{44}{80} = 0.55$

4.4 Distributions conditionnelles

Définition 4.4.1

La distribution des observations suivant les modalités du caractère y sachant que la variable x prend la modalité x_i , est appelée distribution conditionnelle de y pour $x = x_i$.

Pour ceci, il suffit d'extraire du tableau à double entrée la ligne correspondant à $x = x_i$. On obtient des fréquences conditionnelles, notée $f_{j/i}$, en divisant ces effectifs par $n_{i.}$.

$$f_{j/i} = \frac{n_{ij}}{n_{i.}}$$

Définition 4.4.2

La distribution des observations suivant les modalités de la variable x sachant que la variable y prend la modalité y_j , est appelée distribution conditionnelle de x pour $y = y_j$

Pour obtenir cette distribution, il suffit d'extraire du tableau à double entrée la colonne correspondant à $y = y_j$.

Les fréquences conditionnelles, notée $f_{i/j}$, sont données par :

$$f_{i/j} = \frac{n_{ij}}{n_{.j}}$$

Exemples: 4.4.1

En reprenant l'exemple précédent.

La distribution conditionnelle de y sachant $x = 1$ est

$y/x = 1$	$[3, 5[$	$[5, 9[$	$[9, 11[$	Total
n_{1j}	18	10	6	$n_{1.} = 34$

$f_{2/1} = \frac{n_{12}}{n_{1.}} = \frac{10}{34} = 0,2941$. Ceci signifie que parmi les salariés ayant un seul enfant 29.41%, ont un salaire entre 5000Dhs et 9000Dhs.

La distribution conditionnelle de y sachant $x = 3$ est

$y/x = 3$	$[3, 5[$	$[5, 9[$	$[9, 11[$	Total
n_{3j}	12	6	2	$n_{3.} = 20$

$f_{1/3} = \frac{n_{31}}{n_{3.}} = \frac{12}{20} = 0,6$. Ceci signifie que parmi les salariés ayant 3 enfants, 60% ont un salaire entre 3000Dhs et 5000Dhs.

La distribution conditionnelle de $x/y = [5, 9[$

$x/y = [5, 9[$	1	2	3	Total
n_{i2}	10	8	6	$n_{.2} = 24$

$f_{2/2} = \frac{n_{22}}{n_{.2}} = \frac{8}{24} = 0.3333$. Ce qui signifie que 33.33% des salariés ayant un salaire entre 5000Dhs et 9000 Dhs ont 2 enfants.

Propriétés 4.4.1

- $\sum_{i=1}^k f_{i/j} = \sum_{i=1}^k \frac{n_{ij}}{n_{.j}} = 1$
- $\sum_{j=1}^l f_{j/i} = \sum_{j=1}^l \frac{n_{ij}}{n_{i.}} = 1$

4.5 Indépendance statistique

Deux caractères statistiques x et y sont dits indépendants si :

$$\forall i, \forall j \quad f_{ij} = f_{i.} \times f_{.j}$$

ou, ce qui revient au même :

$$n_{ij} = \frac{n_{i.} \times n_{.j}}{N} \quad \forall i, \forall j$$

4.6 Paramètres d'une distribution statistique double

4.6.1 Paramètres des distributions marginales

Les paramètres marginales du caractère x se déterminent à partir de la distribution marginale de ce même caractère, c'est-à-dire à partir des k modalités x_i et des k effectifs marginaux $n_{i.}$

De façon similaire, les paramètres marginales de y s'obtiennent à partir de la distribution marginale de ce même caractère, c'est-à-dire à partir des l modalités y_j et des l effectifs marginaux $n_{.j}$. On peut ainsi définir :

Moyennes marginales

- La moyenne marginale de x :

$$\bar{x} = \frac{1}{N} \sum_{i=1}^k n_{i.} x_i = \sum_{i=1}^k f_{i.} x_i$$

- La moyenne marginale de y :

$$\bar{y} = \frac{1}{N} \sum_{j=1}^l n_{.j} y_j = \sum_{j=1}^l f_{.j} y_j$$

Variances marginales

— La variance marginale de x

$$V(x) = \sigma_x^2 = \frac{1}{N} \sum_{i=1}^k n_{i.}(x_i - \bar{x})^2 = \sum_{i=1}^k f_{i.}(x_i - \bar{x})^2 = \frac{1}{N} \sum_{i=1}^k n_{i.}x_i^2 - \bar{x}^2$$

— La variance marginale de y

$$V(y) = \sigma_y^2 = \frac{1}{N} \sum_{j=1}^l n_{.j}(y_j - \bar{y})^2 = \sum_{j=1}^l f_{.j}(y_j - \bar{y})^2 = \frac{1}{N} \sum_{j=1}^l n_{.j}y_j^2 - \bar{y}^2$$

Exemples: 4.6.1

Le tableau de contingence suivant donne la répartition de salariés d'une entreprise selon le nombre d'enfants à charge (caractère x) et les salaires mensuels qu'ils perçoivent en 1000 dhs (caractère y).

$y \backslash x$	[3, 5[	[5, 9[	[9, 11[	<i>totaux</i>
1	18	10	6	34
2	14	8	4	26
3	12	6	2	20
<i>Totaux</i>	44	24	12	80

Considérons la distribution marginale x

x	1	2	3	$N = n_{..}$
$n_{i.}$	34	26	20	80

— Le nombre moyen d'enfants à charge par salarié est $\bar{x} = 1.82$

— La variance marginale de x est $V(x) = 0.66$

— L'écart-type correspondant est $\sigma_x = 0.81$

Considérons la distribution marginale y

y	[3, 5[	[5, 9[	[9, 11[	$N = n_{..}$
$n_{.j}$	44	24	12	80

— Le salaire mensuel moyen perçu par salarié est $\bar{y} = 5.8$, soit 5800 dhs

— La variance marginale de y est $V(y) = 4.86$

— L'écart-type correspondant est $\sigma_y = 2.2$

4.6.2 Paramètres des distributions conditionnelles

Moyennes conditionnelles

- Les moyennes conditionnelles de x selon y

$$\bar{x}_j = \frac{1}{n_{.j}} \sum_{i=1}^k n_{ij} x_i = \sum_{i=1}^k f_{i/j} x_i \quad j = 1, \dots, l$$

- Les moyennes conditionnelles de y selon x

$$\bar{y}_i = \frac{1}{n_{i.}} \sum_{j=1}^l n_{ij} y_j = \sum_{j=1}^l f_{j/i} y_j \quad i = 1, \dots, k$$

Variances conditionnelles

- Les variances conditionnelles de x selon y

$$V_j(x) = \frac{1}{n_{.j}} \sum_{i=1}^k n_{ij} (x_i - \bar{x}_j)^2 = \frac{1}{n_{.j}} \sum_{i=1}^k n_{ij} x_i^2 - \bar{x}_j^2 \quad j = 1, \dots, l$$

- Les variances conditionnelles de y selon x

$$V_i(y) = \frac{1}{n_{i.}} \sum_{j=1}^l n_{ij} (y_j - \bar{y}_i)^2 = \frac{1}{n_{i.}} \sum_{j=1}^l n_{ij} y_j^2 - \bar{y}_i^2 \quad i = 1, \dots, k$$

Exemple: 4.6.1

La distribution conditionnelle de $x/y = [5, 9[$

$x/y = [5, 9[$	1	2	3	Total
n_{i2}	10	8	6	$n_{.2} = 24$

- $\bar{x}_2 = 1,833$: Les salariés avec un salaire entre 5000Dhs et 9000Dhs ont un nombre moyen des enfants égal à 1,833.
- $V_2(x) = 4 - \bar{x}_2^2 = 4 - (1,833)^2 = 0,6401$

La distribution conditionnelle de y sachant $x = 3$ est

$y/x = 3$	$[3, 5[$	$[5, 9[$	$[9, 11[$	Total
n_{3j}	12	6	2	$n_{3.} = 20$

- $\bar{y}_3 = 5,5$: Le salaire moyen des salariés avec 3 enfants est 5500Dhs.
- $V_3(y) = 34,3 - \bar{y}_3^2 = 4,05$.

4.7 Covariance

Lorsque l'on étudie des distributions à deux caractères quantitatifs, on cherche généralement à quantifier le lien entre ceux-ci. On est amené souvent à calculer la covariance. Ainsi que nous le verrons par la suite, cet indicateur servira dans l'étude de la corrélation entre deux variables.

x et y sont deux caractères quantitatifs .

Définition 4.7.1

La covariance entre x et y est le nombre réel donné par

$$Cov(x, y) = \frac{1}{N} \sum_{i=1}^k \sum_{j=1}^l n_{ij} (x_i - \bar{x})(y_j - \bar{y}).$$

Formule pratique de calcul :

$$Cov(x, y) = \frac{1}{N} \sum_{i=1}^k \sum_{j=1}^l n_{ij} x_i y_j - \bar{x} \bar{y}.$$

Dans le cas de N couples distincts (x_i, y_i) la covariance devient

$$Cov(x, y) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{N} \sum_{i=1}^N x_i y_i - \bar{x} \bar{y}$$

- $Cov(x, x) = Var(x)$; $Cov(y, y) = Var(y)$
- $Cov(x, y) = Cov(y, x)$
- si les caractères x et y sont indépendants, alors $cov(x, y) = 0$.

La réciproque est fausse


4.8 Régression linéaire

4.8.1 Notion d'ajustement


Définition 4.8.1

Diagramme de dispersion : c'est un diagramme utile pour visualiser la forme de la tendance qui peut exister entre les deux caractères.

On représente la distribution du couple (x, y) par un nuage de points de coordonnées (x_i, y_i) .



Le nuage de points nous renseigne sur la forme de la liaison statistique entre les deux caractères observés ainsi que sur l'intensité de cette liaison



Selon l'allure du nuage, on a envie de remplacer ce nuage par le graphe d'une fonction f . (la courbe $y = f(x)$) Cette opération s'appelle un ajustement. $y = ax + b$; $y = ax^b$; $y = a \ln x + b$

4.8.2 Régression linéaire

Exemple d'étude de la relation entre le taux d'investissement en pourcentage du PIB et taux de croissance économique en 2010.

Objectif :

- On souhaite savoir si le taux d'investissement en pourcentage du PIB a une influence sur le taux de croissance économique et sous quelle forme cette influence peut être exprimée
- Le but est d'expliquer au mieux comment le taux de croissance économique varie en fonction du taux d'investissement et éventuellement de prédire le taux d'investissement à partir du taux d'investissement.
- Population : Pays du monde. Sur cette population, on considère deux variables
 - y : le taux de croissance économique ; c'est la variable à expliquer, appelée encore variable à régresser, variable réponse, variable dépendante.
 - x : le taux d'investissement en pourcentage du PIB : c'est la variable explicative, appelée également régresseur, variable indépendante.
- pour l'étude, On considère un échantillon de 26 pays tirés au sort.


x_i	y_i	x_i	y_i
15,39	2,45	23,18	5,15
17,91	2,72	23,73	5,32
18,07	2,87	24,07	4,68
18,15	2,95	24,37	5,95
18,58	2,11	25,34	4,64
18,97	2,50	28,08	6,91
19,20	2,03	29,20	5,22
20,92	5,04	30,24	7,82
21,22	4,96	31,57	7,70
21,64	5,84	31,76	7,74
21,72	5,44	32,22	7,72
21,93	5,62	33,57	9,53
22,11	6,03	43,15	9,67

- On cherche à exprimer la relation entre la variable le taux de croissance économique et la variable taux d'investissement à l'aide d'une fonction mathématique du type $y = f(x)$.

Graphiquement cela revient à représenter cette relation à l'aide d'une courbe (graphe de la fonction).

- Afin de mettre plus clairement en évidence et de quantifier la relation entre les deux variables, le taux d'investissement et le taux de croissance économique,

Pour choisir le modèle de relation, on représente les données graphiquement à l'aide d'un nuage de points.



- À cette fin, la méthode la plus utilisée consiste à ajuster le nuage de points par une droite (D),
- On parle de droite de régression ou de droite d'ajustement ou encore de droite des moindres carrés.
- La droite (D) ne passant pas par tous les points du nuage, il existe naturellement des écarts entre les points du nuage et les points situés sur cette droite.
- notons $\hat{y}_i$ l'ordonnée d'un point de la droite (D) dont l'abscisse est x_i et désignons par e_i les écarts entre la valeur observée y_i de y et la valeur $\hat{y}_i$ située sur la droite : $e_i = y_i - \hat{y}_i$
- L'expression de la droite de régression est alors donnée par : $\hat{y}_i = ax_i + b$, où a et b sont des constantes.
- il s'agit de trouver la droite (D) telle que les écarts e_i soient les plus faibles possibles : c'est-à-dire telle que les valeurs $\hat{y}_i$ situées sur la droite soient les plus proches possibles des valeurs observées y_i .

Afin de déterminer la valeur des paramètres (ou coefficients) a et b de la droite de régression, on applique le principe des moindres carrés ordinaires (MCO) consistant à minimiser la somme des

carrés des écarts. On cherche ainsi à minimiser l'expression suivante par rapport aux paramètres a et b :

$$\sum_{i=1}^N (y_i - ax_i - b)^2$$

4.8.3 L'équation de la droite de régression

La droite des moindres carrés ou droite de régression a pour équation :

$$y = ax + b$$

avec

$$a = \frac{Cov(x, y)}{V(x)}; \quad b = \bar{y} - a\bar{x}$$

Le paramètre a est la pente de la droite de régression de y sur x il mesure la variation de la variable dépendante lorsque la variable indépendante varie d'une unité. b désignant l'ordonnée à l'origine.

$$Cov(x, y) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{N} \sum_{i=1}^N x_i y_i - \bar{x}\bar{y}$$

En effet

On cherche à minimiser la fonction $f(a, b) = \sum_{i=1}^N (y_i - ax_i - b)^2$. A cette fin, on annule les dérivées partielles de $f(a, b)$ par rapport à a et b :

$$\frac{\partial f(a, b)}{\partial a} = -2 \sum_{i=1}^N (y_i - ax_i - b)x_i = 0$$

$$\frac{\partial f(a, b)}{\partial b} = -2 \sum_{i=1}^N (y_i - ax_i - b) = 0$$

On obtient :

$$\sum_{i=1}^N x_i y_i = a \sum_{i=1}^N x_i^2 + b \sum_{i=1}^N x_i \quad \sum_{i=1}^N y_i = a \sum_{i=1}^N x_i + Nb$$

En divisant $\sum_{i=1}^N y_i = a \sum_{i=1}^N x_i + Nb$ par N , il vient

$$\bar{y} = a\bar{x} + b \implies b = \bar{y} - a\bar{x}$$

En remplaçant b par son expression dans $\sum_{i=1}^N x_i y_i = a \sum_{i=1}^N x_i^2 + b \sum_{i=1}^N x_i$, on obtient

$$\sum_{i=1}^N x_i y_i = a \sum_{i=1}^N x_i^2 + (\bar{y} - a\bar{x}) \sum_{i=1}^N x_i$$

On trouve

$$\sum_{i=1}^N x_i y_i - \frac{1}{N} \sum_{i=1}^N x_i \sum_{i=1}^N y_i = a \left(\sum_{i=1}^N x_i^2 - \frac{1}{N} \left(\sum_{i=1}^N x_i \right)^2 \right)$$

Donc

$$NCov(x, y) = aNV(x) \implies a = \frac{Cov(x, y)}{V(x)}$$

Exemple: 4.8.1

Si on reprend l'exemple de la relation entre le taux d'investissement et le taux de croissance économique. On a

- $\bar{y} = 5.33$; $\bar{x} = 24.74$
- $V(x) = 39.11$
- $Cov(x, y) = 12.14$
- On trouve $a = \frac{12.14}{39.11} = 0.31$ et $b = -2.26$

D'où l'équation de la droite de régression est $y = 0.31x - 2.26$.

On constate ainsi que la valeur de a est positive, illustrant bien l'existence d'une relation positive entre les deux variables : lorsque le taux d'investissement augmente, la croissance augmente également.

4.8.4 Corrélation

Définition 4.8.2

On appelle coefficient de corrélation linéaire entre x et y le réel r défini par :

$$r = \frac{Cov(x, y)}{\sqrt{V(x)V(y)}}.$$

Remarques:

- On a toujours $-1 \leq r \leq 1$
- Le nuage des points (x_i, y_i) est une droite si, et seulement si : $r = 1$ (droite à pente positive) ou $r = -1$ (droite à pente négative).
- Si $|r|$ est voisin de 1, on dit qu'il existe une forte corrélation linéaire entre x et y .

Commentaires sur le coefficient de corrélation linéaire

- Un coefficient de corrélation linéaire égal à zéro n'implique pas nécessairement une absence de corrélation entre les deux variables étudiées. Il peut en effet exister une forte corrélation

non linéaire entre les variables, qui ne peut être prise en compte par une droite de régression.

- Une valeur élevée du coefficient de corrélation (proche de 1 en valeur absolue) n'implique pas nécessairement une forte dépendance entre les deux variables considérées. Il se peut en effet qu'une troisième variable agisse sur les deux variables étudiées, conduisant mécaniquement à une valeur élevée du coefficient de corrélation.

Les ventes de crèmes glacées et le nombre de noyades. Il serait incorrect de déduire, de l'observation d'une hausse des valeurs prises par ces deux variables durant l'été, l'existence d'une corrélation entre les deux séries. Ces deux variables ne sont en effet liées entre elles que par l'influence d'une troisième variable : la température, qui est plus élevée en été.

- Corrélation et causalité sont deux concepts différents qu'il convient de ne pas confondre : le calcul du coefficient de corrélation linéaire entre les variables x et y nous permet de dire si ces deux variables sont ou non liées entre elles, mais ne nous permet pas d'établir un lien de causalité. En d'autres termes, il ne permet pas de déterminer si x cause y ou si y cause x .

4.8.5 Qualité d'une régression

Même si r nous permet d'apprécier le degré de corrélation linéaire entre x et y , il est possible de recourir à un indicateur plus général permettant de mesurer l'intensité de la liaison entre deux variables. Cet indicateur, appelé coefficient de détermination.

On a

$$y_i - \bar{y} = (y_i - \hat{y}_i) + (\hat{y}_i - \bar{y})$$
$$\sum_{i=1}^N (y_i - \bar{y})^2 = \sum_{i=1}^N (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Variance totale = Variance expliquée + Variance résiduelle

$$V(y) = V(\hat{y}) + V(e)$$

$\hat{y}$: est la valeur située sur la droite de régression $\hat{y} = ax + b$, la valeur estimée de y .

$e = y - \hat{y}$ l'écart entre la valeur observée de y et $\hat{y}$. (appelé aussi résidu)

Définition 4.8.3

Le coefficient de détermination, noté R^2 , est défini comme le rapport entre la variance expliquée et

la variance totale :

$$R^2 = \frac{\text{Variance expliquée}}{\text{Variance totale}} = \frac{V(\hat{y})}{V(y)} = 1 - \frac{\text{Variance résiduelle}}{\text{Variance totale}} = 1 - \frac{V(e)}{V(y)}$$

Le coefficient de détermination mesure ainsi la part ou le pourcentage de variance expliquée par la régression. R^2 fournit une mesure du pouvoir explicatif de la régression. On a par construction :

$$0 \leq R^2 \leq 1.$$

Remarques:

- $R = 0$ signifie que la variance expliquée est nulle : la régression n'explique pas le nuage de points, les variables x et y ne sont pas liées entre elles.
- $R^2 = 1$: signifie que la régression explique parfaitement le lien entre x et y et la droite d'ajustement passe par tous les points du nuage.
- Plus la valeur de R^2 est proche de 1, plus la variance expliquée est proche de la variance totale et meilleure est la qualité de la régression.
- R^2 correspondant au carré du coefficient de corrélation linéaire entre x et y

$$R^2 = \frac{\text{Cov}(x, y)^2}{V(x)V(y)}$$

Exemple: 4.8.2

Le calcul du coefficient de détermination associé à la régression du taux de croissance sur le taux d'investissement nous donne :

$$R^2 = \frac{12.14^2}{39.11 \times 4.65} = 0.81$$

On en déduit que le taux d'investissement explique 81% de la variance du taux de croissance économique.