

rapport TP4 : MapReduce avec Hadoop Streaming

Nom : yassine ennajai

TP : TP4 — Job MapReduce en Python avec Hadoop Streaming

1. Captures d'écran


Ajoute ici les captures d'écran demandées :

- Exécution du job Hadoop Streaming

```
vboxuser@ubuntu:~$ hadoop jar /usr/local/hadoop/share/hadoop/tools/lib/hadoop-streaming-3.4.2.jar \
-input /user/tp4/streaming/input \
-output /user/tp4/streaming/output \
-mapper mapper.py \
-reducer reducer.py \
-file mapper.py \
-file reducer.py
2025-11-19 14:58:02,003 WARN streaming.StreamJob: -file option is deprecated, please use generic option -files instead.
packageJobJar: [mapper.py, reducer.py] [] /tmp/streamjob2045564610518999840.jar tmpDir=null
2025-11-19 14:58:14,948 WARN impl.MetricsSystemImpl: JobTracker metrics system already initialized!
2025-11-19 14:58:15,858 INFO mapred.FileInputFormat: Total input files to process : 1
2025-11-19 14:58:15,903 INFO mapreduce.JobSubmitter: number of splits:1
2025-11-19 14:58:16,316 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_local1320298376_0001
2025-11-19 14:58:16,320 INFO mapreduce.JobSubmitter: Executing with tokens: []
2025-11-19 14:58:17,024 INFO mapred.LocalDistributedCacheManager: Localized file:/home/vboxuser/mapper.py as file:/tmp/hadoop-vboxuser/mapred/local/job_local1320298376_0001_42ef1b8b-0f6a-4989-9c22-437df4a936cd/mapper.py
2025-11-19 14:58:17,114 INFO mapred.LocalDistributedCacheManager: Localized file:/home/vboxuser/reducer.py as file:/tmp/hadoop-vboxuser/mapred/local/job_local1320298376_0001_4e515619-1716-46b7-bf21-e20e648951dd/reducer.py
2025-11-19 14:58:17,404 INFO mapreduce.Job: The url to track the job: http://localhost:8080/
2025-11-19 14:58:17,408 INFO mapreduce.Job: Running job: job_local1320298376_0001
2025-11-19 14:58:17,415 INFO mapred.LocalJobRunner: OutputCommitter set in config null
2025-11-19 14:58:17,418 INFO mapred.LocalJobRunner: OutputCommitter is org.apache.hadoop.mapred.FileOutputCommitter
2025-11-19 14:58:17,445 INFO output.FileOutputCommitter: File Output Committer Algorithm version is 2
2025-11-19 14:58:17,445 INFO output.FileOutputCommitter: FileOutputCommitter skip cleanup _temporary folders under output directory:false, ignore cleanup failures: false
2025-11-19 14:58:17,583 INFO mapred.LocalJobRunner: Waiting for map tasks
2025-11-19 14:58:17,602 INFO mapred.LocalJobRunner: Starting task: attempt_local1320298376_0001_m_000000_0
2025-11-19 14:58:17,719 INFO output.FileOutputCommitter: File Output Committer Algorithm version is 2
2025-11-19 14:58:17,721 INFO output.FileOutputCommitter: FileOutputCommitter skip cleanup _temporary folders under output directory:false, ignore cleanup failures: false
2025-11-19 14:58:17,785 INFO mapred.Task: Using ResourceCalculatorProcessTree : [ ]
2025-11-19 14:58:17,817 INFO mapred.MapTask: Processing split: hdfs://localhost:9000/user/tp4/streaming/input/data.txt:0+63
2025-11-19 14:58:17,915 INFO mapred.MapTask: numReduceTasks: 1
2025-11-19 14:58:17,992 INFO mapred.MapTask: (EQUATOR) 0 kvi 26214396(104857584)
2025-11-19 14:58:17,992 INFO mapred.MapTask: mapreduce.task.io.sort.mb: 100
2025-11-19 14:58:17,992 INFO mapred.MapTask: soft limit at 83886080
2025-11-19 14:58:17,992 INFO mapred.MapTask: bufstart = 0; bufvoid = 104857600
2025-11-19 14:58:17,992 INFO mapred.MapTask: kvstart = 26214396; length = 6553600
2025-11-19 14:58:18,004 INFO mapred.MapTask: Map output collector class = org.apache.hadoop.mapred.MapTask$MapOutputBuffer
2025-11-19 14:58:18,029 INFO streaming.PipeMapRed: PipeMapRed exec [/home/vboxuser/./mapper.py]
2025-11-19 14:58:18,052 INFO Configuration.deprecation: mapred.work.output.dir is deprecated. Instead, use mapreduce.task.output.dir
2025-11-19 14:58:18,061 INFO Configuration.deprecation: mapred.local.dir is deprecated. Instead, use mapreduce.cluster.local.dir
2025-11-19 14:58:18,061 INFO Configuration.deprecation: map.input.file is deprecated. Instead, use mapreduce.map.input.file
2025-11-19 14:58:18,065 INFO Configuration.deprecation: map.input.length is deprecated. Instead, use mapreduce.map.input.length
```

- Résultat dans HDFS / interface YARN

```
vboxuser@ubuntu:~$ hdfs dfs -cat /user/tp4/streaming/output/part-00000
avec 1
big 2
bonjour 2
data 2
hadoop 1
mapreduce 1
python 1
vboxuser@ubuntu:~$
```



2. Description du fonctionnement (Map → Shuffle → Reduce)

Mapper

Le mapper lit chaque ligne du fichier, découpe en mots, et affiche pour chaque mot :

```
mot      1
```

Il prépare donc les données pour l'étape suivante.s

Shuffle / Sort

Hadoop trie automatiquement les clés (les mots) et regroupe toutes les valeurs du même mot ensemble. Cette étape se fait avant que les reducers reçoivent les données.

Reducer

Le reducer reçoit chaque mot avec toutes ses valeurs et calcule la somme pour obtenir :

```
mot      total
```

C'est la sortie finale du job.

4. Réponses aux questions d'analyse

1. Rôle du mapper :

Lire les lignes d'entrée, extraire les mots et envoyer des couples (mot, 1).

2. Pourquoi Hadoop trie les clés ?

Pour regrouper les mêmes mots ensemble avant le reducer.

3. Pourquoi gérer la fin du fichier dans le reducer ?

Pour afficher le dernier mot traité, sinon il sera perdu.

4. Que se passe-t-il si on enlève `-file mapper.py` `-file reducer.py` ?

Les nœuds Hadoop ne recevront pas les scripts Python et le job va échouer.

5. Différence entre MapReduce Java et Hadoop Streaming ?

- En Java : code MapReduce classique sous forme de classes.
- En Streaming : on peut écrire mapper/reducer dans n'importe quel langage (ex : Python) via stdin/stdout.