



Conception d'un Data Warehouse

Plan


- Introduction
- Représentation multidimensionnelle
- Implémentation d'un Datawarehouse
 - Modélisation: étoile et flocon, constellation
 - Conception d'un Datawarehouse

BI

- Objectifs
 - Transformer un système d'information orienté production en un système décisionnel
 - Exemples: opérations orientées production
 - Gestion des commandes
 - Gestion de stocks
 - Gestion des clients et des fournisseurs
 - Gestion des ressources humaines
 - ...
 - Exemples: opérations orientées décision
 - Meilleur client par régions dans une période
 - Evolution de la part du marché d'un produit
 - Nombre d'employés d'une entreprise par grade, par classe d'âge, par sexe, par affectation, par spécialité, ...
 - Nombre de ventes par vendeur, par région, par mois
 - Nombre de vente par vendeur, par fournisseur, par mois
 - Identification du profil des employés les plus performants.

Entrepôt de données (Data Warehouse)

- Définition de Bill Inmon (1996)
 - « Le Data Warehouse est une collection de données **orientées sujet, intégrées, non volatiles et historisées**, organisées pour le support d'un processus d'aide à la décision. »
 - **Orientées sujet** : thèmes par activités majeurs
 - **Intégrées**: diverses sources de données
 - **Non Volatiles** : ne pas supprimer les données du DW
 - **Historisées**: trace des données, suivre l'évolution des indicateurs.



Base de données transactionnelle VS Entrepôt de données

- Sachant que un Data Warehouse est généralement une base de données.

Base de données: Data base	Entrepôt de données: Data Warehouse
Utilisé pour traitement transactionnel en ligne (OLTP). Les données sont manipulées par des utilisateurs finaux (end-users)	Utilisé pour traitement analytique en ligne (OLAP). Les données historisées sont lues par les utilisateurs qui prennent les décisions
Les tables et les jointures sont complexes car elles sont normalisées (pour SGBDR). Ceci est pour réduire la redondance des données et ainsi réduire l'espace de stockage.	Les tableaux et les jointures sont simples car ils sont de-normalisés. Ceci est pour réduire le temps de réponse des requêtes d'analyse.
La conception d'une base de données relationnelle est basée sur le modèle entité association	La conception d'un Data Warehouse est basée sur une modélisation multidimensionnelle des données (pas des entités)
Optimisé pour les opérations d'écriture (insertion et mise à jour)	Optimisé pour les opérations de lecture
Moins performant pour les requêtes d'analyse	Haute performance pour les requêtes analytiques.

Base de données transactionnelle VS Entrepôt de données

- OLTP (Online Transaction Processing) Traitement des Transactions en Ligne
 - Est caractérisée par un grand nombre de transactions qui sont en ligne (INSERT, UPDATE DELETE).
 - L'accent principal pour les systèmes OLTP est mis sur le traitement des requêtes très rapide, le maintien de l'intégrité des données dans des environnement multiutilisateur et une efficacité mesurée par le nombre de transactions par seconde.
 - Dans une base de données OLTP, il y a des données qui sont détaillées et d'autres actuelles, et le schéma utilisé dans les bases de données transactionnelles est le modèle de l'entité-association.

Base de données transactionnelle VS Entrepôt de données

- OLTP vs OLAP
 - On peut diviser les systèmes informatiques en transactionnel (OLTP) et analytique (OLAP).
 - Les **systèmes OLTP** fournissent des données comme **sources pour les Data Warehouse**, tandis que les **systèmes OLAP aident à les analyser**.

Base de données transactionnelle VS Entrepôt de données

- OLAP (Online Analytical Processing) Traitement Analytique en Ligne
 - Est caractérisée relativement par un faible nombre de transactions.
 - Les requêtes sont souvent très complexes et impliquent des agrégations.
 - Pour les systèmes OLAP, le temps de réponse est une mesure de l'efficacité.
 - Les applications OLAP sont largement utilisés par les techniques de Datamining.
 - Dans les bases de données OLAP, les données sont stockées d'une façon agrégée (historisées) suivant des schémas multidimensionnels (généralement schémas en étoile)

Type de requêtes

- Dans un SGBD de type OLTP
 - Les données sont normalisées et représentées sous forme tabulaire.

T_Produit				
ID	Designation	PrixAchat	PrixConseillVente	Nature

T_Vente				
ID	Id_Produit	Date	Qte	PrixVente

T_Magasin				
ID	Enseigne	Adresse	Ville	Dept

T_Nat2Cat	
Nature	Catégorie

T_Cat2Ray	
Catégorie	Rayon

T_Dep2Reg	
Dept	Region

- OLTP: requêtes simples « qui, quoi »
 - Jointure: les produits vendus par le vendeur Y
 - Le prix du produit X
- OLAP: requêtes complexes: agrégation
 - Le montant total par ville et par produit
 - Le montant total par région et par catégorie en 2014

On peut agréger les données (group by) avec jointure: très coûteux et il faut calculer pour chaque utilisation.

Type de requêtes

- Dans un SGBD de type OLTP (suite)
 - Donner les requêtes pour calculer le montant total par région et par catégorie et par année:


```
SELECT region, categorie, sum(qte*prixvente) FROM T_vente, T_produit, T_magasin, T_dep2reg, T_nat2cat WHERE T_produit.ID = vente.ID AND vente.ID_Mag = magasin.ID AND T_produit.nature = T_nat2cat.nature AND T_magasin.dept = T_dep2reg.dept GROUP BY region, categorie, year(date)
```
 - Donner les requêtes pour calculer le montant total par région et par catégorie en 2014:


```
SELECT region, categorie, sum(qte*prixvente) FROM T_vente, T_produit, T_magasin, T_dep2reg, T_nat2cat WHERE T_produit.ID = vente.ID AND vente.ID_Mag = magasin.ID AND T_produit.nature = T_nat2cat.nature AND T_magasin.dept = T_dep2reg.dept AND year(date) = 2014 GROUP BY region, categorie
```

Type de requêtes

- Dans un SGBD de type OLTP
 - Les données sont normalisées et représentées sous forme tabulaire.

T_Produit				
ID	Designation	PrixAchat	PrixConseillVente	Nature

T_Vente				
ID	Id_Produit	Date	Qte	PrixVente

T_Magasin				
ID	Enseigne	Adresse	Ville	Dept

T_Nat2Cat	
Nature	Catégorie

T_Cat2Ray	
Catégorie	Rayon

T_Dep2Reg	
Dept	Region

- Donner les requêtes pour calculer le montant total par ville et par produit:


```
SELECT ville, Designation, sum(qte*prixvente) FROM T_vente, T_Produit, T_Magasin WHERE T_produit.ID = T_vente.ID AND T_vente.Id_Mag = T_magasin.ID GROUP BY ville, Designation
```
- Donner les requêtes pour calculer le montant total par région et par catégorie:


```
SELECT region, categorie, sum(qte*prixvente) FROM T_vente, T_produit, T_magasin, T_dep2reg, T_nat2cat WHERE T_produit.ID = vente.ID AND vente.ID_Mag = magasin.ID AND T_produit.nature = T_nat2cat.nature and T_magasin.dept = T_dep2reg.dept GROUP BY region, categorie
```

	OLTP (systèmes opérationnels)	OLAP (Data Warehouse)
Source de données	Données opérationnelles; OLTPs sont la source d'origine des données	Données de consolidation; les données OLAP proviennent de différentes bases de données OLTP
But de données	Pour contrôler et exécuter des tâches fondamentales de l'entreprise	Pour aider à la planification, la résolution de problèmes, et l'aide à la décision
Quelles données	Révèle un snapshot sur le business process en cours	Vues multidimensionnelles de toutes sortes d'activités commerciales
Insertion et mise à jour	Insertions et mises à jour rapides et courtes effectuées par les utilisateurs finaux	Utilisation de lots de données de longue durée, périodiques et actualisées
Requêtes	Requêtes relativement simples standardisées retournant relativement peu de données	Souvent, requêtes complexes impliquant des agrégations
Vitesse de traitement	Généralement très rapide	Dépend de la quantité de données, et de types de requêtes. Requêtes complexes peuvent prendre plusieurs heures, la vitesse de requête peut être améliorée par la création d'index
Espace requis	Peut être relativement faible si les données historiques sont archivées	Plus grande en raison de l'existence de structures d'agrégation et de données historisées. Nécessite plus d'index que l'OLTP
Conception de la base	Normalisées avec plusieurs tables	Typiquement dé-normalisé avec moins de tables, l'utilisation d'un modèle en étoile et /ou en flocon de neige
Sauvegarde et restauration	Les données opérationnelles sont essentielles pour diriger l'entreprise, la perte de données est susceptible d'entraîner des pertes financières importantes	Au lieu de sauvegardes régulières, certains environnements peuvent envisager un rechargement (reloading) des données OLTP comme une méthode de récupération

Représentation multidimensionnelle

- Pour aider les décideurs, les données sous forme tabulaire ne permet pas un traitement orienté sujet (thématique)
- Utiliser une représentation multidimensionnelle OLAP (ventes par vendeur, par date, par région, par ville ,...)
- Pour opter pour les OLAP
 - Disposer d'une structure de stockage adaptée à l'OLAP, permettant de représenter les données dans plusieurs dimensions, manipuler les données facilement et efficacement.

Représentation multidimensionnelle


- Représentation des données d'un Data Warehouse sous forme multidimensionnelle: « cube »:

produit	région	vente
écrou	Est	50
écrou	Ouest	60
écrou	Centre	110
vis	Est	70
vis	Ouest	80
vis	Centre	90
boulon	Est	120
boulon	Ouest	10
boulon	Centre	20
joint	Est	50
joint	Ouest	40
joint	Centre	70

Représentation multidimensionnelle par thématique


	Est	Ouest	Centre
écrous	50	60	110
vis	70	80	90
boulons	120	10	20
joints	50	40	70

Multidimensionnelle sous forme de Cube



Modélisation du Data Warehouse

- SGBDR: modélisation conceptuelle basée l'entité- association
- Systèmes décisionnels (DW): Introduit par R. Kimball, un modèle dimensionnel vise à présenter les données sous une forme intuitive qui permet des accès très performants. Il permet de considérer un sujet analysé dans un espace à plusieurs axes d'analyse. Les données sont organisées de manière à mettre en évidence les sujets traités (tables de faits) et le contexte de la réalisation des faits (tables de dimensions).



Modélisation du Data Warehouse

- Systèmes décisionnels (DW): Modélisation basées sur la notion de **dimensions –mesures-faits**.
 - Mesures: valeurs numériques sur lesquelles portent les analyses (ex: montant de ventes, quantité vendue, ect..)
 - Obtenues par des opérations d'agrégation.
 - Dimensions: vues depuis lesquels les mesures peuvent être observées (ex: date, localisation, produit, ect)
 - Stockées dans les tables de dimensions.
 - Faits: valeurs des mesures, mesurées ou calculées, pour les différentes dimensions.

Table Fait

- Une table de fait est une table qui contient des données observables (les faits), que l'on possède sur un sujet que l'on veut étudier, selon divers axes d'analyses (dimension).
- Un fait représente le sujet d'analyse, il permet de mesurer l'activité au sein d'une organisation. Par exemple, la note d'un étudiant, le nombre d'heures enseigné, sont des faits qui peuvent être considérés pour mesurer l'activité au sein d'une université.
- Cette mesure peut être calculée selon les différents axes d'analyse. Par exemple, la moyenne est une mesure calculée à partir des notes d'un étudiant, pour un semestre donné, pour une année donnée.
- La valeur de la mesure est en général une valeur numérique. Tous les faits (mesure) sont stockés dans une table de faits. Cette dernière est composée d'un ensemble de clés étrangères (pointant vers les tables de dimensions) et des mesures du fait.
- Une table de faits est caractérisée par un petit nombre de colonnes et un très grand nombre de lignes. Par exemple, la table de faits recensant les notes des étudiants contiendra toutes les notes de toutes les matières de tous les étudiants inscrits à l'université depuis sa création.

Type des Faits

Les types de faits (ou mesures) tels que additif, semi-additif et non-additif désignent le type de mesure dans un entrepôt de données.

1. Faits additifs :

- Un fait additif est une mesure qui peut être additionnée sur toutes les dimensions sans restriction. Cela signifie que vous pouvez agréger ces mesures sur n'importe quelle dimension (temps, produit, client, etc.) de manière cohérente.
- Exemple: Le montant des ventes ou la quantité vendue. Ces mesures peuvent être additionnées sur plusieurs dimensions (par exemple, le total des ventes par jour, par produit, par client, etc.).
 - Si vous avez vendu 10 produits le lundi et 15 produits le mardi, le total sur deux jours est 25. Le montant est simplement la somme de ces ventes.
 - Si un client achète 100 \$ aujourd'hui et 200 \$ demain, vous pouvez agréger ces ventes pour obtenir 300 \$.

Type des Faits

2. Faits semi-additifs :

- Un fait semi-additif est une mesure qui peut être additionnée sur certaines dimensions mais pas sur toutes. Typiquement, ce type de mesure ne peut pas être agrégé sur la dimension de temps.
- Exemple: Le stock ou le solde de compte bancaire. Par exemple, vous ne pouvez pas simplement additionner les valeurs de stock au cours du temps, car cela donnerait une interprétation erronée du total.
 - Si une entreprise a un stock de 100 unités en janvier et de 120 en février, vous ne pouvez pas dire que le total est de 220 unités sur deux mois. Seule la valeur la plus récente (février : 120 unités) est significative pour le stock actuel.
 - De même, un solde de compte ne peut pas être additionné sur différentes périodes (vous ne pouvez pas dire que vous aviez 5000 \$ en janvier et 6000 \$ en février, donc vous avez 11 000 \$ en tout).

Type des Faits

3. Faits non-additifs :

- Un fait non-additif est une mesure qui ne peut pas être additionnée sur aucune dimension. Ces mesures ne supportent pas l'agrégation, et vous devez utiliser d'autres techniques pour obtenir des résumés.
- Exemple: Un pourcentage, un taux ou une moyenne. Ces mesures ne peuvent pas être additionnées directement, car cela produirait un résultat incorrect.
 - Si le taux de retour de produits est de 5 % pour un produit en janvier et de 10 % en février, vous ne pouvez pas simplement additionner ces pourcentages pour dire que le taux global est de 15 %. Il faut calculer une moyenne pondérée en fonction des ventes totales de chaque mois.
 - De même, un prix moyen ne peut pas être directement additionné. Il faut soit recalculer la moyenne à partir des données sous-jacentes, soit utiliser une autre méthode d'agrégation.

Table Fait

La figure résume ce qu'est une table de faits.

Clés étrangères vers les dimensions

Dimensions dégénérées

Mesures

Table de fait	
Id_dim(FK)	
Id_dim(FK)	
....	
Id_dim(FK)	
Code_dim_dég1(DD)	
Code_dim_dég2(DD)	
Mesure 1	
Mesure 2	
Mesure 3	
....	

Clés Primaire