



PRÉPARATION DES DONNÉES

Réalisé par : Yassine Ennajai

INTRODUCTION

LA PRÉPARATION DES DONNÉES EST UNE ÉTAPE ESSENTIELLE DANS TOUT PROJET D'ANALYSE OU DE MACHINE LEARNING. ELLE CONSISTE À RENDRE LES DONNÉES PROPRES, COHÉRENTES ET PRÊTES POUR L'ANALYSE. CETTE ÉTAPE GARANTIT QUE LES RÉSULTATS OBTENUS SERONT FIABLES ET PRÉCIS.

PANDAS

PANDAS EST UNE BIBLIOTHÈQUE PYTHON OPEN-SOURCE CONÇUE POUR LA **MANIPULATION ET L'ANALYSE DES DONNÉES**. ELLE PERMET DE TRAITER DES DONNÉES COMPLEXES ET VOLUMINEUSES DE MANIÈRE **RAPIDE ET EFFICACE**.

PRINCIPALES CARACTÉRISTIQUES DE PANDAS :

- **DATAFRAME** : STRUCTURE DE DONNÉES EN 2 DIMENSIONS (TABLEAU) AVEC DES **LIGNES ET DES COLONNES**, SIMILAIRE À EXCEL.
- **SERIES** : STRUCTURE DE DONNÉES EN 1 DIMENSION (UNE SEULE COLONNE).
- **NETTOYAGE ET TRANSFORMATION DES DONNÉES** : GÉRER LES VALEURS MANQUANTES, SUPPRIMER LES DOUBLONS, CHANGER LES TYPES DE DONNÉES...
- **ANALYSE ET STATISTIQUES** : TRI, REGROUPEMENT, CALCUL DE LA MOYENNE, SOMME, MINIMUM, MAXIMUM, ETC.
- **COMPATIBILITÉ AVEC PLUSIEURS FORMATS** : CSV, EXCEL, SQL,

NUMPY (NUMERICAL PYTHON)

EST UNE BIBLIOTHÈQUE FONDAMENTALE DE PYTHON UTILISÉE POUR LE CALCUL SCIENTIFIQUE ET NUMÉRIQUE. ELLE PERMET DE MANIPULER DES TABLEAUX MULTIDIMENSIONNELS (ARRAYS) ET D'EFFECTUER DES CALCULS MATHÉMATIQUES RAPIDES ET EFFICACES.

PRINCIPALES CARACTÉRISTIQUES DE NUMPY :

1. ARRAY

STRUCTURE DE DONNÉES PRINCIPALE DE NUMPY. C'EST UN TABLEAU PLUS RAPIDE ET PLUS PERFORMANT QU'UNE LISTE PYTHON CLASSIQUE.

2. CALCULS MATHÉMATIQUES

OPÉRATIONS VECTORISÉES (ADDITION, MULTIPLICATION, MOYENNE, ETC.) BEAUCOUP PLUS RAPIDES QUE LES BOUCLES CLASSIQUES.

③ FONCTIONS MATHÉMATIQUES AVANCÉES
ALGÈBRE LINÉAIRE, STATISTIQUES, TRIGONOMÉTRIE,
MATRICES, ETC.

④ BASE DES BIBLIOTHÈQUES DATA SCIENCE
DES BIBLIOTHÈQUES COMME PANDAS, SCIKIT-LEARN ET
MATPLOTLIB UTILISENT NUMPY EN ARRIÈRE-PLAN.

NETTOYAGE DES DONNÉES (DATA CLEANING)

Le nettoyage vise à **corriger ou supprimer** les **erreurs et incohérences** dans les données.

Principales tâches :

- **Suppression des doublons** : retirer les lignes répétées qui pourraient fausser les analyses.

Nous téléchargeons les données à partir du fichier housing.csv

```
import pandas as pd
data = pd.read_csv("housing.csv")
data
```

✓ 0.8s

UNE VÉRIFICATION DES DOUBLONS EST EFFECTUÉE AFIN D'IDENTIFIER LES LIGNES
RÉPÉTÉES DANS LES DONNÉES

```
duplicates = data.duplicated().sum()  
print(duplicates)
```

✓ 0.0s

2

Nous supprimons les doublons afin d'éviter toute redondance dans les données et d'améliorer la qualité du dataset.

```
data = data.drop_duplicates()
```

GESTION DES VALEURS MANQUANTES : REMPLIR LES VALEURS ABSENTES AVEC UNE MOYENNE, UNE MÉDIANE OU LES S

```
print(data.isnull().sum())
```

✓ 0.0s

longitude	0
latitude	0
housing_median_age	0
total_rooms	0
total_bedrooms	207
population	0
households	0

près la vérification des valeurs manquantes, nous constatons que seule la variable `total_bedrooms` contient des valeurs nulles (207 valeurs manquantes), tandis que les autres variables sont complètes

POUR TRAITER LES VALEURS MANQUANTES DANS LA VARIABLE ***TOTAL_BEDROOMS***,
NOUS AVONS CHOISI DE LES REMPLACER PAR LA **MOYENNE** DE LA COLONNE

```
data['total_bedrooms'] = data['total_bedrooms'].fillna(  
    data['total_bedrooms'].mean())  
✓ 0.0s
```

LA DÉTECTION DES VALEURS ABERRANTES (OUTLIERS):

LES VALEURS ABERRANTES SONT DES OBSERVATIONS EXTRÊMES (TRÈS GRANDES OU TRÈS PETITES) QUI PEUVENT :

- INFLUENCER FORTEMENT LA MOYENNE
- FAUSSER LES ANALYSES STATISTIQUES
- DIMINUER LA PERFORMANCE DES MODÈLES DE MACHINE LEARNING

IL EST DONC IMPORTANT DE LES IDENTIFIER AVANT DE PASSER À LA PHASE DE TRANSFORMATION.

MÉTHODES DE DÉTECTION DES OUTLIERS

MÉTHODE DE L'IQR(INTERQUARTILE RANGE):

Méthode Boxplot

```
Q1 = data['total_rooms'].quantile(0.25)
Q3 = data['total_rooms'].quantile(0.75)
IQR = Q3 - Q1

outliers = data[(data['total_rooms'] < Q1 - 1.5 * IQR) |
                (data['total_rooms'] > Q3 + 1.5 * IQR)]

print("Nombre d'outliers :", len(outliers))
```

✓ 0.0s

Nombre d'outliers : 1287

Méthode Z-Score

```
import numpy as np

mean = np.mean(data["total_rooms"])
std = np.std(data["total_rooms"])

data["Zscore"] = (data["total_rooms"] - mean) / std

outliers = data[np.abs(data["Zscore"]) > 3]
print(outliers)
```

0.0s

```
import seaborn as sns
sns.boxplot(x=data['total_rooms'])
```

✓ 2.0s

Supprimer les outliers (Removal):

On élimine les lignes contenant des valeurs extrêmes.

```
lower = Q1 - 1.5 * IQR  
upper = Q3 + 1.5 * IQR  
data_clean = data[(data["total_rooms"] >= lower) & (data["total_rooms"] <= upper)]
```

✓ 0.0s
