

Compte Rendu - Analyse R

I. Introduction

Ce travail présente la manipulation de vecteurs, opérations arithmétiques, statistiques de base, tableaux de fréquences, quantiles, variance biaisée et non biaisée, ainsi que la génération de graphiques en langage R.

2. Code R utilisé

Le code R complet utilisé dans ce TP est présenté dans les captures ci-dessous :

```
> # Variables simples
>
> x = 3
> y = 4
> res = y + x
> a = 3*x - y
>
> cat("res =", res, "\n")
res = 7
> cat("a =", a, "\n")
a = 5
.

> # Vecteurs S1 et S2
>
> S1 = c(3,5,1,12,20)
> S2 = c("rouge","bleu","vert")
>
> cat("mode S1 =", mode(S1), "\n")
mode S1 = numeric
> cat("mode S2 =", mode(S2), "\n")
mode S2 = character
>
> cat("length S1 =", length(S1), "\n")
length S1 = 5
> cat("length S2 =", length(S2), "\n")
length S2 = 3
.

> # Remplacement dans s
>
> s = c(12,10,11,19,9,10)
> s[s == 10] = 100
>
> cat("s after replacing 10 by 100 =", s, "\n")
s after replacing 10 by 100 = 12 100 11 19 9 100
>
```

```

>
> # W deja faite avec l'instruction w = scan()
>
> cat("w =", w, "\n")
w = 12 13 14 15 12 2 23 3 4 5 2 6 7 86 6 5 54 3 12 34 21 34 23
>
> # Tri + inversion
> cat("rev(sort(w)) =", rev(sort(w)), "\n")
rev(sort(w)) = 86 54 34 34 23 23 21 15 14 13 12 12 12 7 6 6 5 5 4 3 3 2 2
>
> # Effectifs
> eff = table(w)
> cat("table w =\n")
table w =
> print(eff)
w
 2  3  4  5  6  7 12 13 14 15 21 23 34 54 86
2  2  1  2  2  1  3  1  1  1  2  2  1  1
>
> cat("frequences w =\n")
frequences w =
> print(eff / length(w))
w
      2      3      4      5      6
0.08695652 0.08695652 0.04347826 0.08695652 0.08695652
      7      12      13      14      15
0.04347826 0.13043478 0.04347826 0.04347826 0.04347826
      21      23      34      54      86
0.04347826 0.08695652 0.08695652 0.04347826 0.04347826
>
> # Cumul
> cat("cumsum(w) =", cumsum(w), "\n")
cumsum(w) = 12 25 39 54 66 68 91 94 98 103 105 111 118 204 210 215 269 272 284 318 339 373 396

> w_sort = sort(w)
> cat("w sorted =", w_sort, "\n")
w sorted = 2 2 3 3 4 5 5 6 6 7 12 12 12 13 14 15 21 23 23 34 34 54 86
>
> # Table + freq
> effe = table(w_sort)
> cat("table w_sort =\n")
table w_sort =
> print(effe)
w_sort
 2  3  4  5  6  7 12 13 14 15 21 23 34 54 86
2  2  1  2  2  1  3  1  1  1  1  2  2  1  1
>
> cat("frequences w_sort =\n")
frequences w_sort =
> print(effe / length(w_sort))
w_sort
      2      3      4      5      6
0.08695652 0.08695652 0.04347826 0.08695652 0.08695652
      7      12      13      14      15
0.04347826 0.13043478 0.04347826 0.04347826 0.04347826
      21      23      34      54      86
0.04347826 0.08695652 0.08695652 0.04347826 0.04347826

```

```

> # Statistiques
> cat("mean =", mean(w_sort), "\n")
mean = 17.21739
> cat("median =", median(w_sort), "\n")
median = 12
>
> cat("quantiles =\n")
quantiles =
> print(quantile(w_sort))
 0%  25%  50%  75% 100%
  2    5   12   22   86
>
> q1 = quantile(w_sort, probs = .25, names = FALSE)
> q3 = quantile(w_sort, probs = .75, names = FALSE)
>
> cat("IQ =", q3 - q1, "\n")
IQ = 17
~
~
> # Variance biaisee et non biaisee
>
>
> # Variance biaisee (diviser par n)
> var_biased = mean((w_sort - mean(w_sort))^2)
> cat("variance biaisee (division par n) =", var_biased, "\n")
variance biaisee (division par n) = 371.3006
>
> # Variance non biaisee (division par n-1)
> var_unbiased = var(w_sort)
> cat("variance non biaisee (var()) =", var_unbiased, "\n")
variance non biaisee (var()) = 388.1779
>
> # Verification formule pour non biaisee
> var_unbiased_formula = var_biased * length(w_sort) / (length(w_sort) - 1)
> cat("variance non biaisee (formule) =", var_unbiased_formula, "\n")
variance non biaisee (formule) = 388.1779
>
>
> cat("summary =\n")
summary =
> print(summary(w_sort))
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  2.00   5.00   12.00   17.22   22.00   86.00
>
~
~
plot(table(w_sort), col='red', main='titre', ylab='axe y')
hist(w_sort, col='blue')

```

3. Résultats détaillés


Les sorties obtenues dans R sont illustrées dans les sections précédentes et permettent d'interpréter chaque étape de l'analyse statistique appliquée au vecteur w.

.Variance biaisée vs non biaisée


La variance biaisée est calculée en divisant par n. La variance non biaisée (estimation statistique correcte) divise par n-1. R utilise var() pour la version non biaisée.

. Graphiques

Histogramme du vecteur `w_sort` :



Graphique des effectifs (plot) :



4. Analyse statistique du jeu de données `mtcars`

4.1 Exploration des données

Le jeu `mtcars` est chargé et sa structure examinée avec `str()`, permettant d'identifier le nombre d'observations et le type des variables.

```

R 4.5.2 · ~/
> data(mtcars)
> str(mtcars)
'data.frame':   32 obs. of  11 variables:
 $ mpg : num  21 21 22.8 21.4 18.7 18.1 14.3 24.4 22.8 19.2 ...
 $ cyl : num   6  6  4  6  8  6  8  4  4  6 ...
 $ disp: num  160 160 108 258 360 ...
 $ hp  : num  110 110 93 110 175 105 245 62 95 123 ...
 $ drat: num   3.9 3.9 3.85 3.08 3.15 2.76 3.21 3.69 3.92 3.92 ...
 $ wt  : num   2.62 2.88 2.32 3.21 3.44 ...
 $ qsec: num  16.5 17 18.6 19.4 17 ...
 $ vs  : num   0  0  1  1  0  1  0  1  1  1 ...
 $ am  : num   1  1  1  0  0  0  0  0  0  0 ...
 $ gear: num   4  4  4  3  3  3  4  4  4  4 ...
 $ carb: num   4  4  1  1  2  1  4  2  2  4 ...
>
> mpg = mtcars$mpg
> wt  = mtcars$wt
> hp  = mtcars$hp
> cyl = mtcars$cyl
> |

```

4.2 Statistiques descriptives

Les principales mesures de **mpg** sont calculées : minimum, maximum, moyenne, quartiles, variance et écart-type, pour résumer la consommation des véhicules.

```


Console Terminal Background Jobs
R 4.5.2 · ~/
> a = min(mpg)
> b = max(mpg)
> etendue = b - a
> print(paste("L'étendue est :", etendue))
[1] "L'étendue est : 23.5"
>
> # Moyenne
> mean_mpg = mean(mpg)
> print(paste("La moyenne de mpg est :", mean_mpg))
[1] "La moyenne de mpg est : 20.090625"
>
> # Quartiles
> q1 = quantile(mpg, probs = 0.25, names = FALSE)
> q2 = quantile(mpg, probs = 0.50, names = FALSE)
> q3 = quantile(mpg, probs = 0.75, names = FALSE)
>
> # Intervalle interquartile
> IQ = q3 - q1
> print(paste("L'intervalle interquartile (IQ) est :", IQ))
[1] "L'intervalle interquartile (IQ) est : 7.375"
>
> # Variance
> var_pop = mean((mpg - mean(mpg))^2)
> var_ech = sum((mpg - mean(mpg))^2) / (length(mpg) - 1)
>
> print(paste("Variance (population) :", var_pop))
[1] "Variance (population) : 35.188974609375"
> print(paste("Variance (échantillon) :", var_ech))
[1] "Variance (échantillon) : 36.3241028225806"
>
> # Écart-type
> sd_mpg = sd(mpg)
> print(paste("Écart-type :", sd_mpg))
[1] "Écart-type : 6.0269480520891"
> |

```


4.3 Visualisation


Des graphiques montrent la distribution de **mpg**, la dispersion des données et d'éventuelles valeurs aberrantes.

```
> hist(mpg, col = "red", breaks = 21,  
+      main = "Histogramme de mpg", xlab = "mpg")  
> |
```




```
> qqnorm(mpg, col = "blue", pch = 12, cex = 1.2)  
> qqline(mpg, col = "red")  
> |
```






4.4 Variable qualitative cyl

La variable **cyl** est convertie en facteur. Un tableau de fréquences et des graphiques illustrent la répartition des véhicules selon le nombre de cylindres.



4.5 Relation mpg – wt

Un nuage de points et le coefficient de corrélation permettent d'analyser la relation entre la consommation (**mpg**) et le poids (**wt**).




4.6 Paramètres de régression manuels

La pente et l'ordonnée à l'origine sont calculées manuellement à partir de la covariance et de la variance, pour comprendre la régression linéaire.

```
Console Terminal Background Jobs
R - R 4.5.2 · ~/
>
> mult = (N_mpg - 1) / N_mpg
>
> cov_corr = mult * cov(mpg, wt)
> var_corr = mult * var(wt)
>
> pente = cov_corr / var_corr
> print(paste("Pente :", pente))
[1] "Pente : -5.34447157272268"
>
> b = mean(mpg) - pente * mean(wt)
> print(paste("Ordonnée à l'origine :", b))
[1] "Ordonnée à l'origine : 37.285126167342"
>
> |
```


4.7 Régression linéaire avec R

La fonction `lm()` ajuste un modèle de **mpg** en fonction de **wt**, et la droite de régression est visualisée sur le nuage de points.



VI. Conclusion

L'analyse statistique du vecteur `w` permet d'illustrer différentes mesures essentielles : tendances centrales, dispersion, distribution des données et construction de graphiques. R facilite ces traitements via ses fonctions intégrées.