



**المدرسة العليا
للتكنولوجيا - قلعة السراغنة**
ÉCOLE SUPÉRIEURE DE TECHNOLOGIE
D'EL KELÂA DES SRAGHNA

**École Supérieure de Technologie – El Kelaa des Sraghna
DUT ID – S3
Année universitaire : 2025–2026**

TP N°2 : Statistique Appliquée (R)

Réalisé par : Yassine Ennajai

Introduction

Ce travail pratique a pour objectif de manipuler un jeu de données issu d'une enquête réalisée auprès des étudiants américains. À travers l'utilisation du logiciel **R**, nous effectuons des analyses statistiques descriptives, des transformations de variables ainsi que des modèles de régression linéaire afin d'étudier les relations entre certaines variables comme les frais de scolarité, les années d'études et les caractéristiques socio-économiques.

Exercice 1 : Description des données

Les données sont stockées dans le fichier **student.txt** et contiennent plusieurs variables décrivant le profil des étudiants (sexe, origine, niveau d'études des parents, distance université-domicile, frais de scolarité, etc.).

Question 1 : Importation des données

Nous importons le fichier *student.txt* dans R et nous l'enregistrons dans un data frame nommé **stu** afin d'observer sa structure.

```
stu <- read.table("chemin/student.txt", header = TRUE)
head(stu)

> stu <- read.table("C:/Users/chaym/Downloads/student.txt", header =TRUE)
> head(stu)
  female black hispanic dadcoll momcoll ownhome urban dist tuition ed incomehi county state
1      0     0         0      1      0      1      1 0.2 0.88915 12      1      35      11
2      1     0         0      0      0      1      1 0.2 0.88915 12      0      35      11
3      0     0         0      0      0      1      1 0.2 0.88915 12      0      35      11
4      0     1         0      0      0      1      1 0.2 0.88915 12      0      35      11
5      1     0         0      0      0      0      1 0.4 0.88915 13      0      29      11
6      0     0         0      0      0      1      1 0.4 0.88915 12      0      29      11
```

Question 2 : Calculs statistiques de base

Les commandes suivantes permettent de calculer des moyennes, quantiles et écarts types selon différentes conditions sur les données.

Ces commandes permettent d'analyser le comportement des frais de scolarité et des distances selon différents sous-groupes d'étudiants.

```

6      0      0      0      0      0      1      1 0.4 0.889
> mean(stu$tuition)
[1] 0.9131645
> mean(stu$tuition[stu$female == 1])
[1] 0.9126699
> mean(stu$tuition[stu$ed >= 14])
[1] 0.9274047
> mean(stu$tuition[!stu$ed < 14])
[1] 0.9274047
> quantile(stu$dist[stu$urban == 14] , 0.25)
25%
NA
> quantile(stu$dist[stu$urban == 1] , 0.25)
25%
0.2
> sd(stu$dist[stu$hispanic == 1&stu$tuition > 1])
[1] 0.0122002

```

Question 3 : Médiane et quartile

Nous déterminons :

- la médiane du nombre d'années d'études des femmes dont la mère est diplômée du supérieur ;
- le troisième quartile du nombre d'années d'études des étudiantes hispaniques ayant des frais de scolarité supérieurs à 1000\$.

```

> median(stu$ed[stu$female == 1 & stu$momcoll == 1])
[1] 16
> quantile(stu$ed[stu$hispanic == 1 & stu$tuition == 1] , 0.75)
75%
NA
> quantile(stu$ed[stu$hispanic == 1 & stu$tuition > 1] , 0.75)
75%
15

```

Question 4 : Vérification de cohérence

Cette commande permet de vérifier qu'aucun étudiant n'est codé à la fois *black* et *hispanic*.

```

> any(stu$black == 1 & stu$hispanic == 1)
[1] FALSE

```

Question 5 : Manipulation de data frames

Nous effectuons différentes extractions de colonnes et de lignes afin de créer de nouveaux tableaux de données.

```
> tab1 <- stu[, c(8:10)]
> head(tab1)
  dist tuition ed
1 0.2 0.88915 12
2 0.2 0.88915 12
3 0.2 0.88915 12
4 0.2 0.88915 12
5 0.4 0.88915 13
6 0.4 0.88915 12
> tab2 <- stu[-c(1, 3), ]
> head(tab2)
  female black hispanic dadcoll momcoll ownhome urban dist tuition ed incomehi county state
2      1      0         0        0        0        1      1 0.2 0.88915 12          0      35      11
4      0      1         0        0        0        1      1 0.2 0.88915 12          0      35      11
5      1      0         0        0        0        0      1 0.4 0.88915 13          0      29      11
6      0      0         0        0        0        1      1 0.4 0.88915 12          0      29      11
7      1      0         0        0        0        1      0 0.4 0.84988 13          0      45      14
8      1      0         0        0        0        1      0 0.4 0.84988 15          0      45      14
> tab3 <- stu[stu$female == 1, ]
> head(tab3)
  female black hispanic dadcoll momcoll ownhome urban dist tuition ed incomehi county state
2      1      0         0        0        0        1      1 0.2 0.88915 12          0      35      11
5      1      0         0        0        0        0      1 0.4 0.88915 13          0      29      11
7      1      0         0        0        0        1      0 0.4 0.84988 13          0      45      14
8      1      0         0        0        0        1      0 0.4 0.84988 15          0      45      14
10     1      0         0        0        0        1      1 3.0 0.88915 15          0      32      11
11     1      0         0        0        0        1      1 3.0 0.88915 12          1      32      11
> tab4 <- tab3[,-1]
> head(tab4)
  black hispanic dadcoll momcoll ownhome urban dist tuition ed incomehi county state
2      0         0        0        0        1      1 0.2 0.88915 12          0      35      11
5      0         0        0        0        0      1 0.4 0.88915 13          0      29      11
7      0         0        0        0        1      0 0.4 0.84988 13          0      45      14
8      0         0        0        0        1      0 0.4 0.84988 15          0      45      14
10     0         0        0        0        1      1 3.0 0.88915 15          0      32      11
11     0         0        0        0        1      1 3.0 0.88915 12          1      32      11
> tab5 <- stu[stu$female == 1, -1]
> head(tab5)
  black hispanic dadcoll momcoll ownhome urban dist tuition ed incomehi county state
2      0         0        0        0        1      1 0.2 0.88915 12          0      35      11
5      0         0        0        0        0      1 0.4 0.88915 13          0      29      11
7      0         0        0        0        1      0 0.4 0.84988 13          0      45      14
8      0         0        0        0        1      0 0.4 0.84988 15          0      45      14
10     0         0        0        0        1      1 3.0 0.88915 15          0      32      11
11     0         0        0        0        1      1 3.0 0.88915 12          1      32      11
> tab5 <- stu[stu$country == 28 & stu$tuition >= 1.2, -(1:3)]
> tab6 <- stu[stu$country == 28 & stu$tuition >= 1.2, -(1:3)]
> head(tab6)
  dadcoll momcoll ownhome urban dist tuition ed incomehi county state
2032      0        0        1      1 0.5 1.24827 14          1      28      31
2033      0        0        1      1 0.5 1.24827 16          0      28      31
2034      1        0        1      1 0.5 1.24827 13          0      28      31
2035      1        0        1      1 0.5 1.24827 16          1      28      31
2036      1        1        1      1 0.5 1.24827 15          1      28      31
2037      1        1        1      1 0.5 1.24827 16          1      28      31
> tab7 <- stu[stu$hispanic == 1 & stu$incomehi == 1, ]
> tab7 <- tab7[, !(names(tab7) %in% c("hispanic", "black", "incomehi"))]
```

Question 6 : Filtrage des étudiants hispaniques

```
> tab7 <- stu[stu$hispanic == 1 & stu$incomehi == 1, ]
> tab7 <- tab7[, !(names(tab7) %in% c("hispanic", "black", "incomehi"))]
Error: unexpected input in "tab7 <- tab7[, !(names(tab7) %"
> tab7 <- tab7[, !(names(tab7) %in% c("hispanic", "black", "incomehi"))]
> nrow(tab7)
```

Nous extrayons les étudiants hispaniques ayant un revenu familial supérieur à 25 000\$, puis supprimons certaines variables.

Question 7 : Conversion des distances

La distance université-domicile est convertie de miles en kilomètres.

```
stu$dist_km <- stu$dist * 10 * 1.60934
| > stu$dist_km <- stu$dist * 10 * 1.60934
```

Question 8 : Création d'une variable factorisée

Nous créons une variable catégorielle représentant le niveau des frais de scolarité.

```
> tuition.fees[stu$tuition <= 0.6] <- "faible"
> tuition.fees[stu$tuition >= 1] <- "eleve"
> table(tuition.fees)
tuition.fees
eleve faible moyen
1621 634 1540
```

Question 9 : Ajout des scores bytest

Nous importons les données du fichier *bytest.txt* et les combinons avec le data frame initial.

```
bytest <- read.table("bytest.txt", header = TRUE)
stubis <- cbind(stu, bytest)
```

Question 10 : Création de la variable communauté

Nous identifions la communauté de chaque étudiant.

```
commu <- ifelse(stu$hispanic == 1, "Hispanic",
               ifelse(stu$black == 1, "Black", "White"))
stu$commu <- commu
```


Question 11 : Moyenne des scores par communauté

```
by(stubis$score, commu, mean)
```

```
> by(stubis$score, commu, mean)
commu: Black
[1] 45.31999
-----
commu: Hispanic
[1] 48.26366
-----
commu: white
[1] 53.28784
> et <- function(x)
```

Question 12 : Calcul de l'écart-type non corrigé

```
>
> et <- function(x) { sqrt((length(x) - 1) / length(x)) * sd(x) }
> et(stubis$score[stu$female == 1])
[1] 8.589739
> et(stubis$score[stu$female == 0])
[1] 9.036126
> stu$par.sup <- ifelse(stu$dadcoll == 1 / stu$momcoll == 1, 1, 0)
```

Question 13 : Variable parents diplômés

```
stu$par_sup <- ifelse(stu$dadcoll == 1 | stu$momcoll == 1, 1, 0)
by(stubis$score, stu$par_sup, quantile)
> stu$par.sup <- ifelse(stu$dadcoll == 1 | stu$momcoll == 1, 1, 0)
> by(stubis$score, stu$par, quantile)
stu$par: 0
  0%   25%   50%   75%  100%
28.95 42.58 49.78 56.40 69.96
-----
stu$par: 1
  0%   25%   50%   75%  100%
32.52 49.24 55.53 61.47 71.36
```

Question 14 : Régression linéaire

Nous étudions la relation entre les frais de scolarité et les années de scolarisation.


```
model_simple <- lm(tuition ~ ed, data = stu)
summary(model_simple)
```

```
cor(stu$tuition, stu$ed)
[1] 0.0570701
summary(model_simple)$r.squared # R² du modèle
[1] 0.003256996
plot(model_simple$residuals) # Affichage des Résidus
```

Question 15 & 16 : Corrélation et qualité du modèle

Le coefficient de détermination R^2 permet d'évaluer la qualité du modèle.

```
summary(model_simple)$r.squared  
plot(model_simple$residuals)
```



Question 17 : Nuage de points et droite de régression

```
plot(stu$ed, stu$tuition,  
     main = "Frais de scolarité vs Années de scolarisation",  
     xlab = "Années de scolarisation",  
     ylab = "Frais de scolarité",  
     pch = 19)  
abline(model_simple, col = "red")
```

Question 18 : Prédictions

```
new_data <- data.frame(ed = c(10, 12, 14))  
predictions_simple <- predict(model_simple, newdata = new_data)  
predictions_simple
```

```
> new_data <- data.frame(ed = c(10, 12, 14))  
> predictions_simple <- predict(model_simple, newdata = new_data)  
> predictions_simple  
      1      2      3  
0.8789980 0.8968418 0.9146855
```

Question 19 : Transformation logarithmique

Nous appliquons une transformation logarithmique afin d'améliorer l'ajustement du modèle.

```

model_transformed <- lm(log(tuition) ~ ed, data = stu)
summary(model_transformed)
> model_transformed <- lm(log(tuition) ~ ed, data = stu)
> summary(model_transformed)

Call:
lm(formula = log(tuition) ~ ed, data = stu)

Residuals:
    Min       1Q   Median       3Q      Max
-0.7426 -0.2252  0.0474  0.2770  0.5100

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.328269    0.043282  -7.585 4.17e-14 ***
ed           0.013144    0.003103   4.236 2.33e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3467 on 3793 degrees of freedom
Multiple R-squared:  0.004708, Adjusted R-squared:  0.004446
F-statistic: 17.94 on 1 and 3793 DF, p-value: 2.332e-05

```

Conclusion

Ce TP nous a permis de renforcer notre maîtrise du langage R pour l'analyse statistique. Les différentes manipulations de données et les modèles de régression ont montré l'importance des variables explicatives dans l'étude des frais de scolarité.